


A/B Test



A/B Test 假设检验与统计功效：从第一性原理推导

一份保留思维连续性的推导笔记

写作原则

这不是从”标准公式”倒推的讲义，而是按“问题起点 → 自然构造 → 撞坑 → 澄清 → 收敛”的顺序整理的推导过程。很多结论（ $SE = \sqrt{\sigma^2/n}$ 、 $\text{power} = \Phi(\delta/SE - z_{\alpha/2})$ 、样本量公式）在正文里是**推出来的**，不是背下来的。中间几处”岔路”（ α 是不是 $P(H_0)$ 、 H_0 为什么取等号、Z 的尺度/量纲）被特意保留下来，因为二义性正是从这些地方来的——真正理解一个概念，往往是理解清楚它**不是什么**。

目录

1. 问题起点：A/B test 到底在问什么
2. 从均值差出发：CLT 与正态近似
3. 关键区分：数据的方差 vs 均值的方差（ σ^2/n 的推导）
4. 构造检验统计量 Z 与标准误 SE
5. 岔路一： H_0 为什么必须是等号，不能是 $\mu_0 \neq \mu_1$
6. 岔路二： α 是条件概率，不是 $P(H_0 \text{ 为真})$
7. 临界值 1.96 从哪来：正推与”逆向工程”的澄清
8. 频率派的灵魂： α 是长期频率，不是某一次的概率

9. p-hacking: 单次保证如何被重复击穿
 10. Power 的正向推导: H_1 下 Z 往哪里移动
 11. 平移量怎么记: 把 SE 当一个测度值, Z 直接减它
 12. 给定 power 反解样本量 n
 13. 点击率 (伯努利) 场景的落地
 14. 频率派 vs 贝叶斯: 不是深浅, 是范式
 15. 面试话术总结
 16. 这次推导训练到的东西
-

1. 问题起点: A/B test 到底在问什么

有一个 control arm 和一个 test arm, 我们测量某个 metric (比如点击率、人均时长)。核心问题是:

两组之间**是不是真的有差异**, 还是我观察到的差异只是随机噪声?

样本是随机抽的, 所以即使两组真实完全一样, 你观察到的样本 metric 也几乎不可能恰好相等。于是问题变成: **观察到的差异, 大到什么程度, 才不能用“纯噪声”来解释?**

先从最自然的入手: 比较两组的**均值**。设 control 真实均值 μ_0 、test 真实均值 μ_1 。我们想判断 μ_0 与 μ_1 是否相等。

2. 从均值差出发: CLT 与正态近似

单个样本 x_i 的分布可以是任意的 (点击是 0/1, 时长是重尾)。但我们要的是**样本均值** $\bar{x} = \frac{1}{n} \sum x_i$ 。

由**中心极限定理 (CLT)**: 只要 n 足够大, 样本均值 $\bar{x}$ 近似服从正态分布, 无论原始分布是什么。所以:

- $\bar{x}_0 \approx N(\mu_0, \text{Var}(\bar{x}_0))$
- $\bar{x}_1 \approx N(\mu_1, \text{Var}(\bar{x}_1))$

两个独立正态的差仍是正态, 且**方差相加**:

$\bar{x}_0 - \bar{x}_1 \approx N(\mu_0 - \mu_1, \text{Var}(\bar{x}_0) + \text{Var}(\bar{x}_1))$

⚠ 注意是方差相加，不是标准差相加。这是第一个容易写错的地方——后面构造标准误时，分母是“方差之和再开根号”，不是“标准差直接相加”。

3. 关键区分：数据的方差 vs 均值的方差

这一节是整份笔记的地基，也是最容易糊的一层。“单个数据点的方差”和“样本均值的方差”差了一个 n 。

- **单点方差** σ^2 ：原始分布 $N(\mu, \sigma^2)$ 的 σ^2 ，估计用样本方差 $\hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$ 。含义是“数据本身有多散”。
- **均值的方差** $\text{Var}(\bar{x})$ ：含义是“我用样本估的这个均值有多不准”。

从第一性原理推 $\text{Var}(\bar{x})$ ：

$$\text{Var}(\bar{x}) = \text{Var}\left(\frac{1}{n} \sum x_i\right) = \frac{1}{n^2} \sum \text{Var}(x_i) = \frac{1}{n^2} \cdot n \sigma^2 = \frac{\sigma^2}{n}$$

两步是关键： $\frac{1}{n^2}$ 从常数平方里提出来； $\sum \text{Var}(x_i) = n \sigma^2$ (n 个独立同方差相加)。

$$\boxed{\text{Var}(\bar{x}) = \frac{\sigma^2}{n}}$$

直觉：样本越多，均值越稳，所以除以 n 。这个 n 后面是 power 的核心旋钮——它就是“多收数据能提高检验灵敏度”的数学来源。

易错点（保留）：一个自然但错误的写法是把均值差的方差写成 $\frac{\sum (x_{0i} - \bar{x}_0)^2}{n_0} + \frac{\sum (x_{1i} - \bar{x}_1)^2}{n_1}$ 。拆开看， $\frac{\sum (x_i - \bar{x})^2}{n}$ 恰好是单点方差的估计 $\hat{\sigma}^2$ ，不是均值的方差——均值的方差还要再除一个 n ，即 $\frac{\hat{\sigma}^2}{n} = \frac{\sum (x_i - \bar{x})^2}{n^2}$ 。**分母应该是 n^2 ，不是 n 。**少除那一层 n ，就是把“数据的方差”当成了“均值的方差”。

4. 构造检验统计量 Z 与标准误 SE

把上面拼起来，均值差的方差：

$$\text{Var}(\bar{x}_0 - \bar{x}_1) = \frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}$$

定义**标准误** (Standard Error, SE) 为它的标准差:

$$SE = \sqrt{\frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}}$$

于是构造**标准化统计量**:

$$Z = \frac{\bar{x}_0 - \bar{x}_1}{SE} = \frac{\bar{x}_0 - \bar{x}_1}{\sqrt{\sigma_0^2/n_0 + \sigma_1^2/n_1}}$$

在 $H_0 (\mu_0 = \mu_1)$ 为真时, $Z \sim N(0,1)$ 。

Z 是**无量纲**的: 分子分母都带 metric 的单位, 除完抵消。这一点后面第 11 节会反复用到——很多混乱来自忘了 Z 已经除过 SE、是无量纲的。

假设检验框架: - $H_0: \mu_0 = \mu_1$ (无差异) - $H_1: \mu_0 \neq \mu_1$ (有差异) - 双边 $\alpha=0.05$, 临界值 $z_{\alpha/2}=1.96$ - 判定: $|Z| > 1.96 \rightarrow$ 拒绝 H_0

5. 岔路一: H_0 为什么必须是等号, 不能是 $\mu_0 \neq \mu_1$

一个很自然的疑问: 既然我们想证明”有差异”, 为什么不把 H_0 直接设成 $\mu_0 \neq \mu_1$?

因为 H_0 必须是一个”能算出统计量确定分布”的假设, 而 $\neq$ 算不出来。

- $\mu_0 = \mu_1$ (等号) $\rightarrow$ 是一个确定的点 (差为 0) $\rightarrow$ Z 有**唯一确定的分布** $N(0,1)$ $\rightarrow$ 能定临界值、能控制 α 。
- $\mu_0 \neq \mu_1$ (不等) $\rightarrow$ 是**无穷多种可能** (差可以是 0.1、5、-3……每个对应不同分布) $\rightarrow$ Z **没有唯一分布** $\rightarrow$ 无法定临界值。

所以 H_0 取等号不是约定俗成, 是**机制上的必需**: 只有”一个点”才能给出确定分布来做检验。“ $\neq$ ”是复合假设 (无穷多情况), 当不了 H_0 , 只能留给 H_1 。

更深一层: 这也解释了为什么 H_0 永远是”无效应/无差异”——它是那个**具体的、可证伪的、能算分布**的假设。你永远在”假设无差异”这个确定的世界里算概率, 然后看数据极不极端。

与 power 的深层联系: H_0 取等号和”算 power 要假设平移量”是同一个原理

这是最值得点破的一层—— H_0 为什么取等号, 和第 10 节算 power 时为什么要 researcher 主动假设一个具体平移量, 是同一个原理的两面。

原理只有一句：要算出一个分布、进而算概率，就必须指定一个”具体的平移量”（即分布中心在哪）。

- H_0 取 $\mu_0 = \mu_1$ ：这是指定”平移量 = 0 “这个具体的点。中心在 0，分布是确定的 $N(0,1)$ ，能算 α 。
- “ $\mu_0 \neq \mu_1$ ” 当不了 H_0 ：因为它不指定具体平移多少——差可以是 0.1σ 、 3σ 、 -5σ每个对应一个不同的中心、不同的分布。“不知道平移多少”就”算不出一个确定的概率”。无穷多个可能的中心，你对哪个算？
- 算 power 恰恰是补上这一步：researcher **主动从” $\neq$ “里挑一个具体的平移量** δ （比如”假设真实差异 = 某个 σ 的倍数”），给那个模糊的”有差异”钉一个确定的点。有了这个具体 δ ， H_1 下的分布中心就定在 δ/SE ，分布确定，power 才能算。

所以三者是连贯的：

假设	指定的平移量	分布	能算什么
H_0	0（确定）	$N(0,1)$	α
“ $\neq$ ”（复合）	未指定（无穷多）	无唯一分布	算不了
H_1 里挑一个具体 δ	δ/SE （确定）	$N(\delta/SE,1)$	power

关键结论：没有”对所有 $\neq$ 的 power”，只有”针对某个具体 δ 的 power”。这就是为什么 power 永远是”针对某个 effect size 说的”——你必须先回答”我想检测多大的真实差异”，才谈得上 power。而”具体假设平移多少”，取决于业务和问题（想检测的最小有意义提升是多少），由 researcher 定，不是天上掉的。

顺带：想”直接给’有差异’算概率”、想让 H_0 是 $\neq$ ——这其实是在要贝叶斯那种”直接算 H_1 的后验概率”。频率派为了不引入先验，只能把每个要算概率的假设都钉成一个具体的点。见第 14 节。

6. 岔路二： α 是条件概率，不是 $P(H_0 \text{ 为真})$

这是频率派最容易搞反的一步。

α 不是” H_0 为真的概率”。在频率派里，“ H_0 为真”是一个关于世界的固定事实（ μ_0 到底等不等于 μ_1 ），它没有概率——参数是固定的，不是随机的。所以 $P(H_0 \text{ 为真})$ 这个东西在频率派里根本不存在。

α 的正确定义是**条件概率**：

$$\alpha = P(\text{拒绝} \mid H_0 \text{ 为真})$$

读作：“给定 H_0 为真这个条件下，你误拒它的概率。”条件是“ H_0 真”，随机的是“你的判断（因为样本随机）”。

“参数固定、统计量随机”是频率派的地基：- $\mu_0 = \mu_1$ （参数相等）——不是随机事件，没有概率，它是“ H_0 ”这个假设的内容/条件。- $|Z| > 1.96$ （统计量落在拒绝域）——是随机事件，有概率，因为 Z 依赖随机抽到的样本。

α 算的是后者在前者条件下的概率。

逐句还原： α 是不是 $P(\mu_0 = \mu_1) / P(H_0)$

这场来回值得完整留下，因为它是频率派最核心的那道坎。

尝试：“ α 就是 H_0 为真的概率， $P(\mu_0 = \mu_1)$ ，小于 α 就拒绝。”

纠正 1： α 不是 $P(H_0 \text{ 为真})$ 。频率派里 μ_0, μ_1 是固定的真实参数，“ $\mu_0 = \mu_1$ ”要么成立要么不成立，它没有概率——就像 $P(2+2=4)$ 不是一个有意义的概率。给假设本身赋概率，那是贝叶斯（需要先验），频率派不做。

追问（很自然）：“可是反推临界值 1.96 的时候，不就是把 α 当概率、而且假设 H_0 为真吗？”

和解：对，这次说的是对的——反推临界值时，确实是“在 H_0 为真的前提下，把 α 当作那条尾巴的概率”去解 1.96。 α 确实是概率。但要看清：这两句话不矛盾，差别在**条件 vs 事件**：

- ✓ “ H_0 为真时， $|Z| > 1.96$ 的概率 = α ” → α 是**条件概率** $P(\text{拒绝} \mid H_0 \text{ 为真})$ ，对。
- ✗ “ α 就是 H_0 为真的概率” → 把 α 读成 $P(H_0 \text{ 为真})$ ，错。

同样是“ α 是概率”，前者是“ H_0 真这个**条件**下的概率”，后者是“ H_0 为真**这件事本身**的概率”。 **α 是前者，不是后者**。那句“想写 $P(\mu_0 = \mu_1)$ ”的直觉方向没错（ α 确实和“ $\mu_0 = \mu_1$ ”有关），但把“条件”错当成了“被算概率的随机事件”： $\mu_0 = \mu_1$ 是**前提世界**，被算概率的随机事件是“误判拒绝”。

纠正 2（顺带）：和 α 比大小的是 **p-value**，不是统计量 Z 。“p-value $< \alpha$ 就拒绝”；若用 Z ，则和临界值 **1.96** 比。而且统计上永远说“不拒绝 H_0 ”，不说“接受 H_0 ”——不显著 $\neq$ 证明无差异（可能只是 power 不够，见第 10 节）。

用四格表钉死（横=真相，竖=你的判断）：

	真相：H ₀ 真（无效应）	真相：H ₁ 真（有效应）
判拒绝	第一类错误 = α	正确 = power
判不拒绝	正确 = $1-\alpha$	第二类错误 = β

α 是左上格（H₀ 真却拒绝）；power 是右上格（H₁ 真且拒绝）。

关于”假阳性”这个词： α 的标准叫法就是 false positive rate（假阳性率），因为它 = “H₀ 真却报了阳性（拒绝）”。业界工具里都这么叫。如果觉得别扭，用”H₀ 为真时误拒的概率”这个说法也完全等价——理解事件本身即可，叫什么无所谓。本笔记后文尽量直接说”拒绝/不拒绝 H₀”。

7. 临界值 1.96 从哪来：正推与”逆向工程”的澄清

定临界值这一步，还没有任何数据、还没做任何判定。它是：

在 H₀ 为真的假想下， $Z \sim N(0,1)$ ，要求”落进拒绝域的概率 = α ”：

$$P(|Z| > \varphi \mid H_0) = \alpha \implies P(Z > \varphi) = \alpha/2 = 0.025 \implies \varphi = 1.96$$

这一步是把 α 当概率、在 H₀ 为真的前提下反解出临界值 $\varphi=1.96$ 。这个 α 是”H₀ 世界里允许的误拒概率”，你拿它去标准正态上切出 1.96。

一个微妙但正确的点：这里”把 α 当概率”是对的—— α 确实是概率（条件概率），条件是”H₀ 真”。这不矛盾于第 6 节说的” α 不是 $P(H_0 \text{ 为真})$ ”：“ α 是”H₀ 真这个条件下的概率”，不是”H₀ 为真这件事本身的概率”。条件 vs 事件，差在这。

判定是另一步：有了数据算出具体 Z（比如 2.3），和 1.96 比， $|2.3| > 1.96 \rightarrow$ 拒绝。这一步对某一次数据是确定的，没有概率。

关键澄清：临界值 1.96 由 α （在 H₀ 下）正向定死，它是固定的，不随 H₁ 或 power 改变。判定规则只有这一套（ $|Z| > 1.96$ 就拒绝），做实验时你不知道真相是 H₀ 还是 H₁，所以不能因为”假设 H₁ 成立”就换一个界限——否则 α 就失控了。逆向解出来的是样本量 n（第 12 节），不是临界值。

8. 频率派的灵魂： α 是长期频率，不是某一次的概率

一个真实的困惑：对某一次具体数据，Z 是确定的、判定是确定的，说“拒绝的概率”听起来很奇怪。

这个困惑抓得对，它触到了频率派概率的本质：

- 对某一次具体数据：Z 确定，判定确定，没有“拒绝的概率”。
- 对“重复无数次实验”这个假想总体： H_0 真时，长期跑这个检验，有 α 比例的实验会碰巧算出 $|Z| > 1.96$ 从而误拒。这才是 $\alpha = P(\text{拒绝} \mid H_0)$ 的正确读法。

$\alpha=0.05$ 的意思是“ H_0 真时，长期重复这个检验程序，5% 的实验会误拒”，不是“这一次实验有 5% 概率拒绝”。概率属于‘程序在重复下的行为’，不属于‘某一次结果’。这是频率派 vs 具体判定的核心区别，也是下一节 p-hacking 的地基。

9. p-hacking：单次保证如何被重复击穿

单次检验： H_0 真时，误拒概率 $=\alpha=0.05$ 。这是“一次”的保证。

但如果做 m 次独立检验（看 m 次数据 / 测 m 个指标 / 切 m 个子群 / 试 m 个变体），只要任意一次拒绝就宣布“发现显著”：

$$P(\text{至少一次误拒}) = 1 - (1-\alpha)^m$$

推导：每次不误拒的概率 $=1-\alpha$ ； m 次全不误拒 $=(1-\alpha)^m$ ；至少一次误拒 $=1-(1-\alpha)^m$ 。

代数字：

m	$1-(1-0.05)^m$
1	0.05
5	0.23
10	0.40
20	0.64
100	0.994

易错点（保留）：一度写成“ m 次都显著的概率 $=\alpha^m$ ”。 α^m 是“全部误拒”（极小， 0.05^m ），方向反了——p-hacking 关心的是“至少一次误拒”，随 m 涨向 1，而 α^m 随 m 跌向 0。p-hacker 只要“至少一次”撞上，其余丢掉不提。

p-hacking 的本质：把“单次程序的 5% 误拒率”，通过重复，放大成“整体大概率误拒”。测 20 个指标、即使真相全是无效应，也有 64% 概率至少抓到一个“显著”。你不是发现了效应，你是耗尽了那 5% 的运气配额。

常见形态：多指标 fishing；peeking（没到样本量反复看数据，一显著就停，等价于多次检验）；多子群切分；多变体挑赢的。

校正手段：- **Bonferroni**：阈值从 α 降到 α/m （保守但简单）。- **Benjamini-Hochberg (FDR)**：控制“假发现比例”而非“至少一个”，大规模测试常用。- **Peeking 专门解**：sequential testing / alpha spending（如 mSPRT、group sequential）——允许持续监控但控制总 α 。工业 A/B 平台标配。

实战纪律：预先注册主指标和样本量，避免事后 fishing。这是防 p-hacking 的第一原则。

10. Power 的正向推导： H_1 下 Z 往哪里移动

Power = $P(\text{拒绝 } H_0 \mid H_1 \text{ 为真})$ —— 和 α 完全对称，只是条件从“ H_0 真”换成“ H_1 真”。它是四格表右上格：真相有效应、你正确地拒绝。

正向推导，从 researcher 视角出发：

H_1 为真意味着真实差异 $\delta = \mu_1 - \mu_0 \neq 0$ 。此时 $\bar{x}_0 - \bar{x}_1$ 的真实均值是 δ ，不是 0。所以标准化统计量 $Z = \frac{\bar{x}_0 - \bar{x}_1}{SE}$ 的分布**中心平移**了：

$$E[Z \mid H_1] = \frac{E[\bar{x}_0 - \bar{x}_1]}{SE} = \frac{\delta}{SE}$$

这个 δ/SE 是“非中心参数”，是 **power** 的一切。它是 H_1 分布相对 H_0 分布“平移了多远”，也是**信噪比**（效应 ÷ 噪声）。

于是 H_1 下 $Z \sim N(\delta/SE, 1)$ （中心移到 δ/SE ，形状不变）。拒绝域仍是固定的 $|Z| > 1.96$ 。

Power = 平移后的分布落进拒绝域的概率（取主侧，忽略远端小概率）：

$$\text{Power} = P(|Z| > 1.96 \mid Z \sim N(\frac{\delta}{SE}, 1)) = P(N(0, 1) > 1.96 - \frac{\delta}{SE}) = \Phi\left(\frac{\delta}{SE} - z_{\alpha/2}\right)$$

读这个式子（全部直觉都在这里）：power 取决于 $\frac{\delta}{SE} - z_{\alpha/2}$ 。

- δ （效应）越大 $\rightarrow$ 平移越远 $\rightarrow$ power 越高 $\checkmark$
- SE 越小（n 越大、 σ 越小） $\rightarrow \delta/SE$ 越大 $\rightarrow$ power 越高 $\checkmark$
- $z_{\alpha/2}$ 越小（ α 越大） $\rightarrow$ power 越高 $\checkmark$ （ α 与 power 的 trade-off）

四个旋钮（效应量、样本量、方差、 α ）全从 $\Phi(\delta/SE - z_{\alpha/2})$ 这一个式子里掉出来。

一个具体数值：若设真实差异 $\delta = 2 \cdot SE$ （即信噪比 $\delta/SE = 2$ ），则 $Z \sim N(2,1)$ ：

$$\text{Power} = P(Z > 1.96 \mid N(2,1)) = \Phi(2 - 1.96) = \Phi(0.04) \approx 0.52$$

移动 2 个 SE 只有约 52% 的 power——不够常用的 0.8/0.9。要 power=0.9，需要 $\delta/SE = 1.96 + 1.28 = 3.24$ ，即平移 3.24 个 SE。这也回答了“ δ （或 μ ）该取多少”：它是 researcher 根据“想检测多大效应 + 想要多高 power”共同决定的输入。

11. 平移量怎么记：把 SE 当一个测度值，Z 直接减它

这一节讲清楚 power 推导里唯一真正容易反复卡住的地方——“Z 的中心平移了多少、标准化时到底减什么”。结论其实很干净，先把它作为主记法说清楚，再附一句常见的自我打架来源。

主记法：SE 只看测度值，Z 减这个数值

不看量纲、不管单位，把 $SE = \sqrt{\sigma_0^2/n_0 + \sigma_1^2/n_1}$ 当成一个算出来的具体数值（测度值）。比如它算出来 = 4。

researcher 假设真实差异让 Z 的中心平移 k 个 SE（比如 k=2，即平移 2SE = 8 这个数值）。那么标准化就是直接减掉这个测度值：

$$Z_1 = Z - k \cdot SE \sim N(0,1)$$

拒绝域用同一个尺度： $|Z| > 1.96 \cdot SE$ 。

这就完了，没有“再除一次 SE”的操作。只要 Z 和 SE 从头到尾用同一个尺度（都是原始 metric 的测度值）， $Z_1 = Z - k \cdot SE$ 天经地义。power 就是：

$$\text{Power} = P(Z > 1.96 \cdot SE \mid Z_{\text{中心}} = k \cdot SE) = \Phi(k - 1.96)$$

$k=2 \rightarrow \Phi(0.04) \approx 0.52$ 。注意最后 power 只依赖 k（平移了几个 SE），SE 的具体数值 4 自己抵消掉了——这也印证了“power 只取决于信噪比”。

一句话：SE 就是一个数，Z 减这个数（或它的倍数），全程一个尺度，不需要任何额外的除法。

唯一要避免的自我打架：中途换了尺度

上面那套之所以有时候会绕晕，是因为同一个 Z 可以有两种定义，一旦中途换了、却没同步改”减什么”，就会打架：

- 如果你的 $Z = \bar{x}_0 - \bar{x}_1$ （均值差本身，和 SE 同尺度）→ 减 $k \cdot SE$ ，拒绝域 $1.96 \cdot SE$ 。✅ 这就是上面的主记法。
- 如果你的 $Z = \frac{\bar{x}_0 - \bar{x}_1}{SE}$ （已经除过 SE、无量纲）→ 那它的中心平移量就是 k （纯数），减 k ，拒绝域 1.96 。

两套都对，各自内部自洽，power 都是 $\Phi(k-1.96)$ 。出错只有一种情形：用了”除过 SE “的 Z，却去减 $k \cdot SE$ （带 SE 的量）——一个已经把 SE 除掉的量，又减一个含 SE 的量，尺度就不一致了。反过来（用均值差的 Z，却减纯数 k ）也一样。

一句话记牢：Z 减的东西，尺度必须和 Z 一样。Z 是均值差就减 $k \cdot SE$ ；Z 已除 SE 就减 k 。一份推导里选定一个，别中途换。主记法（SE 当测度值、 $Z - k \cdot SE$ ）最不容易错，因为它全程只有”原始测度值”一个尺度。

12. 给定 power 反解样本量 n

实践中真正的用法是反过来：定好想要的 power 和 α ，反解需要多大样本。通常假设 $n_0 = n_1 = n$ （50/50 等分流量）。

要求 $\text{power} = 1 - \beta$ ，需要平移量满足：

$$\frac{\delta}{SE} = z_{\alpha/2} + z_{\beta}$$

其中 $z_{\alpha/2} = 1.96$ ($\alpha = 0.05$ 双边)， $z_{\beta} = \Phi^{-1}(\text{power})$
($\text{power} = 0.8 \rightarrow 0.84$ ； $\text{power} = 0.9 \rightarrow 1.28$)。

代入 $SE = \sqrt{\frac{\sigma^2}{n} + \frac{\sigma^2}{n}} = \sqrt{\frac{2\sigma^2}{n}}$
(等样本、等方差)：

$$\frac{\delta}{\sqrt{2\sigma^2/n}} = z_{\alpha/2} + z_{\beta} \implies \frac{\delta^2 n}{2\sigma^2} = (z_{\alpha/2} + z_{\beta})^2$$

$$\boxed{n = \frac{2\sigma^2 (z_{\alpha/2} + z_{\beta})^2}{\delta^2}} \quad \text{每组}$$

读它（核心记忆）：

- $n \propto \sigma^2$: 方差越大越要样本 $\rightarrow$ 降方差 (CUPED、分层、协变量调整) = 省样本 = 提 power。
- $n \propto 1/\delta^2$: 想检测的效应越小, 样本量按平方涨—— δ 减半, n 要 4 倍。
- α 越小、power 要求越高 $\rightarrow z$ 越大 $\rightarrow n$ 越大。
- 常数: $\alpha=0.05$ 时, power=0.8 下 $(1.96+0.84)^2 \approx 7.85$, 故 $n \approx 16\sigma^2/\delta^2$ (每组); power=0.9 下 $(1.96+1.28)^2 \approx 10.5$, 故 $n \approx 21\sigma^2/\delta^2$ 。

13. 点击率 (伯努利) 场景的落地

metric 是点击/非点击时, 每个用户是伯努利变量: $X_i \sim \text{Bernoulli}(p)$, 其中 p 就是真实点击率 (= 均值 μ)。

伯努利的方差不是自由参数, 由 p 决定:

$$\text{Var}(X_i) = p(1-p)$$

所以把通用公式里的 $\mu \rightarrow p$ 、 $\sigma^2 \rightarrow p(1-p)$:

$$SE = \sqrt{\frac{p_0(1-p_0)}{n_0} + \frac{p_1(1-p_1)}{n_1}}, \quad Z = \frac{\hat{p}_0 - \hat{p}_1}{SE}$$

样本量:

$$n = \frac{2}{p(1-p)} (z_{\alpha/2} + z_{\beta})^2 \delta^2$$

其中 δ 是想检测的点击率**绝对提升** (如从 10% 到 10.5%, $\delta=0.005$)。

一个经典考点: 算 SE 时用不用合并比例 (pooled)。H₀ 下 $p_0=p_1$, 检验时常用 $\hat{p} = \frac{\text{总点击数}}{n_0+n_1}$ 估共同的 p , $SE = \sqrt{\hat{p}(1-\hat{p})(1/n_0+1/n_1)}$ 。而推 power / 算样本量时用各自的 p 。两个场合用哪个, 是面试爱追的细节。

14. 频率派 vs 贝叶斯: 不是深浅, 是范式

贝叶斯不是频率派的”进阶版”, 是平行的另一条路:

- **频率派**（本笔记全程）：条件永远是“给定 H_0/H_1 为真”，算统计量的概率。不给假设赋概率。回答：“ H_0 真时，我看到这么极端数据的概率”（p-value）。
- **贝叶斯**：直接算 $P(H_1 \mid \text{数据})$ 、 $P(p_1 > p_0 \mid \text{数据})$ ——给假设本身赋后验概率，需要先验。回答：“看到数据后， H_1 为真的概率”。

第 5、6 节里“想给‘有差异’算概率、想让 H_0 是 $\neq$ 、想写 $P(H_0)$ ”“的那个直觉——在频率派里非法，在贝叶斯里正是合法的核心。这不是谁对谁错，是两套范式。

工业 A/B 里两者都用：频率派是主流默认（多数实验平台 + sequential）；贝叶斯版（“ $P(\text{test 更好})=95\%$ ”）在部分平台用，好处是能直接说“有 95% 概率 test 更好”、且对 peeking 天然更友好。

15. 面试话术总结（把推导压成能讲的几句）

Power 是什么： > “Power 是有真实效应 δ 时，能正确拒绝 H_0 的概率 $=1-\beta$ 。给定 n 它是 $\Phi(\delta/SE - z_{\alpha/2})$ 。由四个量决定：效应量、样本量、方差、 α 。”

实战怎么用： > “上线前我反过来用它反解样本量 $n = 2\sigma^2(z_{\alpha/2} + z_{\beta})^2 / \delta^2$ ，定 $\text{power}=0.8$ 、 $\alpha=0.05$ 。关键是 n 反比于 δ^2 ——想检测的提升越小，样本量涨得越快；而降方差（CUPED）能直接省样本。这样避免样本不足导致真效应测不出来。”

解读负结果： > “实验不显著，要区分是真没效果，还是 power 不够没测出来。没 power 的实验，不显著 $\neq$ 无效。”

p-hacking： > “单次 $\alpha=0.05$ 只保证单次误拒率， m 次至少一次误拒 $=1-(1-\alpha)^m$ ，测 20 个指标就有 64%。所以我预先注册主指标和样本量，多重比较用 Bonferroni/FDR，peeking 用 sequential testing。”

贝叶斯（加分）： > “还有 Bayesian A/B，区别是给假设赋后验、能直接说 $P(\text{更好})$ 、对 peeking 更友好。”

16. 这次推导训练到的东西

不是“记住了 power 公式”，而是重走了一条从第一性原理构造统计推断的路，可迁移：

1. 把‘均值的方差’和‘数据的方差’分清（差一个 n ）——一切标准误的地基。

2. H_0 取等号是机制必需，不是约定：只有“一个点”才有确定分布。
 3. α 是条件概率（条件= H_0 真），不是 $P(H_0)$ ；参数固定、统计量随机。
 4. 频率派的概率是长期频率，属于“程序”，不属于“某一次结果”——这直接推出 p-hacking。
 5. power 是对称的另一半：Z 中心从 0 平移到 δ/SE ，落进固定拒绝域的概率。
 6. 尺度一致性：把 SE 当一个测度值，Z 减这个数（或它的倍数），全程一个尺度就不会错。Z 减的东西尺度必须和 Z 一样——中途换尺度是最常见的自相矛盾来源。
 7. 反解 n: $n \propto \sigma^2/\delta^2$ ，效应减半、样本 4 倍；降方差就是省样本。
-

一句话压缩：整套 A/B 检验，是“假设无差异（ H_0 取一个点）→ 由 CLT 得均值差近似正态、标准误 $\sqrt{\sigma^2/n}$ → 标准化成 Z → 在 H_0 世界定临界值 1.96（控制长期误拒率 α ）→ 在 H_1 世界看 Z 平移 δ/SE 后落进拒绝域的概率（power）→ 反解样本量”。每一步都是从“参数固定、样本随机 + 想控制两类错误”这一个出发点长出来的。