

A/B Test 假设检验与统计功效：从第一性原理推导

一份保留思维连续性的推导笔记

写作原则

这不是从“标准公式”倒推的讲义，而是按“问题起点 → 自然构造 → 撞坑 → 澄清 → 收敛”的顺序整理的推导过程。很多结论（ $SE = \sqrt{\sigma^2/n}$ 、power = $\Phi(\delta/SE - z_{\alpha/2})$ 、样本量公式）在正文里是**推出来的**，不是背下来的。中间几处“岔路”（ α 是不是 $P(H_0)$ 、 H_0 为什么取等号、 Z 的尺度/量纲）被特意保留下来，因为二义性正是从这些地方来的——真正理解一个概念，往往是理解清楚它**不是什么**。

目录

1. 问题起点：A/B test 到底在问什么
 2. 从均值差出发：CLT 与正态近似
 3. 关键区分：数据的方差 vs 均值的方差（ σ^2/n 的推导）
 4. 构造检验统计量 Z 与标准误 SE
 5. 岔路一： H_0 为什么必须是等号，不能是 $\mu_0 / \mu_1 =$
 6. 岔路二： α 是条件概率，不是 $P(H_0 \text{ 为真})$
 7. 临界值 1.96 从哪来：正推与“逆向工程”的澄清
 8. 频率派的灵魂： α 是长期频率，不是某一次的概率
 9. p-hacking：单次保证如何被重复击穿
 10. Power 的正向推导： H_1 下 Z 往哪里移动
 11. 平移量怎么记：把 SE 当一个测度值， Z 直接减它
 12. 给定 power 反解样本量 n
 13. 点击率（伯努利）场景的落地
 14. 频率派 vs 贝叶斯：不是深浅，是范式
 15. 面试话术总结
 16. 这次推导训练到的东西
-

1. 问题起点：A/B test 到底在问什么

有一个 control arm 和一个 test arm，我们测量某个 metric（比如点击率、人均时长）。核心问题是：

两组之间是不是真的有差异，还是我观察到的差异只是随机噪声？

样本是随机抽的，所以即使两组真实完全一样，你观察到的样本 metric 也几乎不可能恰好相等。于是问题变成：**观察到的差异，大到什么程度，才不能用“纯噪声”来解释？**

先从最自然的入手：比较两组的**均值**。设 control 真实均值 μ_0 、test 真实均值 μ_1 。我们想判断 μ_0 与 μ_1 是否相等。

2. 从均值差出发：CLT 与正态近似

单个样本 x_i 的分布可以是任意的（点击是 0/1，时长是重尾）。但我们要的是**样本均值** $\bar{x} = \frac{1}{n} \sum x_i$ 。

由**中心极限定理（CLT）**：只要 n 足够大，样本均值 $\bar{x}$ 近似服从正态分布，无论原始分布是什么。所以：

- $\bar{x}_0 \approx N(\mu_0, \text{Var}(\bar{x}_0))$
- $\bar{x}_1 \approx N(\mu_1, \text{Var}(\bar{x}_1))$

两个独立正态的差仍是正态，且**方差相加**：

$$\bar{x}_0 - \bar{x}_1 \approx N(\mu_0 - \mu_1, \text{Var}(\bar{x}_0) + \text{Var}(\bar{x}_1))$$

注意是**方差**相加，不是**标准差**相加。这是第一个容易写错的地方——后面构造标准误时，分母是“方差之和再开根号”，不是“标准差直接相加”。

3. 关键区分：数据的方差 vs 均值的方差

这一节是整份笔记的地基，也是最容易糊的一层。“**单个数据点的方差**”和“**样本均值的方差**”差了一个 n 。

- **单点方差** σ^2 ：原始分布 $N(\mu, \sigma^2)$ 的 σ^2 ，估计用样本方差 $\hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$ 。含义是“数据本身有多散”。
- **均值的方差** $\text{Var}(\bar{x})$ ：含义是“我用样本估的这个均值有多不准”。

从第一性原理推 $\text{Var}(\bar{x})$ ：

$$\text{Var}(\bar{x}) = \text{Var}\left(\frac{\sum_i x_i}{n}\right) = \frac{1}{n^2} \sum_i \text{Var}(x_i) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}$$

两步是关键： $\frac{1}{n^2}$ 从常数平方里提出来； $\sum \text{Var}(x_i) = n\sigma^2$ （ n 个独立同方差相加）。

$$\boxed{\text{Var}(\bar{x}) = \frac{\sigma^2}{n}}$$

直觉：样本越多，均值越稳，所以除以 n 。这个 n 后面是 power 的核心旋钮——它就是”多收数据能提高检验灵敏度”的数学来源。

易错点（保留）：一个自然但错误的写法是把均值差的方差写成 $\frac{\sum(x_{0i}-\bar{x}_0)^2}{n_0} + \frac{\sum(x_{1i}-\bar{x}_1)^2}{n_1}$ 。拆开看， $\frac{\sum(x_i-\bar{x})^2}{n}$ 恰好是单点方差的估计 $\hat{\sigma}^2$ ，不是均值的方差——均值的方差还要再除一个 n ，即 $\frac{\hat{\sigma}^2}{n} = \frac{\sum(x_i-\bar{x})^2}{n^2}$ 。分母应该是 n^2 ，不是 n 。少除那一层 n ，就是把”数据的方差”当成了”均值的方差”。

4. 构造检验统计量 Z 与标准误 SE

把上面拼起来，均值差的方差：

$$\text{Var}(\bar{x}_0 - \bar{x}_1) = \frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}$$

定义标准误（Standard Error, SE）为它的标准差：

$$SE = \sqrt{\frac{\sigma_0^2}{n_0} + \frac{\sigma_1^2}{n_1}}$$

于是构造标准化统计量：

$$Z = \frac{\bar{x}_0 - \bar{x}_1}{SE} = \frac{\bar{x}_0 - \bar{x}_1}{\sqrt{\sigma_0^2/n_0 + \sigma_1^2/n_1}}$$

在 H_0 ($\mu_0 = \mu_1$) 为真时， $Z \sim N(0, 1)$ 。

Z 是无量纲的：分子分母都带 metric 的单位，除完抵消。这一点后面第 11 节会反复用到——很多混乱来自忘了 Z 已经除过 SE 、是无量纲的。

假设检验框架：- $H_0 : \mu_0 = \mu_1$ （无差异） - $H_1 : \mu_0 \neq \mu_1$ （有差异） - 双边 $\alpha = 0.05$ ，临界值 $z_{\alpha/2} = 1.96$ - 判定： $|Z| > 1.96 \rightarrow$ 拒绝 H_0

5. 岔路一： H_0 为什么必须是等号，不能是 $\mu_0 \neq \mu_1$

一个很自然的疑问：既然我们想证明”有差异”，为什么不把 H_0 直接设成 $\mu_0 \neq \mu_1$ ？

因为 H_0 必须是一个”能算出统计量确定分布”的假设，而 $\mu_0 \neq \mu_1$ 算不出来。

- $\mu_0 = \mu_1$ （等号） $\rightarrow$ 是一个确定的点（差为 0） $\rightarrow Z$ 有唯一确定的分布 $N(0, 1)$ $\rightarrow$ 能定临界值、能控制 α 。
- $\mu_0 \neq \mu_1$ （不等） $\rightarrow$ 是无穷多种可能（差可以是 0.1、5、-3……每个对应不同分布） $\rightarrow Z$ 没有唯一分布 $\rightarrow$ 无法定临界值。

所以 H_0 取等号不是约定俗成，是**机制上的必需**：只有”一个点”才能给出确定分布来做检验。“ $/=$ ”是复合假设（无穷多情况），当不了 H_0 ，只能留给 H_1 。

更深一层：这也解释了为什么 H_0 永远是”无效应/无差异”——它是那个**具体的、可证伪的、能算分布**的假设。你永远在”假设无差异”这个确定的世界里算概率，然后看数据极不极端。

与 power 的深层联系： H_0 取等号和”算 power 要假设平移量”是同一个原理

这是最值得点破的一层—— H_0 为什么取等号，和第 10 节算 power 时为什么要 researcher 主动假设一个具体平移量，是同一个原理的两面。

原理只有一句：要算出一个分布、进而算概率，就必须指定一个”具体的平移量”（即分布中心在哪）。

- H_0 取 $\mu_0 = \mu_1$ ：这是指定”平移量 = 0 “这个**具体的点**。中心在 0，分布是确定的 $N(0, 1)$ ，能算 α 。
- “ μ_0 / μ_1 ”=当不了 H_0 ：因为它**不指定具体平移多少**——差可以是 0.1σ 、 3σ 、 -5σ ……每个对应一个不同的中心、不同的分布。“**不知道平移多少”就”算不出一个确定的概率”**。无穷多个可能的中心，你对哪个算？
- 算 power 恰恰是补上这一步：researcher **主动从” $/=$ ”里挑一个具体的平移量** δ （比如”假设真实差异 = 某个 σ 的倍数”），给那个模糊的”有差异”钉一个确定的点。有了这个具体 δ ， H_1 下的分布中心就定在 δ/SE ，分布确定，power 才能算。

所以三者是连贯的：

假设	指定的平移量	分布	能算什么
H_0	0（确定）	$N(0, 1)$	α
“ $/=$ ”（复合）	未指定（无穷多）	无唯一分布	算不了
H_1 里挑一个具体 δ	δ/SE （确定）	$N(\delta/SE, 1)$	power

关键结论：没有”对所有 $/$ 的 power”，只有”针对某个具体 δ 的 power”。这就是为什么 power 永远是”针对某个 effect size 说的”——你必须先回答”我想检测多大的真实差异”，才谈得上 power。而”具体假设平移多少”，取决于业务和问题（想检测的最小有意义提升是多少），由 researcher 定，不是天上掉的。

顺带：想”直接给’有差异’算概率”、想让 H_0 是 $/=$ ——这其实是在要**贝叶斯**那种”直接算 H_1 的后验概率”。频率派为了不引入先验，只能把每个要算概率的假设都钉成一个具体的点。见第 14 节。

6. 岔路二： α 是条件概率，不是 $P(H_0 \text{ 为真})$

这是频率派最容易搞反的一步。

α 不是“ H_0 为真的概率”。在频率派里，“ H_0 为真”是一个关于世界的固定事实（ μ_0 到底等不等于 μ_1 ），它没有概率——参数是固定的，不是随机的。所以 $P(H_0 \text{ 为真})$ 这个东西在频率派里根本不存在。

α 的正确定义是条件概率：

$$\alpha = P(\text{拒绝 } H_0 \mid H_0 \text{ 为真})$$

读作：“给定 H_0 为真这个条件下，你误拒它的概率。”条件是“ H_0 真”，随机的是“你的判断（因为样本随机）”。

“参数固定、统计量随机”是频率派的地基：- $\mu_0 = \mu_1$ （参数相等）——不是随机事件，没有概率，它是“ H_0 ”这个假设的内容/条件。- $|Z| > 1.96$ （统计量落在拒绝域）——是随机事件，有概率，因为 Z 依赖随机抽到的样本。

α 算的是后者在前者条件下的概率。

逐句还原： α 是不是 $P(\mu_0 = \mu_1) / P(H_0)$

这场来回值得完整留下，因为它是频率派最核心的那道坎。

尝试：“ α 就是 H_0 为真的概率， $P(\mu_0 = \mu_1)$ ，小于 α 就拒绝。”

纠正 1： α 不是 $P(H_0 \text{ 为真})$ 。频率派里 μ_0, μ_1 是固定的真实参数，“ $\mu_0 = \mu_1$ ”要么成立要么不成立，它没有概率——就像 $P(2 + 2 = 4)$ 不是一个有意义的概率。给假设本身赋概率，那是贝叶斯（需要先验），频率派不做。

追问（很自然）：“可是反推临界值 1.96 的时候，不就是把 α 当概率、而且假设 H_0 为真吗？”

和解：对，这次说的是对的——反推临界值时，确实是“在 H_0 为真的前提下，把 α 当作那条尾巴的概率”去解 1.96。 α 确实是概率。但要看清：这两句话不矛盾，差别在条件 vs 事件：

- “ H_0 为真时， $|Z| > 1.96$ 的概率 = α ” $\rightarrow \alpha$ 是条件概率 $P(\text{拒绝} \mid H_0 \text{ 真})$ ，对。
- “ α 就是 H_0 为真的概率” $\rightarrow$ 把 α 读成 $P(H_0 \text{ 真})$ ，错。

同样是“ α 是概率”，前者是“ H_0 真这个条件下的概率”，后者是“ H_0 为真这件事本身的概率”。 α 是前者，不是后者。那句“想写 $P(\mu_0 = \mu_1)$ ”的直觉方向没错（ α 确实和“ $\mu_0 = \mu_1$ ”有关），但把“条件”错当成了“被算概率的随机事件”： $\mu_0 = \mu_1$ 是前提世界，被算概率的随机事件是“误判拒绝”。

纠正 2（顺带）：和 α 比大小的是 p-value，不是统计量 Z 。“p-value $< \alpha$ 就拒绝”；若用 Z ，则和临界值 1.96 比。而且统计上永远说“不拒绝 H_0 ”，不说“接受 H_0 ”——不显著 / 证明无差异（可能只是 power 不够，见第 10 节）。

用四格表钉死（横=真相，竖=你的判断）：

	真相: H_0 真 (无效应)	真相: H_1 真 (有效应)
判拒绝	第一类错误 = α	正确 = power
判不拒绝	正确 = $1 - \alpha$	第二类错误 = β

α 是左上格 (H_0 真却拒绝) ; power 是右上格 (H_1 真且拒绝) 。

关于”假阳性”这个词: α 的标准叫法就是 false positive rate (假阳性率), 因为它 = “ H_0 真却报了阳性 (拒绝)” 。业界工具里都这么叫。如果觉得别扭, 用” H_0 为真时误拒的概率” 这个说法也完全等价——理解事件本身即可, 叫什么无所谓。本笔记后文尽量直接说”拒绝/不拒绝 H_0 “。

7. 临界值 1.96 从哪来: 正推与”逆向工程” 的澄清

定临界值这一步, 还没有任何数据、还没做任何判定。它是:

在 H_0 为真的假想下, $Z \sim N(0,1)$, 要求”落进拒绝域的概率 = α “:

$$P(|Z| > \varphi \mid H_0) = \alpha \implies P(Z > \varphi) = \alpha/2 = 0.025 \implies \varphi = 1.96$$

这一步是把 α 当概率、在 H_0 为真的前提下反解出临界值 $\varphi = 1.96$ 。这个 α 是” H_0 世界里允许的误拒概率”, 你拿它去标准正态上切出 1.96。

一个微妙但正确的点: 这里”把 α 当概率” 是对的—— α 确实是概率 (条件概率), 条件是” H_0 真”。这不矛盾于第 6 节说的” α 不是 $P(H_0 \text{ 为真})$ “: α 是” H_0 真这个条件下的概率”, 不是” H_0 为真这件事本身的概率”。条件 vs 事件, 差在这。

判定是另一步: 有了数据算出具体 Z (比如 2.3) , 和 1.96 比, $|2.3| > 1.96 \rightarrow$ 拒绝。这一步对某一次数据是确定的, 没有概率。

关键澄清: 临界值 1.96 由 α (在 H_0 下) 正向定死, 它是固定的, 不随 H_1 或 power 改变。判定规则只有这一套 ($|Z| > 1.96$ 就拒绝), 做实验时你不知道真相是 H_0 还是 H_1 , 所以不能因为”假设 H_1 成立”就换一个界限——否则 α 就失控了。逆向解出来的是样本量 n (第 12 节), 不是临界值。

8. 频率派的灵魂: α 是长期频率, 不是某一次的概率

一个真实的困惑: 对某一次具体数据, Z 是确定的、判定是确定的, 说”拒绝的概率”听起来很怪。

这个困惑抓得对, 它触到了频率派概率的本质:

- 对某一次具体数据: Z 确定, 判定确定, 没有”拒绝的概率”。

· 对”重复无数次实验”这个假想总体： H_0 真时，长期跑这个检验，有 α 比例的实验会碰巧算出 $|Z| > 1.96$ 从而误拒。**这才是 $\alpha = P(\text{拒绝} | H_0)$ 的正确读法。**

$\alpha = 0.05$ 的意思是” H_0 真时，长期重复这个检验程序，5% 的实验会误拒”，**不是**”这一次实验有 5% 概率拒绝”。**概率属于’程序在重复下的行为’，不属于’某一次结果’。**这是频率派 vs 具体判定的核心区别，也是下一节 p-hacking 的地基。

9. p-hacking：单次保证如何被重复击穿

单次检验： H_0 真时，误拒概率 = $\alpha = 0.05$ 。这是”一次”的保证。

但如果做 m 次独立检验（看 m 次数据 / 测 m 个指标 / 切 m 个子群 / 试 m 个变体），只要任意一次拒绝就宣布”发现显著”：

$$P(\text{至少一次误拒}) = 1 - (1 - \alpha)^m$$

推导：每次不误拒的概率 = $1 - \alpha$ ； m 次全不误拒 = $(1 - \alpha)^m$ ；至少一次误拒 = $1 - (1 - \alpha)^m$ 。

代数字：

m	$1 - (1 - 0.05)^m$
1	0.05
5	0.23
10	0.40
20	0.64
100	0.994

易错点（保留）：一度写成” m 次都显著的概率 = α^m ”。 α^m 是”全部误拒”（极小， 0.05^m ），**方向反了**——p-hacking 关心的是”至少一次误拒”，随 m 涨向 1，而 α^m 随 m 跌向 0。p-hacker 只要”至少一次”撞上，其余丢掉不提。

p-hacking 的本质：把”单次程序的 5% 误拒率”，通过重复，放大成”整体大概率误拒”。测 20 个指标、即使真相全是无效应，也有 64% 概率至少抓到一个”显著”。**你不是发现了效应，你是耗尽了那 5% 的运气配额。**

常见形态：多指标 fishing；peeking（没到样本量反复看数据，一显著就停，等价于多次检验）；多子群切分；多变体挑赢的。

校正手段：- Bonferroni：阈值从 α 降到 α/m （保守但简单）。- Benjamini-Hochberg (FDR)：控制“假发现比例”而非“至少一个”，大规模测试常用。- Peeking 专门解：sequential testing / alpha spending（如 mSPRT、group sequential）——允许持续监控但控制总 α 。工业 A/B 平台标配。

实战纪律：预先注册主指标和样本量，避免事后 fishing。这是防 p-hacking 的第一原则。

10. Power 的正向推导： H_1 下 Z 往哪里移动

Power = $P(\text{拒绝 } H_0 \mid H_1 \text{ 为真})$ —— 和 α 完全对称，只是条件从“ H_0 真”换成“ H_1 真”。它是四格表右上格：真相有效应、你正确地拒绝。

正向推导，从 researcher 视角出发：

H_1 为真意味着真实差异 $\delta = \mu_1 - \mu_0 \neq 0$ 。此时 $\bar{x}_0 - \bar{x}_1$ 的真实均值是 δ ，不是 0。所以标准化统计量 $Z = \frac{\bar{x}_0 - \bar{x}_1}{SE}$ 的分布中心平移了：

$$E[Z \mid H_1] = \frac{E[\bar{x}_0 - \bar{x}_1]}{SE} = \frac{\delta}{SE}$$

这个 δ/SE 是“非中心参数”，是 power 的一切。它是 H_1 分布相对 H_0 分布“平移了多远”，也是信噪比（效应 ÷ 噪声）。

于是 H_1 下 $Z \sim N(\delta/SE, 1)$ （中心移到 δ/SE ，形状不变）。拒绝域仍是固定的 $|Z| > 1.96$ 。

Power = 平移后的分布落进拒绝域的概率（取主侧，忽略远端小概率）：

$$\text{Power} = P(Z > 1.96 \mid Z \sim N(\frac{\delta}{SE}, 1)) = P(N(0, 1) > 1.96 - \frac{\delta}{SE}) = \Phi\left(\frac{\delta}{SE} - z_{\alpha/2}\right)$$

读这个式子（全部直觉都在这里）：power 取决于 $\frac{\delta}{SE} - z_{\alpha/2}$ 。

- δ （效应）越大 $\rightarrow$ 平移越远 $\rightarrow$ power 越高 $\checkmark$
- SE 越小（ n 越大、 σ 越小） $\rightarrow \delta/SE$ 越大 $\rightarrow$ power 越高 $\checkmark$
- $z_{\alpha/2}$ 越小（ α 越大） $\rightarrow$ power 越高 $\checkmark$ （ α 与 power 的 trade-off）

四个旋钮（效应量、样本量、方差、 α ）全从 $\Phi(\delta/SE - z_{\alpha/2})$ 这一个式子里掉出来。

一个具体数值：若设真实差异 $\delta = 2 \cdot SE$ （即信噪比 $\delta/SE = 2$ ），则 $Z \sim N(2, 1)$ ：

$$\text{Power} = P(Z > 1.96 \mid N(2, 1)) = \Phi(2 - 1.96) = \Phi(0.04) \approx 0.52$$

移动 2 个 SE 只有约 52% 的 power——不够常用的 0.8/0.9。要 power=0.9，需要 $\delta/SE = 1.96 + 1.28 = 3.24$ ，即平移 3.24 个 SE。这也回答了“ δ （或 μ ）该取多少”：它是 researcher 根据“想检测多大效应 + 想要多高 power”共同决定的输入。

11. 平移量怎么记：把 SE 当一个测度值， Z 直接减它

这一节讲清楚 power 推导里唯一真正容易反复卡住的地方——“ Z 的中心平移了多少、标准化时到底减什么”。结论其实很干净，先把它作为主记法说清楚，再附一句常见的自我打架来源。

主记法： SE 只看测度值， Z 减这个数值

不看量纲、不管单位，把 $SE = \sqrt{\sigma_0^2/n_0 + \sigma_1^2/n_1}$ 当成一个算出来的具体数值（测度值）。比如它算出来 = 4。

researcher 假设真实差异让 Z 的中心平移 k 个 SE （比如 $k = 2$ ，即平移 $2SE = 8$ 这个数值）。那么标准化就是直接减掉这个测度值：

$$Z_1 = Z - k \cdot SE \sim N(0, 1)$$

拒绝域用同一个尺度： $|Z| > 1.96 \cdot SE$ 。

这就完了，没有”再除一次 SE “的操作。只要 Z 和 SE 从头到尾用同一个尺度（都是原始 metric 的测度值）， $Z_1 = Z - k \cdot SE$ 天经地义。power 就是：

$$\text{Power} = P(Z > 1.96 \cdot SE \mid Z \text{ 中心} = k \cdot SE) = \Phi(k - 1.96)$$

$k = 2 \rightarrow \Phi(0.04) \approx 0.52$ 。注意最后 power 只依赖 k （平移了几个 SE ）， SE 的具体数值 4 自己抵消掉了——这也印证了”power 只取决于信噪比”。

一句话： SE 就是一个数， Z 减这个数（或它的倍数），全程一个尺度，不需要任何额外的除法。

唯一要避免的自我打架：中途换了尺度

上面那套之所以有时候会绕晕，是因为同一个 Z 可以有两种定义，一旦中途换了、却没同步改”减什么”，就会打架：

- 如果你的 $Z = \bar{x}_0 - \bar{x}_1$ （均值差本身，和 SE 同尺度） $\rightarrow$ 减 $k \cdot SE$ ，拒绝域 $1.96 SE$ 。这就是上面的主记法。
- 如果你的 $Z = \frac{\bar{x}_0 - \bar{x}_1}{SE}$ （已经除过 SE 、无量纲） $\rightarrow$ 那它的中心平移量就是 k （纯数），减 k ，拒绝域 1.96。

两套都对，各自内部自治，power 都是 $\Phi(k - 1.96)$ 。出错只有一种情形：用了”除过 SE “的 Z ，却去减 $k \cdot SE$ （带 SE 的量）——一个已经把 SE 除掉的量，又减一个含 SE 的量，尺度就不一致了。反过来（用均值差的 Z ，却减纯数 k ）也一样。

一句话记牢： Z 减的东西，尺度必须和 Z 一样。 Z 是均值差就减 $k \cdot SE$ ； Z 已除 SE 就减 k 。一份推导里选定一个，别中途换。主记法（ SE 当测度值、 $Z - k \cdot SE$ ）最不容易错，因为它全程只有”原始测度值”一个尺度。

12. 给定 power 反解样本量 n

实践中真正的用法是反过来：定好想要的 power 和 α ，反解需要多大样本。通常假设 $n_0 = n_1 = n$ （50/50 等分流量）。

要求 $\text{power} = 1 - \beta$ ，需要平移量满足：

$$\frac{\delta}{SE} = z_{\alpha/2} + z_{\beta}$$

其中 $z_{\alpha/2} = 1.96$ （ $\alpha = 0.05$ 双边）， $z_{\beta} = \Phi^{-1}(\text{power})$ （ $\text{power} = 0.8 \Rightarrow 0.84$ ； $\text{power} = 0.9 \Rightarrow 1.28$ ）。

代入 $SE = \sqrt{\frac{\sigma^2}{n} + \frac{\sigma^2}{n}} = \sqrt{\frac{2\sigma^2}{n}}$ （等样本、等方差）：

$$\frac{\delta}{\sqrt{2\sigma^2/n}} = z_{\alpha/2} + z_{\beta} \implies \frac{\delta^2 n}{2\sigma^2} = (z_{\alpha/2} + z_{\beta})^2$$

$$n = \frac{2\sigma^2 (z_{\alpha/2} + z_{\beta})^2}{\delta^2} \quad (\text{每组})$$

读它（核心记忆）：

- $n \propto \sigma^2$ ：方差越大越要样本 $\rightarrow$ 降方差（CUPED、分层、协变量调整）= 省样本 = 提 power。
- $n \propto 1/\delta^2$ ：想检测的效应越小，样本量按平方涨—— δ 减半， n 要 4 倍。
- α 越小、power 要求越高 $\rightarrow z$ 越大 $\rightarrow n$ 越大。
- 常数： $\alpha = 0.05$ 时， $\text{power} = 0.8$ 下 $(1.96 + 0.84)^2 \approx 7.85$ ，故 $n \approx 16\sigma^2/\delta^2$ （每组）； $\text{power} = 0.9$ 下 $(1.96 + 1.28)^2 \approx 10.5$ ，故 $n \approx 21\sigma^2/\delta^2$ 。

13. 点击率（伯努利）场景的落地

metric 是点击/非点击时，每个用户是伯努利变量： $X_i \sim \text{Bernoulli}(p)$ ，其中 p 就是真实点击率（= 均值 μ ）。

伯努利的方差不是自由参数，由 p 决定：

$$\text{Var}(X_i) = p(1 - p)$$

所以把通用公式里的 $\mu \rightarrow p$ 、 $\sigma^2 \rightarrow p(1 - p)$ ：

$$SE = \sqrt{\frac{p_0(1 - p_0)}{n_0} + \frac{p_1(1 - p_1)}{n_1}}, \quad Z = \frac{\hat{p}_0 - \hat{p}_1}{SE}$$

样本量：

$$n = \frac{2p(1 - p)(z_{\alpha/2} + z_{\beta})^2}{\delta^2}$$

其中 δ 是想检测的点击率**绝对提升**（如从 10% 到 10.5%， $\delta = 0.005$ ）。

一个经典考点：算 SE 时用不用合并比例 (pooled)。 H_0 下 $p_0 = p_1$ ，检验时常常用 $\hat{p} = \frac{\text{总点击数}}{n_0 + n_1}$ 估共同的 p ， $SE = \sqrt{\hat{p}(1 - \hat{p})(1/n_0 + 1/n_1)}$ 。而推 power / 算样本量时用各自的 p 。两个场合用哪个，是面试爱追的细节。

14. 频率派 vs 贝叶斯：不是深浅，是范式

贝叶斯不是频率派的”进阶版”，是平行的另一条路：

- 频率派（本笔记全程）：条件永远是”给定 H_0/H_1 为真”，算统计量的概率。不给假设赋概率。回答：“ H_0 真时，我看到这么极端数据的概率” (p-value)。
- 贝叶斯：直接算 $P(H_1 \text{ 为真} | \text{数据})$ 、 $P(p_1 > p_0 | \text{数据})$ ——给假设本身赋后验概率，需要先验。回答：“看到数据后， H_1 为真的概率”。

第 5、6 节里”想给’有差异’算概率、想让 H_0 是 $\neq$ 想写 $P(H_0)$ “的那个直觉——在频率派里非法，在贝叶斯里正是合法的核心。这不是谁对谁错，是两套范式。

工业 A/B 里两者都用：频率派是主流默认（多数实验平台 + sequential）；贝叶斯版（“ $P(\text{test 更好}) = 95\%$ ”）在部分平台用，好处是能直接说”有 95% 概率 test 更好”、且对 peeking 天然更友好。

15. 面试话术总结（把推导压成能讲的几句）

Power 是什么： > “Power 是有真实效应 δ 时，能正确拒绝 H_0 的概率 $= 1 - \beta$ 。给定 n 它是 $\Phi(\delta/SE - z_{\alpha/2})$ 。由四个量决定：效应量、样本量、方差、 α 。”

实战怎么用： > “上线前我反过来用它反解样本量 $n = 2\sigma^2(z_{\alpha/2} + z_\beta)^2/\delta^2$ ，定 power=0.8、 $\alpha=0.05$ 。关键是 n 反比于 δ^2 ——想检测的提升越小，样本量涨得越快；而降方差（CUPED）能直接省样本。这样避免样本不足导致真效应测不出来。”

解读负结果： > “实验不显著，要区分是真没效果，还是 power 不够没测出来。没 power 的实验，不显著 / 无效。”

p-hacking： > “单次 $\alpha = 0.05$ 只保证单次误拒率， m 次至少一次误拒 $= 1 - (1 - \alpha)^m$ ，测 20 个指标就有 64%。所以我预先注册主指标和样本量，多重比较用 Bonferroni/FDR，peeking 用 sequential testing。”

贝叶斯（加分）： > “还有 Bayesian A/B，区别是给假设赋后验、能直接说 $P(\text{更好})$ 、对 peeking 更友好。”

16. 这次推导训练到的东西

不是”记住了 power 公式”，而是重走了一条从第一性原理构造统计推断的路，可迁移：

1. 把’均值的方差’和’数据的方差’分清（差一个 n ）——一切标准误的地基。
 2. H_0 取等号是机制必需，不是约定：只有”一个点”才有确定分布。
 3. α 是条件概率（条件= H_0 真），不是 $P(H_0)$ ；参数固定、统计量随机。
 4. 频率派的概率是长期频率，属于”程序”，不属于”某一次结果”——这直接推出 p-hacking。
 5. power 是对称的另一半： Z 中心从 0 平移到 δ/SE ，落进固定拒绝域的概率。
 6. 尺度一致性：把 SE 当一个测度值， Z 减这个数（或它的倍数），全程一个尺度就不会错。 Z 减的东西尺度必须和 Z 一样——中途换尺度是最常见的自相矛盾来源。
 7. 反解 n ： $n \propto \sigma^2/\delta^2$ ，效应减半、样本 4 倍；降方差就是省样本。
-

一句话压缩：整套 A/B 检验，是”假设无差异（ H_0 取一个点）→ 由 CLT 得均值差近似正态、标准误 $\sqrt{\sigma^2/n}$ → 标准化成 Z → 在 H_0 世界定临界值 1.96（控制长期误拒率 α ）→ 在 H_1 世界看 Z 平移 δ/SE 后落进拒绝域的概率（power）→ 反解样本量”。每一步都是从”参数固定、样本随机 + 想控制两类错误”这一个出发点长出来的。