Attention 智能涌现推演

Part 1：从模型调试、权重投影到 Induction Head 的训练动力学

一份以讨论过程为主线的研究笔记

不仅记录结论，更重建每一步的提问、模型假设、错误纠正与推导转向。

核心路线
观察现象 → 抽象建模 → 数学计算 → 检验假设 → 重新建模.
两个案例：**MIT Weight-Space Programming** 说明如何用实验定位模型故障并做最小权重修改；**Induction Head** 说明为什么单看 CE 梯度不足以解释 Attention 的结构优势，需要进一步抽象模型并分析梯度流。

整理日期：2026-11-06 | 版本：Part 1 / 20 页扩展版

范围说明：本文依据当前对话中的实际讨论重建；提问以忠实意译为主，并非逐字访谈记录。论文结论与我们的直觉性猜想明确区分。

目录

1 研究问题从哪里开始：预测 Token 为什么会出现算法行为? 2

1.1 先厘清实验物理与理论证明的关系 . . . 2

1.2 重复序列是第一个可分析例子 . . . 2

2 插曲一：MIT Weight-Space Programming——把模型故障转换为几何优化 2

2.1 先问清楚输出和权重的关系 . . . 2

2.2 为什么 ΔW 不唯一？引入最小改动 . . . 3

2.3 从向量几何再推一遍，才真正闭合 . . . 3

2.4 一次重要的维度纠错：空间维数、坐标数与矩阵 Rank . . . 4

2.5 把数学投影放回 MIT 的模型修复实验 . . . 4

3 插曲二：对“平坦极小值与泛化”的一次必要纠错 5

4 回到 Induction Head：从简单 CE 梯度走到结构问题 6

4.1 最初试图直接推整个 Transformer 的梯度 . . . 6

4.2 把整层 BP 的依赖结构写清楚 . . . 7

4.3 关于 BOS、Sequence 和梯度稀疏性的长时间纠错 . . . 7

4.4 为什么最终不再把“CE 下降”当成关键证明? . . . 8

5 NeurIPS 2024：为什么必须先抽象建模，之后才谈证明? 8

5.1 自然数据假设：高阶 Markov 与任务内转换规律 . . . 8

5.2 论文的模型参数与标准 Transformer 对应在哪里? . . . 8

5.3 训练目标与梯度流：先说命题，不抢跑证明 . . . 9

5.4 第一阶段 FFN 的直观数学对象 . . . 9

6 两篇工作的交叉启示：研究的价值发生在哪里? 10

7 Part 2 交接点：保留哪些已知事实与未做计算? 10

8 扩展推演一：从问题意识到第一条可验证的数学链 11

9 扩展推演二：权重投影问题为何会自然成为约束优化 12

10 扩展推演三：正交几何、Frobenius 最小值与列空间 13

11 扩展推演四：逆向研究 Astra 的 Agent 实验循环 14

12 扩展推演五：Activation 统计、层选择与方向消融 15

13 扩展推演六：从 CE 到 G_2，并重新梳理索引 16

14 扩展推演七：看完两层 Attention 的 BP，我们为何转向归纳偏置? 17

15 扩展推演八：简化模型与原生 Transformer 不应混淆 18

主要资料入口 18

1 研究问题从哪里开始：预测 Token 为什么会出现算法行为?

最初的问题不是“Transformer 的 Attention 公式如何工作”，也不是“LLM 如何写代码”，而是：**一个通过 Cross-Entropy 做 Next Token Prediction 的系统，为什么能够逐渐获得复制、匹配、推理、Coding 和 Debugging 等计算能力?** 我们希望用数学模型解释这种机制的形成，而不是仅靠神经元探测画出漂亮的 Circuit 图。

1.1 先厘清实验物理与理论证明的关系

围绕 Mechanistic Interpretability，我们讨论过 Neuron Probing、Sparse Autoencoder（SAE）、Activation Patching、Circuit Tracing、Training Dynamics。前四者更接近“观察—假设—干预—复现”的实验科学；后者试图解释**机制如何在训练中形成**。区分“模型里有什么”与“梯度下降为何学出它”很关键。

> **方法论节点 A：**使用梯度、矩阵和优化公式，不代表已经解释智能涌现。真正有价值的理论问题是：给定数据分布及架构，$\theta(t)$ 为什么沿训练动力学进入某种实现算法的参数区域?

1.2 重复序列是第一个可分析例子

考虑 `A B C D A -> B`。简单的 Induction Rule 是：在前文找到同样的 A，读取它之后的 Token B。一般化时，匹配的可以是多个历史 Token 的组合，而不是一个固定 $A \to B$ 词典。我们曾反复澄清：**记忆与可泛化模式并非非此即彼**。模型既能吸收固定的条件统计，也能从当前 Context 中进行匹配；泛化发生在已知词表构成的未见组合上，不是凭空生成词表之外的独立 Token。

这与 Rule 110、元胞自动机的类比只是一种思想启发：简单局部规则经过反复组合可以表达复杂计算；反过来神经网络或许能从大量近优求解轨迹中学习可复用的步骤。但**它是启发性理解，并非我们已经证明的智能理论**。

2 插曲一：MIT Weight-Space Programming——把模型故障转换为几何优化

这一部分并非偏离主题：它让我们亲手经历了一次“观测 → 选方向 → 干预 → 验证”的完整研究过程，之后再回到 Attention 的训练动力学。

2.1 先问清楚输出和权重的关系

设某线性层的输入 $x \in \mathbb{R}^{d_{\text{in}}}$，权重 $W \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$，输出为

$$h = Wx, \qquad h \in \mathbb{R}^{d_{\text{out}}}. \tag{1}$$

我们希望消除输出在某个非零方向 u 上的分量。直觉上的要求是 $u^\top h' = 0$。这里的目标不是让所有 h' 都成为零向量，而是把它们限制在 $u^\perp$ 内。

提问 / 直觉： “从 h' 出发还是从 W' 出发？两个方向都可以吧?”

核对 / 结论： 可以。输出法写 $h' = h + \Delta h$，权重法写 $W' = W + \Delta W$。我们先沿权重法走，因为目标是对任意输入都成立。

$$u^\top (W + \Delta W)x = 0, \qquad \forall x \in \mathbb{R}^{d_{\text{in}}}. \tag{2}$$

若某行向量与任意 x 内积均为零，该行向量只能是零向量，于是

$$u^\top (W + \Delta W) = 0_{1\times d_{\text{in}}}. \tag{3}$$

这是我们讨论中专门停下来补全的逻辑，不应跳过“对任意 x”这一步。

2.2 为什么 ΔW 不唯一？引入最小改动

提问 / 直觉： “这不好直接解 ΔW，是欠定的?”

核对 / 结论： 正确。$u^\top W' = 0$ 仅规定每一列位于一个超平面内，W' 有无穷多种。于是选取最接近原权重的可行矩阵：

$$\min_{\Delta W} \frac{1}{2}\|\Delta W\|_F^2 \quad \text{s.t.} \quad u^\top (W + \Delta W) = 0. \tag{4}$$

Frobenius 范数的平方就是所有元素的平方和：$\|\Delta W\|_F^2 = \sum_{ij}(\Delta W_{ij})^2$。这里仅仅在参数空间中定义最小改动；不等于已经保证下游能力、一般化或原训练 Loss 都不变。

我们把拉格朗日函数一步步写成

$$\mathcal{J}(\Delta W, \lambda) = \frac{1}{2}\|\Delta W\|_F^2 + \lambda^\top u^\top (W + \Delta W), \tag{5}$$

$$\frac{\partial \mathcal{J}}{\partial \Delta W} = \Delta W + u\lambda^\top = 0, \tag{6}$$

$$\Delta W = -u\lambda^\top, \tag{7}$$

$$u^\top W - (u^\top u)\lambda^\top = 0, \tag{8}$$

$$\lambda^\top = \frac{u^\top W}{u^\top u}, \tag{9}$$

$$\Delta W = -\frac{uu^\top W}{u^\top u}, \tag{10}$$

$$W' = \left(I - \frac{uu^\top}{u^\top u}\right) W. \tag{11}$$

这个推导由讨论中分多轮完成：要求“只带进去一步”、再“求 λ”、再“代回 ΔW”，而不是一次性抛出答案。

2.3 从向量几何再推一遍，才真正闭合

我们随后转换路线，不看拉格朗日，而看单个输出向量：

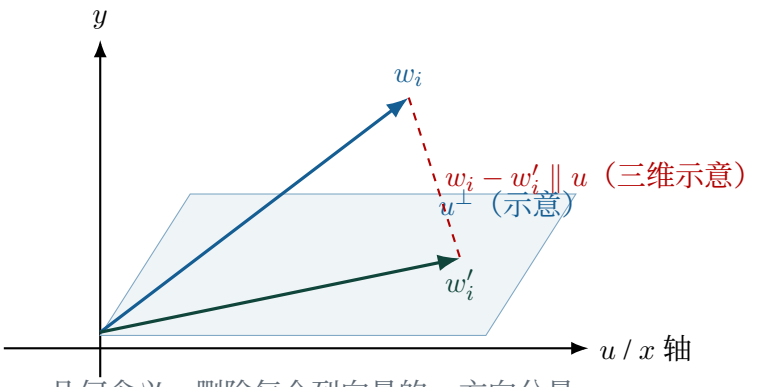
$$h' = h - \text{proj}_u(h) = h - \frac{u^\top h}{u^\top u}u. \tag{12}$$

代入 $h = Wx$ 和 $h' = W'x$，若要求对任意 x 成立，则得到与式 (11) 完全相同的 W'。

当时最关键的一次顿悟： W 的每列不是某种神秘参数，而是输出空间里的一个向量。令 $W = [w_1, \ldots, w_{d_{\text{in}}}]$，有 $h = \sum_i x_i w_i$。消除输出的 u 分量，等价于把每一列都投到 $u^\perp$：

$$w_i' = w_i - \frac{u^\top w_i}{u^\top u} u. \tag{13}$$

每个 w_i' 都是超平面内距离 w_i 最近的点，因此 $\sum_i \|w_i' - w_i\|_2^2$ 最小——这恰好就是 $\|W' - W\|_F^2$。**欧氏最短距离与 Frobenius 最优化在这里统一。**



几何含义：删除每个列向量的 u 方向分量

图为概念示意，非严格三维坐标投影。

2.4 一次重要的维度纠错：空间维数、坐标数与矩阵 Rank

令 $d_{\text{out}} = 3, d_{\text{in}} = 4$，$u = (1, 0, 0)^\top$。则 $u^\perp = \{(0, y, z)^\top : y, z \in \mathbb{R}\}$ 是**三维空间里的二维子空间**：每个向量仍有 3 个坐标，但只有 2 个自由度。满足约束的 W' 是 3×4 矩阵，第一行全零，整个矩阵有 8 个自由参数，$\text{rank}(W') \le 2$，不是一定等于 2。与 yz 平面平行、但 $x \neq 0$ 的仿射平面不属于 $u^\perp$。

这里也区分了另一个常见误解：对一个固定输入得到的唯一 h'，无法唯一决定整个 W'；但如果要求投影关系对任意 x 成立，便唯一确定线性映射 W'。

2.5 把数学投影放回 MIT 的模型修复实验

MIT 的 Weight-Space Programming 案例中，研究 Agent Astra 对 Qwen 的数学题输出进行检查，发现大量推理轨迹陷入重复并触及 Token 上限。我们先问：**它是不是仅用自然语言读出“Reasoning Loop”?** 回答是：对文本异常的初步判断确实使用语义理解；但定位层与方向，必须借助数值实验。

研究流程（按原始 p50c 实验日志重建）：

1. Astra 观察 Qwen 的生成结果，包括正确结束与重复截断的样本。
2. Astra 用相同数学题构造**正常推进**和**重复循环**的 Assistant 推理片段，通过 Teacher Forcing 获取两种路径的中间 Activation。这里并不是“两个不同 *Prompt* 指令要求模型分别正常/循环回答”。
3. 对齐可比较的 Token 区间，分别计算 Activation 平均值及差异；同一题的对照能减少题目内容的干扰。我们提出过按循环周期做 modulo 对齐的改进想法；Astra 早期实现采用了末尾约 40 Token 的区间均值，而不是 modulo 对齐。

4. 筛选候选层、方向与神经元，做消融（Ablation）、方向投影修改以及原模型/修改模型的配对评估，逐步确定更有效的干预组合。

以第 l 层的 MLP 为例（SwiGLU 的展开式略）：

$$m^{(l)} = W_{\text{down}}^{(l)} a^{(l)} = \sum_i a_i^{(l)} w_i^{(l)}. \tag{14}$$

$w_i^{(l)}$ 是固定权重矩阵的一列，$a_i^{(l)}$ 是随上下文变化的激活系数。我们首先想到比较 $\Delta a_i = a_i^{\text{loop}} - a_i^{\text{normal}}$，再得到差输出 $\Delta m = W_{\text{down}} \Delta a$，把它的归一化方向作为候选 u。Astra 的实现与此接近，但最初候选 u 主要来自 **Residual Hidden State 的正常/循环差异**，并结合各 MLP 神经元的“沿该方向写入贡献”做实验筛选。

单神经元的候选贡献可以写为

$$\Delta c_i = \Delta a_i \, (u^\top w_i). \tag{15}$$

提问 / 直觉： “既然已找到 u，为什么还要找哪个神经元贡献大？最终不还是要改 W?”

核对 / 结论： 如果对整层 W 直接做完整方向投影，这一分析**不是必要条件**；它主要用于局部消融的因果探测，以及当最终只改部分列时筛选修改范围。两种干预的结果方向一致，但不能把局部消融等同为完整方向修复。

公开日志显示：对第 19 层的单个 MLP 神经元进行消融，只得到较弱的改善；后续测试方向删除、不同强度与第 15/19 层组合，结果更明显。最终版本修改第 15 与 19 层各 64 个 MLP 输出列。该最终修改是带强度系数和列掩码的定向干预，**并不简单等于上述“整矩阵、最小 Frobenius 距离”的正交投影**。此处我们推导的投影公式是理解其基本几何操作的标准形式，不应混同实验最终实现。

> **方法论节点 B：** 数学上，投影与最小修改是经典线性代数和约束优化；研究中真正有实践价值的环节，是如何从失败文本定义候选机制、获取对照激活、进行可证伪的干预实验。Astra 是 LLM 决策 + Harness 工具执行 + 反馈再决策的 Agent Loop，并非凭空直接“看懂”8 亿个权重。

3 插曲二：对“平坦极小值与泛化”的一次必要纠错

讨论中我们使用线性回归类比：离散数据用连续函数拟合；与学到的规律接近的新点可能有较好表现，纯噪声输入则可能失败。接着出现一个重要概念混淆：

- 参数空间的 Flat Minimum：$L(\theta)$ 在 θ^* 附近对参数扰动较不敏感。
- 输入空间的局部平滑：$f_\theta(x)$ 对 x 的小变化响应平稳。

这两者不是同一个数学对象。**参数空间平坦性本身不保证输入空间对任意新样本都平滑或预测正确**。对样本分布的适配、模型结构与输入分布仍然重要。这里的纠错改变了我们后续表述的严谨性，但不需要为了展示严谨性而引入无关反例。

4 回到 Induction Head：从简单 CE 梯度走到结构问题

4.1 最初试图直接推整个 Transformer 的梯度

我们以 `A B C D A -> B` 作为例子。先不加 FFN、Residual、LayerNorm，两层单头 Attention 的 Toy Model 为

$$H_0 = X, \tag{16}$$

$$Q_l = H_{l-1}W_Q^{(l)}, \quad K_l = H_{l-1}W_K^{(l)}, \quad V_l = H_{l-1}W_V^{(l)}, \tag{17}$$

$$P_l = \text{softmax}_{\text{row}}\left(Q_l K_l^\top / \sqrt{d_k} + M\right), \tag{18}$$

$$H_l = P_l V_l W_O^{(l)}, \qquad l = 1, 2. \tag{19}$$

最终 $z = W_U^\top h_2 + b$，其中 h_2 是最后预测位置的 Hidden State，z 是 Logits，$p = \text{softmax}(z)$ 是 Vocabulary 概率。W_O 是 Attention 输出维度映射回 d_{model} 的投影，W_U 才是 Vocabulary 投影——这两个权重曾专门被区分。

若正确 Token 是 B：

$$L = -\log p_B = -z_B + \log \sum_j e^{z_j}, \tag{20}$$

$$\frac{\partial L}{\partial z_i} = p_i - \mathbf{1}_{i=B}, \tag{21}$$

$$\frac{\partial L}{\partial W_U} = h_2 (p - y)^\top, \tag{22}$$

$$\frac{\partial L}{\partial h_2} = W_U (p - y). \tag{23}$$

提问 / 直觉： “正确 *Token* 的 $p_B - 1 < 0$，其他 $p_i > 0$；那么 *B* 对应的 W_U 一列都变大吗?”

核对 / 结论： 不一定。该列沿 $+h_2$ 方向移动，但每个元素增加或减少取决于 h_2 对应分量的正负。同理 $\partial L / \partial h_2$ 不能仅凭符号判断，因为 W_U 有正有负且各 Token 贡献叠加。这个阶段我们得到了确定的梯度表达式，却没有得到直观的 Circuit 形成解释。

4.2 把整层 BP 的依赖结构写清楚

令 $G_l = \partial L/\partial H_l$，$T_l = P_l V_l$。对任一层 l：

$$G_{T_l} = G_l (W_O^{(l)})^\top, \qquad \frac{\partial L}{\partial W_O^{(l)}} = T_l^\top G_l, \tag{24}$$

$$G_{P_l} = G_{T_l} V_l^\top, \qquad G_{V_l} = P_l^\top G_{T_l}, \tag{25}$$

$$(G_{S_l})_{ij} = (P_l)_{ij} \left[(G_{P_l})_{ij} - \sum_k (P_l)_{ik} (G_{P_l})_{ik} \right], \tag{26}$$

$$G_{Q_l} = G_{S_l} K_l / \sqrt{d_k}, \qquad G_{K_l} = G_{S_l}^\top Q_l / \sqrt{d_k}, \tag{27}$$

$$\frac{\partial L}{\partial W_Q^{(l)}} = H_{l-1}^\top G_{Q_l}, \qquad \frac{\partial L}{\partial W_K^{(l)}} = H_{l-1}^\top G_{K_l}, \tag{28}$$

$$\frac{\partial L}{\partial W_V^{(l)}} = H_{l-1}^\top G_{V_l}. \tag{29}$$

第一层接收第二层沿 Q/K/V 三条路径的梯度和：

$$G_1 = G_{Q_2} (W_Q^{(2)})^\top + G_{K_2} (W_K^{(2)})^\top + G_{V_2} (W_V^{(2)})^\top. \tag{30}$$

这是标准链式求导，不是论文的主要理论创新。我们发现：**能把梯度写出来，与能证明 SGD 学出重复匹配算法，是两回事**。

4.3 关于 BOS、Sequence 和梯度稀疏性的长时间纠错

为避免索引混乱，我们最后统一一个具体训练约定：给序列 `BOS A B C D A B`，它包含 7 个输入位置。设 Batch Size 为 B，每层输出 $H_2 \in \mathbb{R}^{B\times 7\times d_{\text{model}}}$，Logits $Z \in \mathbb{R}^{B\times 7\times V}$。在 0-based 索引下：

- $Z[:, 0, :]$ 对应 BOS 输入位置，预测 A；
- $Z[:, 1, :]$ 预测 B；
- $Z[:, 5, :]$ 预测输入序列末尾的那个 B；
- $Z[:, 6, :]$ 若用于预测，则指向序列外的下一个 Token。

在**只用第 6 个实际 Token B 的预测位置**计算单目标 CE 的 Toy Model 中，若 Loss 依赖 $Z[:, 5, :]$，那么对最终 H_2 的直接梯度只有索引 5 的行可能非零：

$$G_2[:, i, :] = 0 \quad (i \neq 5), \qquad G_2[:, 5, :] \propto (W_U(p - y))^\top. \tag{31}$$

这仅仅反映**当前定义的 Loss 选择了一个预测位置**，不是所有 Causal LM 训练的普遍性质。标准全序列 CE 对多个目标位置计算损失，因此对应多行可能非零。即使最终层仅目标行接收直接梯度，较早层的历史位置仍经 K/V Attention 路径收到反向传播。

> **纠错节点 C：**我们曾混用了“包含 BOS 的输入长度”“目标 Token 编号”“Python 0-based 行索引”和“推理时只给前缀”几种约定，导致不必要的反复纠正。数学上必须先写清 $Z[b, i, :]$ 对应的预测目标 x_{i+1}，再谈矩阵形状和 G_2 的零行。

4.4 为什么最终不再把“CE 下降”当成关键证明?

我们曾尝试沿 $\nabla_\theta L$ 说明下次 Forward 会提高 $P(B \mid A, B, C, D, A)$。对于单一样本，只要沿完整梯度的负方向、梯度非零且步长足够小，CE 的确会局部下降。但 **DNN、RNN、LSTM、Transformer 都可以这样下降**。这不能解释 Attention 为什么尤其擅长在 Context 中找 `A...A` 的历史后继。

由此推导路线发生关键转向:

> **旧问题：**经过 BP，为什么正确 Token 概率会上升?
>
> ⇓
>
> **新问题：** Attention 的参数化和跨位置存取结构为什么让重复匹配更容易表示和学习?

RNN/LSTM 通过固定维状态递归压缩历史，而标准 Causal Attention 可以直接使用此前各位置的 K/V 表示。对于关联检索，这提供清晰的结构优势；但要区分**在受限设定下的表达/资源复杂度证明**与**一般情况下训练效率的统一证明**。我们在讨论中决定只关注 Induction Head，不把话题扩散到“所有智能能力”上。

5 NeurIPS 2024：为什么必须先抽象建模，之后才谈证明?

讨论对象:*Unveiling Induction Heads: Provable Training Dynamics and Feature Learning in Transformers*（NeurIPS 2024）。它研究广义 Induction Head 的训练形成机制。我们对论文最重要的判断是：**它不是把一般工业 Transformer 的所有权重梯度硬推到底；而是设计一个可分析的简化模型，再证明在明确条件下训练会学出特定机制**。

5.1 自然数据假设：高阶 Markov 与任务内转换规律

设 $x_1, \ldots, x_L, x_{L+1}$ 来自一类 n-gram Markov 数据生成过程。形式上，下一 Token 的条件分布依赖有限历史:

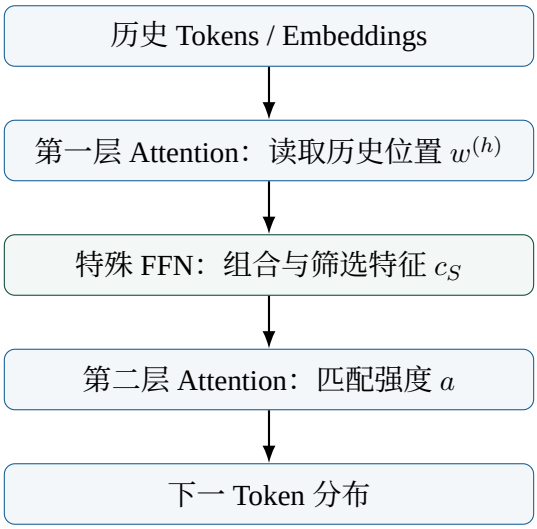
$$P(x_{t+1} \mid x_{1:t}) = P(x_{t+1} \mid x_{t-n+1:t}). \tag{32}$$

这就是经典 NLP n-gram / Markov 近似的数学形式。文章允许不同序列拥有不同的转换核，从而强调：模型不能只记住全局固定 $A \to B$，还需要从当前序列的统计模式中进行检索和估计。

5.2 论文的模型参数与标准 Transformer 对应在哪里?

论文参数	直观计算作用	对应模块(但不是一一等价的原生矩阵)
$w^{(h)}$	控制第一层读取哪些历史相对位置	第一层 Attention 的简化位置选择参数
c_S	给历史特征组合分配权重	两层 Attention 之间的特殊 FFN / 特征映射
a	放大第二层对历史匹配特征的偏好	第二层 Attention 的匹配强度参数

我们在一开始的 Toy Model 里直接写 $H_1 \to \text{Attn}_2$，**省略了 FFN**。而论文模型采用了第一层 Attention、特殊 FFN、第二层 Attention 的可分析结构。在真实工业 Transformer 中，一层通常包括 Attention、Residual、Normalization、FFN；FFN 先升至 d_{ff}，经非线性变换后投回 d_{model}。它不仅是“去噪”，还承担特征加工、组合与表达能力扩展。



5.3 训练目标与梯度流：先说命题，不抢跑证明

用 $\theta = (\{w^{(h)}\}, \{c_S\}, a)$ 表示简化参数，考虑总体 CE 类目标

$$\mathcal{L}(\theta) = -\mathbb{E}_{\pi,x} \log f_\theta(x_{L+1} \mid x_{1:L}) \tag{33}$$

（原论文有平滑与具体参数化细节，本文为读者准备使用的纲要式表达）。连续时间梯度流为

$$\frac{d\theta(t)}{dt} = -\nabla_\theta \mathcal{L}(\theta(t)). \tag{34}$$

论文把动力学分析置于**特定简化结构、分阶段参数更新、初始化和数据假设**之下，再说明哪些特征被突出、哪些历史位置被读取、第二层如何匹配，从而趋近广义 Induction Head。这里的“广义”可直观理解为：不只是 `A B ... A -> B`，而是能匹配多个历史 Token/特征的上下文模式，对后继 Token 做加权统计。

必须准确说出两个层次：

1. **存在/表达：**特定参数配置能实现此类历史匹配预测；
2. **训练/收敛：**在论文指定的梯度流训练机制下，参数轨迹确实会趋向相关结构。

第一层不自动推出第二层。我们的“先从一般 Attention 梯度硬推，发现不透明，再回头找合适抽象”的经历，正好解释了论文建模这一步为何关键。

5.4 第一阶段 FFN 的直观数学对象

论文里的 FFN 不只是普通两层全连接。可以将其特征核概括成：

$$\langle \phi(v), \phi(v') \rangle = \sum_{S:\,|S| \le D} c_S^2 \prod_{h \in S} \langle v^{(h)}, v'^{(h)} \rangle. \tag{35}$$

S 表示使用哪些历史特征组合，c_S 控制对应组合的权重。我们暂时**只理解变量意义，不继续展开论文的梯度证明**，因为讨论在此处暂停，后续 Part 2 由读者自己选择要推的具体梯度步骤。

6 两篇工作的交叉启示：研究的价值发生在哪里?

维度	MIT Weight-Space Programming	NeurIPS 2024 Induction Head
研究对象	已训练模型的特定故障（推理循环）	重复匹配机制如何在训练中形成
最初数据	失败/成功 Rollout、Teacher-forced 对照片段	具有 Markov 统计结构的序列分布
基本数学	Activation 差向量、方向投影、约束最小二乘	可分析的 Transformer 参数化、总体 CE、梯度流
关键实验/证明	局部消融、方向编辑、重复评测; 结果具有任务依赖性	在定理假设下证明特征选择/复制/匹配机制的训练形成
我们自己的收获	几何上的正交投影 = 矩阵 Frobenius 最小改动	单看 BP 不够；首先要抽象出可证明的核心机制

贯穿整个讨论的结论：难点未必是公式求导，而是选对研究对象与建模粒度。
MIT 案例说明: 如何将一个“循环推理”的模糊现象变成可测量、可干预的几何问题。Induction Head 论文说明：如何将一个高维耦合优化问题抽象成可以分析训练动力学的模型。
我们尚未推导完成的部分：论文各阶段的完整梯度动力学、收敛条件、误差界，以及从该 Toy Model 推广到普通 Transformer 的限制。

7 Part 2 交接点：保留哪些已知事实与未做计算?

1. 已完成标准 CE/Softmax 梯度、输出投影梯度以及两层 Attention 的一般 BP 结构，暂不需要重复做机械求导。
2. 已识别证明目标不是“当前样本 CE 变小”，而是“为什么某种架构和数据分布使特定 Circuit 能在训练中形成”。
3. 已认识到论文参数 $w^{(h)}, c_S, a$ 是经过专门设计的理论模型，不是一般 W_Q, W_K, W_V, W_O 的简单改名。
4. 下一步可从论文第一阶段的假设和梯度流开始，但只在明确要求时计算相应梯度与界，不抢先推后续结果。

8 扩展推演一：从问题意识到第一条可验证的数学链

对话回放 · 研究对象究竟是什么?

提问 / 直觉： “我们讨论 LLM Coding 和 Debugging，最后想解释的并不是如何写代码，而是智能怎么在训练中涌现。”

核对 / 结论： 这一步将问题从工程表现推进到训练机制。现实里，程序 Debug 的步骤包括定位错误、推断程序状态、构造测试、检查反馈；但这些都只是可观察行为。要从数学上解释其形成，必须把对象换成：训练分布、模型参数、损失函数、梯度轨迹，以及训练后实现的内部计算。

提问 / 直觉： “Neuron Probing、SAE、Activation Patching、Circuit Tracing 像实验物理，更多是观察和干预，数学推导不多?”

核对 / 结论： 这个区分是我们的第一条方法论结论。观察到 Feature 不等于解释 Feature 如何形成；对 Feature 干预证明其影响某个输出，也不等于证明 SGD 为什么到达该 Feature。可解释性研究可以发现机制，却不自动给出机制的学习动力学。

> **当时建立的四层问题：**（1）某种规律是否存在于数据?（2）某种网络能否表示这条规律?（3）优化是否倾向于找到该表示?（4）找到后是否能推广到未见样本? 这四层不能混为一个命题。

我们以 `A B C D A -> B` 做实验思想模型。最初认为这“不过是条件频率统计”：大量重复模式出现，CE 的负梯度强化正确 Token，模型渐渐学习某种映射。这一步直觉合理，但随即发现不同模型都可以把当前样本的 CE 降低，所以这还没有解释 Attention 的优势。

提问 / 直觉： “如果大量近优求解过程反复包含高效规则，LLM 会不会学习到这种 repeated pattern，最后组合成更复杂的推理?”

核对 / 结论： 作为探索性的解释框架，可以先接受；它把智能理解为可复用计算模式的学习与组合。这里没有声称 Rule 110 直接证明了 LLM 学习能力。Rule 110 只是帮助我们区分两件事情：某个计算系统**能表示复杂过程**，以及学习系统**为何能获得相应机制**。

本页阶段性产物： 我们需要的不是“让 Softmax 的正确类别增大”的证明，而是“一个具有跨位置索引机制的网络，为什么形成一种可复用的上下文匹配算法”的证明。

9 扩展推演二：权重投影问题为何会自然成为约束优化

对话回放 · 从 $h = Wx$ 到欠定矩阵方程

提问 / 直觉： “对于某一层的 Activation Stream，希望去掉一个方向 u。目标应该是 $u^\top h' = 0$ 吧?”

核对 / 结论： 是。取 $u \neq 0$ 且 $h \in \mathbb{R}^{d_{\text{out}}}$, 要求修改后的向量落在 $u^\perp$。下一步不是直接写最终投影公式, 而是自己选择变量: 修改 h, 还是修改 W? 因为真实模型要永久改权重, 我们先选择 $W' = W + \Delta W$。

$$h = Wx, \quad h' = W'x,$$
$$u^\top h' = u^\top (W + \Delta W)x = 0 \quad (\forall x).$$

提问 / 直觉： “只要对任意 x 内积都为零，那么那个 $1 \times d_{\text{in}}$ 行向量本身只能是零向量。这一步你要写出来。”

核对 / 结论： 因而 $u^\top (W + \Delta W) = 0$。把 W 按列展开, 条件变成 d_{in} 个独立的约束 $u^\top (w_j + \Delta w_j) = 0$。对每一列来说，它在一个 $d_{\text{out}} - 1$ 维子空间中有无限多种解。

提问 / 直觉： “这样不容易直接解 ΔW。既然解无限多，增加一个最小改变的目标?”

核对 / 结论： 于是出现优化问题:

$$\min_{\Delta W} \frac{1}{2} \sum_{j=1}^{d_{\text{in}}} \|\Delta w_j\|_2^2 \quad \text{s.t.} \quad u^\top (w_j + \Delta w_j) = 0 \quad \forall j.$$

在此处选择 Frobenius 范数，并非 AI 问题特有的技巧，而是把“尽量少改原参数”量化为各元素的平方距离。

用拉格朗日法的路线： 对矩阵约束引入 $\lambda \in \mathbb{R}^{d_{\text{in}}}$，得到

$$\mathcal{J} = \tfrac{1}{2} \|\Delta W\|_F^2 + \lambda^\top u^\top (W + \Delta W).$$

我们当时明确要求每次只计算一步：先求 $\partial \mathcal{J} / \partial \Delta W$，再代约束求 λ，最后再得 ΔW。整个过程的重点不是计算难，而是知道为何要这样设优化目标。

10 扩展推演三：正交几何、Frobenius 最小值与列空间

对话回放 · 从数形结合突然看懂了矩阵最优解

提问 / 直觉： “$uu^\top$ 是外积，像一个线性神经层？可是我们的目标是让 u 方向的输出为零。”

核对 / 结论： 对。$uu^\top$ 在 u 单位化时抽取 u 分量；目标操作是从原向量减去这个分量。先不限制 u 单位化，可写为

$$h' = h - \frac{u^\top h}{u^\top u} u.$$

再依次代入 $h = Wx$、$h' = W'x$，在对所有 x 成立的前提下，得到

$$W' = \left(I - \frac{uu^\top}{u^\top u} \right) W.$$

提问 / 直觉： “假设 $d_{\text{out}} = 3, d_{\text{in}} = 4, u = (1, 0, 0)$。和 u 垂直的不就是 yz 平面？里面有无数个列向量，因此有无数个 W'。”

核对 / 结论： 对；但要修正当时一处形象化误解：并不是无数个平行于 yz 的平面。正交补只有穿过原点的 $x = 0$ 平面。其他平移平面上的点与 u 内积不是零。每个列向量的坐标数是 3，而正交补的空间维数是 2；3×4 的可行矩阵有 8 个自由度、Rank 不超过 2，但不保证 Rank 恰为 2。

提问 / 直觉： “消除 h 在 u 上的分量以后，h' 在平面上的位置已经确定；我想从几何上理解为何 W' 也恰好是最小改变的那个。”

核对 / 结论： 这里需区分单一输入与所有输入。仅一个 (x, h') 配对不确定整个线性算子；若每个输入都要满足相同的投影映射，四个基方向的输出自然分别固定：每个列向量 w_j 被送到 $w'_j = \text{proj}_{u^\perp}(w_j)$。

关键闭合： 某列 w_j 到 $u^\perp$ 的最短欧氏距离沿法向量 u；所以所有列分别取最近点，得到 $\sum_j \|w'_j - w_j\|^2$ 最小。这正是 Frobenius 距离平方。**最小距离几何与矩阵最优化不是两套答案，而是同一操作的两种语言。**

这个节点之所以值得在笔记里放大，是因为我们不是从答案倒推，而是先在三维空间看懂单个向量，才发现整个矩阵问题自然分解成独立的列向量问题。

11 扩展推演四：逆向研究 Astra 的 Agent 实验循环

对话回放·“它是不是只是会做普通 Model Debug?”

提问 / 直觉： “Astra 先观察数学失败样本，看到 Token 用尽。可是怎么判断 Reasoning Loop？是看 Chain of Thought，用自己的语义能力判断重复?”

核对 / 结论： 基本如此。输出文本的重复是可观察现象；接着必须通过数值和干预实验判断它对应什么内部机制。我们把“文本语义诊断”与“Activation/权重定位”明确分开。

提问 / 直觉： “最好同一道题, 一个成功、一个失败, 做对照。类似 RL 里相同 Prompt 的不同 Rollout。”

核对 / 结论： 这是一个合理的设计。核对原始日志后，发现 Astra 的具体实施更像可控对照：相同数学问题，直接写出两段不同 Assistant 文本，一段正常、一段重复，使用 Teacher Forcing 比较模型在这些文本前缀下的内部激活。

固定问题	Rafael 周一 10h，周二 8h，剩余 20h，时薪 $20，问总工资。
正常文本	$10+8=18$，$18+20=38$，$38\times 20=760$，随后完成检查。
循环文本	$10+8=18$，反复追问“20 小时是总时间吗？不是，是剩余时间”，不推进到结束。

提问 / 直觉： “是不是两个 Prompt，一个要求正常推理，另一个要求死循环?”

核对 / 结论： 不是。**Prompt 相同，给定的 Assistant continuation 不同。** Teacher Forcing 强制使用指定的 Token 作为后续输入，但模型自己每一步仍输出预测概率和中间 Activation；无需预测结果与指定 Token 相同。

提问 / 直觉： “那么 Harness 把 Qwen 的 Forward 结果返回 Astra，Astra 再返回 Python/结构化工具调用，Harness 执行之后继续反馈?”

核对 / 结论： 是。原日志每轮都有收到的工具结果和 Astra 的代码/forward 请求。可以把它准确归类为 LLM-driven Research Agent。亮点在实验任务的自主编排，而不是全新的执行框架。

实证边界： 诊断出文本循环，与证实某个 MLP 方向会造成循环，是两个不同层次的证据；最终结果依赖独立实验验证。

12 扩展推演五：Activation 统计、层选择与方向消融

对话回放・我们与 Astra 的实验思路究竟差在哪里?

提问 / 直觉： “假设在第 j 层对每个生成 Token 记录 $h_{i,j}^{\text{loop}}$ 与 $h_{i,j}^{\text{normal}}$，求均值差向量，先看哪个 Layer 的差异更大。”

核对 / 结论： 我们先定义可比较的上下文区间 $I_{\text{loop}}, I_{\text{normal}}$，令

$$\delta_j = \frac{1}{|I_{\text{loop}}|} \sum_{i \in I_{\text{loop}}} h_{i,j}^{\text{loop}} - \frac{1}{|I_{\text{normal}}|} \sum_{i \in I_{\text{normal}}} h_{i,j}^{\text{normal}}.$$

最初尝试按 Token 下标配对会遇到两个序列长度和内容不同的问题。你提出对重复周期用 $i \bmod N$ 对齐的想法；Astra 的初期脚本更简单，取末尾约 40 个 Token 的平均激活并做差。

提问 / 直觉： “比较归一化向量的内积，其实就是 Cosine Similarity；如果分数 0.8、0.7、0.02，前两个自然有 Gap。”

核对 / 结论： 对，这属于合理的候选筛选启发式。但 Astra 并未严格按一个 Gap 阈值选择所有要修改的层；它做了候选评分，随后对不同层和组合进行干预，再看实际数学准确率和循环比例。

提问 / 直觉： “一层 MLP 的 W_{down} 列向量类似固定方向 w_i，激活系数 a_i 是 Scale，所以正常和循环之间应该关注 Δa_i。”

核对 / 结论： 这是自然且重要的分解:

$$m = W_{\text{down}} a = \sum_i a_i w_i, \qquad \Delta m = W_{\text{down}} \Delta a.$$

候选循环方向可来自同层的 Hidden State 或 MLP 输出之差，归一化后得到 u。若要追溯单个神经元沿 u 方向写入多少信号，可以计算 $\Delta a_i (u^\top w_i)$。这里的 w_i 不是必然正交的标准坐标轴，而是固定的输出方向集合。

提问 / 直觉： “已经有 u 了，为什么还要找贡献最大的神经元？直接改整个 W 不就行?”

核对 / 结论： 如果要实施整矩阵的方向投影，确实不需要预先找到单个神经元。贡献评分主要服务于**局部消融的因果检查**以及**只编辑少量输出列的方案**。Astra 的最终实施就属于选择部分列并调节干预强度，而不是把所有列强制投影到一个正交平面。

特别记录：“统计分数高”只提供相关性候选，“改权重后重复减少、准确率改善”才是干预证据。这个 distinction 是我们从 Debug 走到 Mechanistic Interpretability 的关键一步。

13 扩展推演六：从 CE 到 G_2，并重新梳理索引

对话回放 · 为什么我们花很多时间统一 BOS 和 Z 的位置?

一开始用 $A, B, C, D, A \to B$ 做单目标 CE：$L = -\log p_B$。我们先求得 $\partial L/\partial z = p - y$，再得到

$$\frac{\partial L}{\partial W_U} = h_2(p-y)^\top, \qquad \frac{\partial L}{\partial h_2} = W_U(p-y).$$

提问 / 直觉： “正确 Token B 的 $p_B - 1 < 0$，是不是 W_U 对应列直接上升?”

核对 / 结论： 必须看 h_2 分量的符号：B 那一列是沿 $+h_2$ 方向更新，不是每个元素都增大。同样，W_U 可正可负，所以仅看 $W_U(p-y)$ 也无法断言 h_2 每一维增减。这一步提醒我们：标准求导并没有自动出现可解释的匹配结构。

提问 / 直觉： “实际训练时六个 Token 不该有六行 Logits 吗？BOS 呢？第 0 行预测谁?”

核对 / 结论： 这段讨论最大的教训是：没有写清序列和监督索引，就容易出现看似正确、却彼此错位的公式。采用我们最终统一的**训练约定**：

$$\underbrace{[\text{BOS}, A, B, C, D, A, B]}_{S=7\text{ 个输入位置}}, \qquad H_2 \in \mathbb{R}^{B\times 7\times d_{\text{model}}}, \quad Z \in \mathbb{R}^{B\times 7\times V}.$$

零基索引时，$Z[:,0,:]$ 用 BOS 的状态预测 A，$Z[:,5,:]$ 用第二个 A 对应输入位置预测末尾的 B。$Z[:,6,:]$ 对下一 Token 给出分布；若训练样本没有第八个 Token 标签，则这里不计损失。

提问 / 直觉： “如果仅用 $Z[:,5,:]$ 的 CE，那么 G_2 的其他行应该是零；这是行稀疏从哪里来?”

核对 / 结论： 是。对这一单目标 Loss，最终表示层的直接梯度仅在预测 B 的位置非零：

$$G_2[:,i,:] = \begin{cases} (W_U(p-y))^\top/B, & i = 5, \\ 0, & i \neq 5. \end{cases}$$

这里 p 与 y 按每个 Batch 样本计算。若换成所有已知 Token 的 Next-token CE，多个位置自然都会有梯度。并且即使 G_2 仅某一行非零，也不意味着前层的历史 K/V 通路没有梯度。

14 扩展推演七：看完两层 Attention 的 BP，我们为何转向归纳偏置?

对话回放·“新的 Forward 为什么更容易提高 B 的概率?”

我们把两层 Attention 化成最少的算子:

$$H_l = \underbrace{\mathrm{softmax}\left(\frac{H_{l-1}W_Q^{(l)}(H_{l-1}W_K^{(l)})^\top}{\sqrt{d_k}} + M\right)}_{P_l} H_{l-1}W_V^{(l)}W_O^{(l)}.$$

从 CE 反向传回 H_2 后，梯度沿 Attention 权重 P_2、Values V_2、以及 Scores 的 Q/K 路径回到第一层。对参数的梯度形式并不难写；困难是所有路径高度耦合，且参数元素正负都可能变化。

提问 / 直觉： “如果 SGD 优化 CE，下一轮 $P(B \mid ABCDA)$ 变大，这就是证明方向吗?”

核对 / 结论： 对单一样本, 小学习率负梯度可以局部降低它的 CE；但是**这并不专属于 Transformer**。任何可微模型都可以在自己的参数化内沿下降方向减小损失。这里我们意识到自己最初追逐了一个与架构无关的结论。

提问 / 直觉： “那 RNN/LSTM 也是 CE，为什么 Attention 的 Induction Head 更特殊?”

核对 / 结论： 于是转而考虑信息的可访问方式。固定维 RNN/LSTM Hidden State 不断压缩历史；标准 Causal Attention 在序列内可针对各历史位置单独生成 K/V 并进行动态寻址。对关联检索，前者容易遇到容量瓶颈，后者天然具备可按内容寻址的结构。

提问 / 直觉： “但如果只是固定的 $A \to B$，RNN/LSTM 也会学，不必夸大 Attention。”

核对 / 结论： 正确。必须区分**固定条件关联记忆**与**在当前上下文中寻找之前出现的 A，再读取其后继 Token**。Induction Head 是后者的特定 Circuit。这使位置关系、历史后继的可读取性都进入解释，而不仅仅是某个词表概率分量。

> **真正的研究转折：**“CE 会下降”是优化目标的一般性事实；“Attention 的参数化为什么容易形成内容寻址和后继复制”才是模型结构与训练动力学相交的问题。此后我们停止试图从一条梯度符号直接读出完整算法。

15 扩展推演八：简化模型与原生 Transformer 不应混淆

对话回放 · 为什么论文先建模再推导，而不是直接求完整 BP?

提问 / 直觉： “论文说 FFN 选有用特征、第一层 Attention 复制、第二层 Attention 匹配。这是不是只是定性解释?”

核对 / 结论： 论文的主张更强：在专门定义的简化架构、数据分布和阶段式训练下，研究对应参数的梯度流，并证明其收敛/主导机制。它并不宣称任意工业 Transformer 训练时都逐步严格经过这几个阶段。

提问 / 直觉： “FFN 在哪里？我们自己最初的 H_1 不是直接送到第二层了吗?”

核对 / 结论： 是，我们自己为了单纯看 Attention，最早省略了 FFN。论文恰好需要一个可分析的特征组合模块，用 c_S 表示不同历史特征集合的权重。在标准 Transformer Block 中，Attention 后经过带非线性的 FFN，再进入下一 Block；残差与归一化也存在，但不改变 $B \times S \times d_{\text{model}}$ 的主干维度。

对象	我们最终采用的理解
$w^{(h)}$	把第一层对历史相对位置的选择简化成少量可分析参数。
c_S	把多个历史特征的交互或组合压缩成可分析的特征权重。
a	控制第二层对历史匹配项偏好的强度。
$\theta(t)$	在特定损失与阶段式更新规则下，随连续梯度流变化的简化参数。

提问 / 直觉： “也就是说，作者先证明这个特殊构造可以对应 Induction Head，再证明梯度流能学出来?”

核对 / 结论： 方向正确，但更准确的顺序是：**定义问题和模型→ 确认机制可表达→ 分析学习动力学→ 得到定理条件下的结论**。直接对任意 W_Q, W_K, W_V, W_O 写出完整梯度，虽然形式上更一般，却无法自动指出哪些参数组合对应复制、匹配和最终统计。

Part 2 的明确起点： 先核对论文中 c_S 的特征核、位置选择参数与训练阶段的精确定义，再由读者选择某一段梯度计算。只有在明确给定条件后，才讨论收敛，而不把实验现象或作者直觉当作数学证明。

主要资料入口

- NeurIPS 2024，*Unveiling Induction Heads: Provable Training Dynamics and Feature Learning in Transformers*：https://arxiv.org/abs/2409.10559
- MIT Weight-Space Programming 研究页面：https://rikiyat.github.io/blog/weight-space-programming
- MIT / Astra 原始实验日志(exp8_math, p50c)：https://github.com/RikiyaT/lm_understand-logs/tree/main/exp8_math/runs/p50c

- Associative Recall 的 RNN/Transformer 理论比较：*RNNs Are Not Transformers (Yet)*，https://arxiv.org/abs/2402.18510

阅读材料与本笔记的关系

- **Induction Head 原始论文：**核对特殊 FFN 的特征核、三个训练阶段、梯度流假设与具体定理。本文只把证明目标形式化，尚未在会话中逐项完成证明。
- **Astra 原始日志：**用于核对 Teacher Forcing 的输入形式、Activation 对比、层与神经元筛选，以及局部/方向消融的实验路径。日志记录可支持“做了什么”，不自动支持“机制已经被严格证明”。
- **RNN 与 Transformer 的比较论文：**只用于界定关联检索的容量或资源约束差异；不能据此直接断言全部优化算法、全部训练分布中 Transformer 必然更快学成。

下次续推时的约定

本文使用 $Z[:, 5, :]$ 表示包含 BOS 的七位置训练输入中用于预测末尾 B 的位置；单目标 Loss 与标准全序列 CE 必须分别标注。讨论由读者主导推理步骤：只有明确要求时，才计算单个梯度或展开某段证明，不抢先把后续答案全部列出。