

1 Attention 的数学本质：一次自问自答的推演

本文不是论文，是一次思辨的记录。我们从” QK^T 到底是什么”这个朴素问题出发，一路追问下去——每一步都先提出疑问，再辨析，中间走过弯路、也纠正过错误。目的是把 attention 的因果顺序讲清楚： Q ，不是从天而降的定义，而是从”如何度量词与词的关联”这个本质问题里**推导**出来的产物。

1.1 一、起点： QK^T 为什么是”词与词的关联度”？

大多数教程上来就甩出：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

然后告诉你” Q 去找 K ，算出注意力权重，再加权 V ”。但这是**把结论当定义**——你并不知道 Q, K 为什么存在， QK 为什么能代表关联。

我们换一个问法：**如果让你从零设计”衡量第 i 个词和第 j 个词有多相关”，你会怎么做？**

最自然的起点是内积。 QK^T 的第 (i, j) 个元素是两个行向量的点积：

$$(QK^T)_{ij} = Q_i \cdot K_j = \sum_d Q_{id} K_{jd} = \|Q_i\| \|K_j\| \cos \theta$$

内积的几何意义是**投影 / 对齐程度**：两个向量方向越一致，内积越大。所以内积天然就是一个相似度量——这是”关联度”的数学来源。**不是先有 attention 才有关联度，是先想度量关联，内积自然浮现。**

1.2 二、 Q, K 来自同一个 X ：双线性型登场

关键在于， Q 和 K 都是**同一个输入 X** 的线性投影：

$$Q = XW_Q, \quad K = XW_K$$

于是 $Q_i = x_i W_Q$ （第 i 个词的 embedding 投影）， $K_j = x_j W_K$ 。代入内积：

$$(QK^T)_{ij} = (x_i W_Q)(x_j W_K)^T = x_i (W_Q W_K^T) x_j^T = x_i M x_j^T$$

其中

$$M = W_Q W_K^T \in \mathbb{R}^{d_{model} \times d_{model}}$$

这一步是整个推演的**枢纽**。 $(QK^T)_{ij}$ 不是别的，就是两个词的原始 embedding x_i, x_j 通过一个矩阵 M 的**双线性型 (bilinear form)**。它衡量”词 i 和词 j 在 M 定义的度量下有多关联”。

到这里，一个自然的正确认知顺序浮现了：

关联度 = 双线性型 $x_i M x_j^T$ （本质） $\rightarrow M$ 分解成 $W_Q W_K^T$ （工程） $\rightarrow$ 涌现出 Q, K 和 QK^T （结论）。

Q, K 不是 attention 的前提，而是”用可学习双线性型度量关联”这个想法的副产物。教程把顺序讲反了。

1.3 三、一个弯路：这是二次型吗？它凭什么能”非对称”？

这里我一度怀疑： $x_i M x_j^T$ 看着像二次型，而二次型不是应该对称吗？注意力的” i 关注 j ”和” j 关注 i ”要能不同，非对称从哪来？

辨析后发现：它不是二次型，是双线性型。这个区分正是非对称的根源。

- 二次型 $x^T A x$ ：同一个向量 x 夹在两边。它永远等价于对称矩阵，因为 $x^T A x = x^T \frac{A+A^T}{2} x$ ——反对称部分被同一个向量两边夹消掉了。二次型无法表达非对称。
- 双线性型 $x_i M x_j^T$ ：两个不同的向量 $x_i \neq x_j$ 。 M 的非对称部分不会被消掉。

严格验证非对称性——把 i, j 换位看是否相等：

$$x_j M x_i^T = (x_j M x_i^T)^T = x_i M^T x_j^T$$

（标量转置等于自身，再展开转置。）于是

$$x_i M x_j^T = x_j M x_i^T \iff M = M^T$$

而 $M = W_Q W_K^T$ ， W_Q, W_K 是两个独立的投影矩阵，一般 $W_Q W_K^T \neq W_K W_Q^T$ ，即 $M \neq M^T$ 。所以 $x_i M x_j^T \neq x_j M x_i^T$ ，非对称成立。

非对称的能力来自两处叠加：（1）两个不同向量（不是二次型的同一个向量）；（2）两个不同投影 $W_Q \neq W_K$ 。若强行令 $W_Q = W_K$ ，则 $M = W_Q W_Q^T$ 对称，注意力退化无向的——正因为 Q, K 用不同投影，才有有向注意力。

这里的教训：我最初的直觉”二次型该对称”没有错，错在把它当成二次型。它是双线性型，天生能非对称。

1.4 四、“ M 定义的度量”到底是什么意思？

“在 M 定义的度量下的关联”这句话很抽象。用具体的 M 落地：

$M = I$ （单位矩阵）：

$$x_i I x_j^T = x_i \cdot x_j = \sum_k x_{ik} x_{jk}$$

普通点积，每个维度同等权重。这是标准欧氏度量。

$M = \text{diag}(w_1, \dots, w_d)$ （对角）：

$$x_i M x_j^T = \sum_k w_k x_{ik} x_{jk}$$

每个维度有了权重 w_k 。若 $w_1 = 10, w_2 = 0.1$ ，则第1维匹配被放大、第2维几乎忽略。 M 在说：算这两个词像不像

M 非对角（一般情形）：

$$x_i M x_j^T = \sum_{k,l} M_{kl} x_{ik} x_{jl}$$

出现**跨维度项** $M_{kl} x_{ik} x_{jl}$ ——“词 i 的第 k 维”与“词 j 的第 l 维”之间也能关联。比如维度 3 编码时态、维度 7 编码主谓， $M_{37} \neq 0$ 就让“ i 的时态”去匹配“ j 的主谓”。

所以“度量”在数学上就是**如何定义两个向量的广义内积**。 M 可以拉伸某些维度、压缩某些维度、混合维度。 $M = W_Q W_K^T$ 是学出来的，训练让它变成“对这个任务，词与词的关联该怎么算”的度量。这就是“ M 定义的度量下的关

1.5 五、维度清账

推到这里必须把维度全部钉死，这是白板上最易错的地方。

张量	维度
X	$L \times d_{model}$
W_Q, W_K	$d_{model} \times d_k$
W_V	$d_{model} \times d_v$
Q, K	$L \times d_k$
V	$L \times d_v$
$M = W_Q W_K^T$	$d_{model} \times d_{model}$
$Q K^T$	$L \times L$
输出	$L \times d_v$

几个约束：

1. W_Q, W_K 的输出维度**必须相同**（都是 d_k ），否则 $Q K^T$ 点积维度不匹配。
2. W_V 的输出维度 d_v **可以独立**——它不参与点积，只被加权求和。
3. $Q K^T$ 是 $L \times L$ ，**只由序列长度决定，与 d_k 无关**——这正是长序列 $O(L^2)$ 显存瓶颈的来源。

1.6 六、核心洞察： M 是低秩的，这是一次矩阵分解

M 是 $d_{model} \times d_{model}$ ，但它的秩被瓶颈维度 d_k 卡住：

$$\text{rank}(M) = \text{rank}(W_Q W_K^T) \leq \min(\text{rank}(W_Q), \text{rank}(W_K)) \leq d_k$$

通常 $d_k \ll d_{model}$ （例如 $d_{model} = 512, d_k = 64$ ）。所以 M 是一个名义上 512×512 、**实际秩不超过 64 的低秩矩阵**。这正是“矩阵分解”的气味。

低秩带来三层后果：

- (1) 计算上——**从不显式构造 M** 。靠结合律：

$$x_i M x_j^T = x_i (W_Q W_K^T) x_j^T = (x_i W_Q) (x_j W_K)^T = Q_i \cdot K_j$$

关联度在 d_k 维空间点积，不在 d_{model} 维。计算从 $O(d_{model}^2)$ 降到 $O(d_{model} d_k)$ 。

(2) 表达上——低秩是归纳偏置。关联度不在全空间算，而是先投影到 d_k 维子空间再比较。模型被迫”只在最相关 d_k 个方向上判断关联”。

(3) Multi-head 是低秩分解的并行拼接。 h 个头各自 $M_i = W_Q^{(i)} W_K^{(i)T}$ ，秩 $\leq d_{model}/h$ 。整体注意力 $= h$ 个低秩关联模式的并行组合，每个头在不同的低秩子空间捕捉一种关联（句法、指代、时态.....）。这比单个满 M 更有结构。

1.7 七、SVD 视角：关联的”主成分”是什么

到这里出现一个关键的追问：既然 M 低秩、像 SVD，那能不能直接从 M 整体（而不是拆成两个塔）来看？

可以，而且这个视角更接近本质。把 $x_i M x_j^T$ 读作” M 作用在 x_j 上，再和 x_i 内积”：

$$x_i M x_j^T = x_i \cdot (M x_j^T)$$

$M x_j^T$ 把 x_j 线性变换成一个新的 d_{model} 维向量，再和 x_i 做标准内积。

现在对 M 做 SVD: $M = U \Sigma V^T$, U, V 正交, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_{d_k}, 0, \dots, 0)$ (低秩, 只有 d_k 个非零奇异值)。代入

$$x_i M x_j^T = x_i U \Sigma V^T x_j^T = \sum_{r=1}^{d_k} \sigma_r (x_i \cdot u_r) (x_j \cdot v_r)$$

逐项读：

- u_r, v_r : 第 r 对关联主方向;
- $x_i \cdot u_r$: x_i 在主方向 u_r 上的分量;
- $x_j \cdot v_r$: x_j 在主方向 v_r 上的分量;
- σ_r : 这对主方向的重要性权重。

所以关联度 = d_k 对”主方向配对”的加权和。 σ_r 大的方向主导关联, $\sigma_r = 0$ 的方向 (第 d_k 个之后) 完全不参与——这正是低秩: 只有 d_k 个主方向活跃。

这里我们纠正了一个之前的说法。在”两个塔”视角下 ($Q_i K_j$), x_i, x_j 各自降到 d_k 维、在低维相遇, 不升回 d_{model} 。但在” M 整体算子”视角下, $M x_j^T$ 确实是 d_{model} 维向量。所以”把 x_i 降维抽取主成分、重新生成 d_{model} 维向量再和 x_j 内积”这个描述——在 M 视角下是完全正确的, 只是和两个塔视角拆分的位置不同。同一 $x_i M x_j^T$, 两种视角、两种维度叙事, 数学等价。

1.8 八、辨析：像 SVD，但不是 SVD

低秩让人联想 SVD，但要加限定：

- SVD $M = U \Sigma V^T$: U, V 正交、 Σ 对角非负, 是唯一的、有约束的分解, 奇异值排序。
- $M = W_Q W_K^T$: W_Q, W_K 无任何正交约束, 自由学出, 因子不唯一、不正交。

两者都是低秩分解, SVD 是其中最规范的一种 (正交+对角), $W_Q W_K^T$ 是无约束的低秩分解。任何秩 $\leq d_k$ 的矩阵都能写成 SVD、也能写成 $W_Q W_K^T$, 但后者的因子既不唯一也不正交。所以精确的说法是: M 低秩, “抽取 d_k 个主成分”的直觉对, 但因子是学出来的、非正交的, 不是严格的 SVD。

1.9 九、和 two-tower 检索的同构

$$x_i M x_j^T = (x_i W_Q)(x_j W_K)^T = \langle Q_i, K_j \rangle$$

这个结构和推荐 / 检索系统的**双塔 (two-tower)** 模型完全同构：

$$\text{推荐打分 } R_{ij} = \langle u_i, v_j \rangle, \quad u_i = \text{user_tower}(x_i), \quad v_j = \text{item_tower}(x_j)$$

W_Q 是 query 塔、 W_K 是 key 塔，点积算相关性。矩阵分解 $R \approx UV^T$ 里 $u_i \cdot v_j$ 是低秩打分——和 $Q_i \cdot K_j$ 是同一个数学骨架。

换句话说：two-tower retrieval 本质上就是 single-head attention 的关联计算部分。做过 EBR / 双塔召回的人，其实早就在用 attention 的数学核心，只是没把它和 transformer 显式连起来。

1.10 十、 $\sqrt{d_k}$ 缩放：为什么是根号

$$\text{scores} = \frac{QK^T}{\sqrt{d_k}}$$

假设 Q_i, K_j 各维独立、均值 0、方差 1，则点积

$$Q_i \cdot K_j = \sum_{d=1}^{d_k} Q_{id} K_{jd}$$

是 d_k 个独立项之和，方差 = d_k （方差可加），标准差 $\sim \sqrt{d_k}$ 。维度越高、点积数值越大。

若不缩放，大数值进 softmax 会让分布**极度尖锐**（一个位置接近 1、其余接近 0），落入 softmax 的饱和区，梯度 ≈ 0 ，训练停滞。除以 $\sqrt{d_k}$ 把方差归一化回 1，让 softmax 输入保持在合理范围。**之所以是 $\sqrt{d_k}$ 而非 d_k ，因为要抵消的是标准差 $\sqrt{d_k}$ ，不是方差。**

1.11 十一、退一步：这条推演的正确顺序

把整条线收拢成一句：

先问”关联度怎么算” $\rightarrow$ 内积 $\rightarrow$ 双线性型 $x_i M x_j^T \rightarrow M$ 该低秩（关联是低维的） $\rightarrow$ 分解 $M = W_Q W_K^T \rightarrow$ 涌现 $Q, K, QK^T \rightarrow$ 归一化（softmax + $\sqrt{d_k}$ ） $\rightarrow$ 加权聚合 $V \rightarrow$ 完整 attention。

Q, K, V 是从”用低秩双线性型度量关联”推导出来的**产物**，不是需要背诵的前提。会背 $\text{softmax}(QK^T/\sqrt{d})V$ 的人很多；能说清”attention 本质是用低秩双线性型定义词间关联， Q, K 是这个双线性型的低秩分解”的人，理解

1.12 十二、更大的图景：维度变换是 ML 的一条主线

最后把 attention 放进更大的坐标系。几乎所有模型都在做同一件事——把信息变换到合适的维度，让想要的结构显现。

SVM kernel——升维求可分。原空间线性不可分（如同心圆），核 $\phi: \mathbb{R}^d \rightarrow \mathbb{R}^D$ ($D \gg d$) 把数据升到高维，让原 trick 只算高维内积 $K(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$ ，不显式升维。**动机：低维分不开的，高维分得开。**

Attention——降维求匹配。embedding 在 d_{model} 高维、直接匹配噪声多，投影到 d_k 低维子空间算相似。**动机：高维噪声多，低维更匹配。**

注意 SVM 和 attention 方向相反——一个升维求可分、一个降维求匹配。因为目标不同：SVM 要”分开”，attention 要”度量相似”。**维度变换的方向由任务目标决定。**

Deep NN——升降交替，逐层重塑。DNN 不是单向：

$$h_{l+1} = \sigma(W_l h_l + b_l)$$

升维层（hidden 更宽，如 transformer 的 FFN $d_{model} \rightarrow 4d_{model} \rightarrow d_{model}$ ，先升后降）增加表达容量、制造可分性。 σ 是关键——纯线性的升降复合仍是线性（ $W_2 W_1$ 还是一个矩阵），非线性让每层不可合并，才能逐层重塑。**动机：增加容量，制造可分性。**

统一视角——核方法 / 表示学习的谱系：

- SVM kernel: 固定的升维 ϕ （人选 RBF / 多项式）；
- Attention: 学出的单次低维投影 W_Q, W_K （数据驱动的 kernel）；
- Deep NN: 学出的多层非线性变换（ ϕ 本身被学习）。

演进主线清晰：从”人手工设计维度变换”（SVM kernel）→ “数据学出单次变换”（attention）→ “数据学出多层变换”（Deep NN）。越往后，维度变换越不靠人的先验、越靠数据学习。这正是深度学习相对传统 ML 的本质进步——不再手工设计特征/核，而是学出变换本身；从特征工程走向表示学习。而无论哪一种，核心都是同一句话：维度变换让结构显现。

记于一次自问自答的推演之后。