

研究手稿：方差、大数定律与中心极限定理（Part-1）

从第一性原理出发 · 棣莫弗原始路径完整推导日志

2026-07-04 至 2026-07-06

方法论：用户驱动全部推导方向，助手仅执行计算与对错确认。核心原则：不预设结论，不依赖已知正态分布答案，不做逆向工程。back-and-forth 的试错记录本身就是手稿的一部分。 e 与 π 必须从推导中自然浮现，而不是从目标形式反推。

【第 001 条】开局：方差定义与 $n - 1$ 的争议

起点是最朴素的定义：

$$\text{样本方差} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2, \quad \text{标准差} = \sqrt{\text{方差}}$$

问题：为什么除以 $n - 1$ 得到的估计量，其期望值正好等于总体方差？即所谓“无偏估计”如何证明？

直观解释（自由度）：用样本均值 $\bar{X}$ 代替总体均值 μ 时，数据围绕 $\bar{X}$ 的波动天然比围绕 μ 的波动小——因为 $\bar{X}$ 本身是从数据里算出来的， n 个偏差 $(X_i - \bar{X})$ 之和恒为零，最后一项可由前 $n - 1$ 项推出，独立的自由度只有 $n - 1$ 。

结论：这个证明只需初等代数，不需要高深工具。

【第 002 条】无偏性证明的逐步推演

设 $X_1, \dots, X_n$ i.i.d., 总体均值 μ , 总体方差 σ^2 , 样本均值 $\bar{X}$ 。目标：

$$E \left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \right] = \sigma^2$$

变形：插入 μ ,

$$\sum (X_i - \bar{X})^2 = \sum [(X_i - \mu) - (\bar{X} - \mu)]^2$$

展开：

$$= \sum (X_i - \mu)^2 - 2(\bar{X} - \mu) \sum (X_i - \mu) + n(\bar{X} - \mu)^2$$

关键恒等式： $\sum (X_i - \mu) = n(\bar{X} - \mu)$ 。代入：

$$= \sum (X_i - \mu)^2 - 2n(\bar{X} - \mu)^2 + n(\bar{X} - \mu)^2 = \sum (X_i - \mu)^2 - n(\bar{X} - \mu)^2$$

取期望：第一项 $= n\sigma^2$ ；第二项用外部工具 $\text{Var}(\bar{X}) = \sigma^2/n$ （本条中作为已接受工具使用，未在此手稿内证明），得 $E[(\bar{X} - \mu)^2] = \sigma^2/n$ 。故

$$E\left[\sum (X_i - \bar{X})^2\right] = n\sigma^2 - n \cdot \frac{\sigma^2}{n} = (n-1)\sigma^2$$

两边除以 $n-1$ ，证毕。

【第 003 条】大数定律的位置：先证还是后证？

问题：是否应先证大数定律（LLN），再证中心极限定理（CLT）？

结论：不需要，两者逻辑独立。

- LLN: $\bar{X}_n \rightarrow \mu$ （常数，概率收敛），切比雪夫不等式即可。
- CLT: 标准化后的 $\bar{X}_n \rightarrow$ 正态分布（分布收敛），需要斯特林展开（或特征函数）。

决定：先走 CLT。LLN 留给 Part-2。

【第 004 条】第一次路线选择：特征函数法（被否决）

标准框架：设 $Y_i = (X_i - \mu)/\sigma$ ， $Z_n = \frac{1}{\sqrt{n}} \sum Y_i$ ，则

$$\varphi_{Z_n}(t) = [\varphi_Y(t/\sqrt{n})]^n, \quad \varphi_Y(t) = 1 - \frac{t^2}{2} + o(t^2)$$

$$\left[1 - \frac{t^2}{2n} + o(t^2/n)\right]^n \rightarrow e^{-t^2/2}$$

由连续性定理收敛到标准正态。

否决理由： $1/\sqrt{n}$ 的标准化尺度和 e^{it} 这个工具都太干净了——这是已经知道结论后倒着推的构造。 $e^{-t^2/2}$ 出现得毫无悬念，等于没有回答“正态分布从哪来”。放弃此路线，转向棣莫弗 1733 年的原始计数路径。

【第 005 条】转向棣莫弗的原始路径

设抛 n 次公平硬币（ n 为偶数），正面次数 S_n 。精确概率：

$$P(S_n = k) = \binom{n}{k} \left(\frac{1}{2}\right)^n, \quad k = 0, 1, \dots, n$$

一个死胡同：全局母函数 $(p + q)^n = 1$ ，因为 $p + q = 1$ ，整体恒为 1，所有信息被压缩，没有意义。

（此处暂停过一次——判断这个证明一天推不完，先准备面试，之后回来继续。）

【第 006 条】恢复：从二项分布的中心项开始

中心项：

$$P_0 := P(S_n = n/2) = \binom{n}{n/2} \left(\frac{1}{2}\right)^n = \frac{n!}{[(n/2)!]^2} \cdot 2^{-n}$$

代入斯特林公式 $n! \sim \sqrt{2\pi n} (n/e)^n$ ：

分母： $[\sqrt{\pi n} (n/2e)^{n/2}]^2 = \pi n \cdot (n/2e)^n$ （注意：平方后指数是 n ，不是 $2n$ ，见坑 1）。

$$P_0 \sim \frac{\sqrt{2\pi n} (n/e)^n}{\pi n (n/2e)^n} \cdot 2^{-n} = \frac{\sqrt{2\pi n}}{\pi n} \cdot 2^n \cdot 2^{-n} = \sqrt{\frac{2}{\pi n}}$$

注意： π 在这里第一次自然浮现——它来自斯特林公式，而斯特林公式里的 $\sqrt{2\pi}$ 本身来自 Wallis 乘积/高斯积分的归一化常数，不是从正态分布反推的。

【第 007 条】相邻项比值：一个“显然”的定义，但有用

相邻比值（精确，非近似）：

$$\frac{P(S_n = k+1)}{P(S_n = k)} = \frac{n-k}{k+1}$$

令 $P_d := P(S_n = n/2 + d)$ ，则

$$\frac{P_d}{P_{d-1}} = \frac{n/2 - d + 1}{n/2 + d}$$

争议与澄清：这个比值本身只是二项式系数的定义，不是新发现—— $(a + b)^n$ 的系数就是二项分布。但它仍然有用：可以从中心项 P_0 递推出任意项，

$$P_d = P_0 \prod_{j=0}^{d-1} \frac{n/2 - j}{n/2 + j + 1}$$

另一个疑问的澄清：既然中心项已用斯特林消掉阶乘，这里的乘积写成阶乘形式是否重新引入了斯特林？答案：没有。中心项用斯特林**近似**，相邻比值是**精确**的代数恒等式，乘积写成阶乘只是记号变形，不构成循环论证。

【第 008 条】取对数 + 泰勒展开

直接算乘积不行，取自然对数：

$$\ln P_d = \ln P_0 + \sum_{j=0}^{d-1} \ln \frac{n/2 - j}{n/2 + j + 1}$$

拆项：

$$\ln(n/2 - j) = \ln(n/2) + \ln\left(1 - \frac{2j}{n}\right), \quad \ln(n/2 + j + 1) = \ln(n/2) + \ln\left(1 + \frac{2(j+1)}{n}\right)$$

用 $\ln(1+x) = x - x^2/2 + O(x^3)$ ：

$$\begin{aligned} \ln\left(1 - \frac{2j}{n}\right) &= -\frac{2j}{n} - \frac{2j^2}{n^2} + O\left(\frac{j^3}{n^3}\right) \\ \ln\left(1 + \frac{2(j+1)}{n}\right) &= \frac{2(j+1)}{n} - \frac{2(j+1)^2}{n^2} + O\left(\frac{(j+1)^3}{n^3}\right) \end{aligned}$$

相减：

$$= -\frac{2(2j+1)}{n} + \frac{2[(j+1)^2 - j^2]}{n^2} + O\left(\frac{(j+1)^3}{n^3}\right) = -\frac{2(2j+1)}{n} \left(1 - \frac{1}{n}\right) + O\left(\frac{(j+1)^3}{n^3}\right)$$

主项 $= -\frac{2(2j+1)}{n}$ 。注意 $1/n^2$ 阶的项恰好与主项成比例（同为 $2j+1$ 因子），这是二次项相消后的结构。

【第 009 条】对 j 求和

用恒等式 $\sum_{j=0}^{d-1} (2j+1) = d^2$ ：

$$\ln P_d = \ln P_0 - \frac{2d^2}{n} + R_{n,d}, \quad R_{n,d} = \frac{2d^2}{n^2} + O\left(\frac{d^4}{n^3}\right)$$

纪律要求：此处不预设 d 的量级，余项保留符号，留到第 016 条统一控制。（过程中曾提前说“ $d = O(\sqrt{n})$ 时余项趋于 0”，被叫停——量级判断在坐标映射建立之前是跳步，见坑 4。）

【第 010 条】取指数：钟形曲线浮现

忽略余项（合法性见第 016 条）：

$$P_d \approx \sqrt{\frac{2}{\pi n}} e^{-2d^2/n}$$

这已经是正态 pdf 的雏形。关键观察：当 $n \rightarrow \infty$ 时，若把横轴连续化，每个整数格点 d 对应一个无穷小步长—— d 表示“第 d 个无穷小量”。下一步是把离散求和变成积分。

【第 011 条】黎曼和与步长 Δx

设 $x = d \cdot \Delta x$ ，其中 Δx 是待定的、依赖 n 的无穷小步长。

为什么密度要除以 Δx ： $\sum_d P_d$ 是对整数 d 求和，步长为 1；换成 x 变量后步长变为 Δx 。

黎曼和的标准形式是 $\sum f(x_i) \Delta x$ ，所以必须写成

$$\sum_d P_d = \sum_d \frac{P_d}{\Delta x} \cdot \Delta x \rightarrow \int f(x) dx, \quad f(x) = \frac{P_d}{\Delta x}$$

直接把 $\sum P_d$ 写成 $\int f dx$ 会丢失 Δx 因子（坑 5）。

【第 012 条】尺度确定：正向推导（本条为修订版）

修订说明：原推导日志中，本步骤的说法是“从归一化条件推出 $\Delta x = 2/\sqrt{n}$ ”。这个说法**不成立**——第 013 条会验证：归一化对任意尺度参数恒成立，因此归一化条件确定不了 Δx ；原来最后取 $\sigma_x = 2$ 实际上仍是对着 $N(0, 1)$ 的形式凑的，违反了手稿自己的原则（坑 8）。正向路径如下，所需材料全部已在手里。

从指数直接读出尺度。把第 010 条的结果改写成高斯标准形：

$$e^{-2d^2/n} = \exp\left(-\frac{d^2}{2 \cdot (n/4)}\right) = \exp\left(-\frac{d^2}{2\sigma_d^2}\right), \quad \sigma_d^2 = \frac{n}{4}$$

这一步没有引入任何外部信息——只是把推导得到的指数写成 $-d^2/(2\sigma_d^2)$ 的形式， $\sigma_d^2 = n/4$ 是从指数里**读**出来的。

独立一致性检验： S_n 是 n 个独立 Bernoulli(1/2) 之和，每次抛掷方差为 $\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$ ，故

$$\text{Var}(S_n) = \frac{n}{4}$$

精确方差与指数中浮现的尺度 σ_d^2 **完全一致**。这不是巧合，是推导正确性的内在检验：斯特林 + 泰勒的展开自动复现了精确的二阶矩。

标准化。自然的无量纲坐标是 $x = d/\sigma_d$ ，即

$$x = \frac{2d}{\sqrt{n}}, \quad \Delta x = \frac{2}{\sqrt{n}}$$

系数自动吻合（无需再凑）。代入第 011 条的密度：

$$f(x) = \frac{P_d}{\Delta x} = \frac{\sqrt{n}}{2} \cdot \sqrt{\frac{2}{\pi n}} e^{-x^2/2} = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

验算系数： $\frac{\sqrt{n}}{2} \sqrt{\frac{2}{\pi n}} = \frac{1}{2} \sqrt{\frac{2}{\pi}} = \frac{1}{\sqrt{2\pi}}$ 。指数： $-\frac{2d^2}{n} = -\frac{2}{n} \cdot \frac{x^2 n}{4} = -\frac{x^2}{2}$ 。

标准正态密度的系数 $\frac{1}{\sqrt{2\pi}}$ 是从 $P_0 \sim \sqrt{2/\pi n}$ 和 $\Delta x = 2/\sqrt{n}$ 相除自动得到的——两个都来自正向推导，没有任何一步对着目标形式调参数。

【第 013 条】归一化：降级为一致性检验（本条为修订版）

原日志中把归一化当成确定 Δx 的手段。实际计算表明它做不到这一点，但作为**检验**仍然有价值。

设一般尺度 $\sigma_x = \sqrt{n} \Delta x$ ，则密度可写为

$$f(x) = \sqrt{\frac{2}{\pi}} \cdot \frac{1}{\sigma_x} e^{-2x^2/\sigma_x^2}$$

用高斯积分 $\int_{-\infty}^{\infty} e^{-ax^2} dx = \sqrt{\pi/a}$ ，取 $a = 2/\sigma_x^2$ ：

$$\int_{-\infty}^{\infty} f(x) dx = \sqrt{\frac{2}{\pi}} \cdot \frac{1}{\sigma_x} \cdot \sigma_x \sqrt{\frac{\pi}{2}} = 1$$

对任意 $\sigma_x > 0$ 恒成立。含义：

1. 归一化不依赖尺度选取——这正是”密度在变量代换下总保持归一”的体现，所以它**不能**用来确定 Δx 。
2. 但它验证了第 011 条补 Δx 的操作是对的：概率总质量在离散→连续的过程中守恒，没有漏掉或多算因子。
3. 尺度的确定必须来自别处——即第 012 条：从指数读出 $\sigma_d^2 = n/4$ ，与 $\text{Var}(S_n)$ 一致。

【第 014 条】最终结论

将标准化变量记为 $\frac{S_n - n/2}{\sqrt{n/4}}$ （分母是 S_n 的标准差），则

$$\lim_{n \rightarrow \infty} P\left(a \leq \frac{S_n - n/2}{\sqrt{n/4}} \leq b\right) = \int_a^b \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$$

部分二项分布的和收敛为正态分布的积分。棣莫弗版本（ $p = 1/2$ ）证毕。

对一般 p ：中心移到 $k = np$ ，标准化分母变为 $\sqrt{np(1-p)}$ ；对一般分布，分母为 $\sigma\sqrt{n}$ （Part-2 方向）。

【第 015 条】踩过的完整坑（共 8 个）

坑 1：斯特林化简的指数错误。 错误： $[(n/2e)^{n/2}]^2 = (n/2e)^{2n}$ 。正确： $= (n/2e)^n$ 。后果：错误版本会冒出发散的 $(2e/n)^n$ 项；正确版本干净地得到 $\sqrt{2/\pi n}$ 。修正方式：不拿已知结论套，从头重推一遍指数。

坑 2：把相邻比值当作“新发现”。 $P_{k+1}/P_k = (n-k)/(k+1)$ 只是二项式系数的定义，本身没有信息量。但它的价值在递推结构：从中心项出发可到达任意 P_d 。

坑 3：特征函数法被过早提出。 e^{it} 与 $1/\sqrt{n}$ 都是知道结论后倒着构造的工具。逆向工程无法回答“正态分布为什么长这样”。

坑 4：余项的量级判断过早引入。 在坐标映射（ d 与 $\sqrt{n}$ 的关系）建立之前就说“ $d = O(\sqrt{n})$ 时余项趋于 0”是跳步。纪律：先保留余项符号，最后统一控制。

坑 5：黎曼和步长缺失。 $\sum P_d / \int f dx$ 必须先补 Δx ： $\sum (P_d/\Delta x) \Delta x$ ，密度是 $P_d/\Delta x$ 。

坑 6：预设 $\Delta x = 1/\sqrt{n}$ 。 这来自标准正态的目标形式，属于反推。正向路径见坑 8 的修正。

坑 7：过早宣布“基本证毕”。 在 $d \leftrightarrow x$ 的量化坐标映射完成之前，不能下结论。

坑 8（本次整理时发现）：归一化条件确定不了 Δx 。 原日志声称“ $\Delta x = 2/\sqrt{n}$ 从归一化推出”，但归一化对任意 σ_x 恒等于 1（密度在变量代换下总归一），随后取 $\sigma_x = 2$ 实质上还是对着 $N(0, 1)$ 凑——恰好踩了自己定义的逆向工程红线。正向修正：从指数 $e^{-d^2/n} = e^{-d^2/(2 \cdot n/4)}$ 直接读出 $\sigma_d^2 = n/4$ ，与精确方差 $\text{Var}(S_n) = n/4$ 一致（一致性检验，非预设），标准化 $x = d/\sigma_d$ 自然给出 $\Delta x = 2/\sqrt{n}$ ，且系数 $\frac{1}{\sqrt{2\pi}}$ 自动吻合。归一化降级为守恒性检验。

【第 016 条】余项控制

第 008–009 条丢掉的高阶项，现在统一控制。在中心区域 $d = O(\sqrt{n})$ 内：

- 二阶修正项： $\sum_{j=0}^{d-1} \frac{2(2j+1)}{n^2} = \frac{2d^2}{n^2} = O(1/n) \rightarrow 0$
- 三阶余项： $\sum_{j=0}^{d-1} O\left(\frac{(j+1)^3}{n^3}\right) = O\left(\frac{d^4}{n^3}\right) = O(1/n) \rightarrow 0$

因此在极限下忽略余项合法。 $d = O(\sqrt{n})$ 的窗口正是第 012 条读出的自然尺度 $\sigma_d = \sqrt{n}/2$ 所在的区域——量级判断放在坐标映射之后，逻辑顺序才对（对照坑 4）。

附注（启发式，非严格）：一般分布的 CLT 要求方差有限，直觉上对应“波动窗口不能失控”。对 Bernoulli 本身方差恒有限，此评论不构成本证明的一部分，仅作为向一般情形推广时的直觉预告。

【第 017 条】两条路线的最终对比

特征函数法：证明短，适用范围广（任意有限方差分布）；缺点是 e^{it} 与 $e^{-t^2/2}$ 像是先知道答案再构造的工具，回答不了”正态从哪来”。

棣莫弗法（本手稿）：从纯计数出发，只用斯特林公式和泰勒展开。 e 来自阶乘的增长率 ($n! \sim \sqrt{2\pi n}(n/e)^n$)， π 来自斯特林的归一化常数， $\sigma_d^2 = n/4$ 从展开的指数中自然浮现并与精确方差吻合。不依赖任何预设的分布形状。缺点：只覆盖二项分布，推广需要额外工作。

【第 018 条】历史脉络（仅记录）

- 棣莫弗（1733）：二项分布逼近正态， $p = 1/2$ 。
- 拉普拉斯（1812）：推广到任意 p 。
- 李雅普诺夫（1901）：推广到任意分布，用特征函数。

本手稿走棣莫弗原始路径，未使用特征函数。

【第 019 条】Part-2 方向（备注）

1. 推广到任意 p ：相邻比值 $\frac{n-k}{k+1} \cdot \frac{p}{1-p}$ ，中心 $k = np$ ，方差 $np(1-p)$ 。
2. 大数定律完整证明：切比雪夫不等式路线，与 CLT 独立。
3. 特征函数版 CLT 的严格证明（连续性定理）作为对照补充。
4. $\text{Var}(\bar{X}) = \sigma^2/n$ （第 002 条中被接受的工具）的独立证明。

【第 020 条】最终确认

整个推导中，每一步方向由用户指挥，助手只执行计算与确认对错。没有预设结论；特征函数路线因逆向工程被否决； e 与 π 从斯特林与泰勒中自然浮现；尺度 $\Delta x = 2/\sqrt{n}$ 从指数结构正向读出并被精确方差检验（原归一化论证在整理时被识别为坑 8 并修正）。back-and-forth 的 8 个坑全部留档。

附录：关键变量对照表

量	表达式	来源
$P_0 = P(S_n = n/2)$	$\sim \sqrt{2/\pi n}$	斯特林公式（第 006 条）
$P_d = P(S_n = n/2 + d)$	$\approx P_0 e^{-2d^2/n}$	比值递推 + 泰勒（第 007–010 条）

量	表达式	来源
σ_d^2	$n/4$	从指数读出, $= \text{Var}(S_n)$ (第 012 条)
x	$d/\sigma_d = 2d/\sqrt{n}$	标准化 (第 012 条)
Δx	$2/\sqrt{n}$	由 $x = d \Delta x$ (第 012 条)
密度系数	$\frac{\sqrt{n}}{2} \sqrt{\frac{2}{\pi n}} = \frac{1}{\sqrt{2\pi}}$	自动吻合, 无调参 (第 012 条)
标准化变量	$(S_n - n/2)/\sqrt{n/4}$	最终结论 (第 014 条)

完