从线性注意力到 Gated DeltaNet：一条被约束逼出来的推导

ARC-AGI-3 项目番外 · V1 · 2026-10-12

0. 缘起

这篇不在计划里。起因是 ARC-AGI-3 的 agent 跑在 Qwen3.6-35B-A3B 上，调 vLLM 前缀缓存时发现：这个模型大约 3/4 的层是线性注意力（Gated DeltaNet，下称 GDN），1/4 是普通 softmax 注意力。线性注意力层没有每个 token 一份的 K/V，只有一个固定大小的状态矩阵 S，所以缓存只能在“存了 S 快照”的位置复用，对话前缀一改就得整段重算。

为了弄清楚这个 S 到底是什么，顺手决定：不看论文，从“去掉 softmax”出发，正着推出 GDN 的更新式。

推导规则：推导由 Bo 完成。Claude 只做判卷：判“成立 / 不成立”，指出出错位置，不给提示、不给答案。中途约定了更细的判法：分两层，一层是“按你自己的逻辑对不对”，一层是“这一步离 GDN 近还是远”。

本文的价值在第 2 节：完整保留来回的过程，包括走错的路、判错的地方和被纠正的地方。终点公式人人能查到，怎么一步步被约束逼到终点，才是这次推导真正的收获。

1. 起点：手上有的三个公式

softmax 注意力

$$o_t = \sum_{i \le t} \frac{\exp(q_t^\top k_i)}{\sum_{j \le t} \exp(q_t^\top k_j)}\, v_i$$

线性注意力（直接去掉 softmax）

$$o_t = \sum_{i \le t} (q_t^\top k_i)\, v_i = \Big(\sum_{i \le t} v_i k_i^\top\Big) q_t, \qquad S_t = \sum_{i \le t} v_i k_i^\top = S_{t-1} + v_t k_t^\top, \qquad o_t = S_t q_t$$

其中 $S_t \in \mathbb{R}^{d_v \times d_k}$，大小固定，不随序列长度增长。

目标形式（GDN 的更新式，推导前已经知道长这样，推导的目标是“为什么是它”）

$$S_t = \alpha_t\, S_{t-1}\big(I - \beta_t\, k_t k_t^\top\big) + \beta_t\, v_t k_t^\top, \qquad o_t = S_t\, q_t$$

2. 推导全过程（逐轮记录）

下面按时间顺序记录。“Bo”是推导者的原话（只做了轻微整理，如笔误“先行”改为“线性”），“判”是当时的判卷，“注”是事后补的说明。

阶段零：推导前，softmax 到底在做什么

> **Bo**：所以 softmax 的归一化，是通过 Gated DeltaNet 实现的?
> **判**：不成立。GDN 没有去实现 softmax 的归一化，而是用别的办法补“去掉 softmax 之后”出的问题。
> **Bo**：是因为 e^x 会放大内积大的、相似的词，再归一化，输出就稳定。GDN 我可以推导一下。
> **判**：成立。

阶段一：问题定位——去掉 softmax 丢了什么

第 1 轮

> **Bo**：GDN 是用来解决 softmax 不在的问题吧。$S_t = S_{t-1} + v_t k_t^\top$ 一直这样累加，正负不好说。
> **判**：成立。

注：$q_t^\top k_i$ 可正可负，权重不再是非负的、也不归一，S_t 只增不减。

第 2 轮

> **Bo**：有正有负，需要把它近似到 0–1 之间；但会有假设，距离 t 越近的 token 越重要。
> **判**：“越近越重要”成立，对应门控衰减 α_t；“有正有负，所以需要近似到 0–1 之间”不成立。

第 3 轮（插曲：位置编码）

> **Bo**：位置编码是直接加到 q 上?
> **判**：不成立。普通注意力层用 RoPE，对 q、k 各自按位置做旋转，是乘法；GDN 层不加显式位置编码，位置信息来自衰减的先后作用和一层很短的因果卷积。
> **Bo**：那就是 q、k 各自的位置编码加到各自原始向量上呗。v 用位置编码吗？感觉不用，不需要注意力。
> **判**：“加到各自原始向量上”不成立（是旋转，不是相加）；v 不加位置编码，成立。
> **Bo**：这个“加”不是加法，就是向量里两两元素乘以旋转矩阵。
> **判**：成立。

第 4 轮

> **Bo**：所以 GDN 是要把原始线性注意力转化成某种优化问题去看?
> **判**：成立。

第 5 轮

> **Bo**：线性注意力的问题是丢掉了 softmax。softmax 让输出稳定，同时注意力放大关系近的 token pair。那么这里要做类似的优化，优化什么，要想。
> **判**：成立。

第 6 轮

> **Bo**：所以第一个假设“越靠近当前 t 的 token 越重要”，有点像 e^x 放大关系近的 token pair 的感觉?
> **判**：不成立。问题在“近”字：e^x 放大的是**内容上**相似（$q^\top k$ 大）的 token，衰减偏向的是**位置上**靠近的 token，是两回事。

第 7 轮

> **Bo**：内容相似的，在线性注意力里被放大了吗？但不相似的也被放大了……
> **判**：成立。线性注意力里相似度只按 $q^\top k$ 线性加权，没有指数放大；衰减只看位置，近的不管相不相似都被抬高。
> **Bo**：那就是要看 q_t 和不同 k_i 的关系了。
> **判**：成立。

阶段二：走错的路——从输出 o_t 的递推入手

第 8 轮

> **Bo**：先把 o_t 和 o_{t-1} 的递推写一下。

判卷方写出了递推，但多加了一句“真正能递推的是状态 S_t，不是输出 o_t”。这是越界的提示，Bo 当场指出（“让你提示了吗，我说啥做啥”），重新只按要求写，不引入 S：

$$o_t - o_{t-1} = \sum_{i \le t-1} \left((q_t - q_{t-1})^\top k_i \right) v_i + \left(q_t^\top k_t \right) v_t$$

第 9 轮

> **Bo**：因为之前说 q_t 要和所有 k_i 看关系，但这个关系被 S_t 打破了，所以我才想从 o_t 看怎么解决。
> **判**：不成立，问题在“被 S_t 打破”。
> **Bo**：隐藏吧。
> **判**：成立。

注：$S_t q_t = \sum_i (k_i^\top q_t) v_i$ 恒等成立，两两关系一个没丢，只是被折叠进了 S_t。

第 10 轮

> **Bo**：那推导方向，从 o_t 和 o_{t-1} 这个看呢?
> **判**：这个方向推不到 GDN。
> **Bo**：（指着 $o_t = o_{t-1} + S_{t-1}(q_t - q_{t-1}) + (k_t^\top q_t) v_t$）所以应该从这里看?
> **判**：不成立，这还是 o_t 的递推。
> **Bo**：所以还是要从注意力分数上看，而不是直接碰 o。

> **判**：不成立，问题在“注意力分数”。

注：Bo 随后指出：“你明知道我意思是从 S_t 上看。”判卷方按字面判了，这次是判卷方的错。

阶段三：转到状态 S_t——衰减与“核心信息”

第 11 轮

> **Bo**：S_t 本身要做某种加权平均，类似 AdamW 那种感觉。
> **判**：成立。
> **Bo**：但 AdamW 那个加权平均可以直接用恒等式推出来，这里是转化成优化问题，解决思路不一样。
> **判**：成立。

第 12 轮

> **Bo**：S_t 本身衰减是自然的直觉，但也要保持 S_t 里有一个核心信息不丢？来优化。
> **判**：成立。
> **Bo**：这个核心信息该是个啥？引导一下，但不要直接提示和答案，简洁。

判卷方给了一个引导性问题：“S 被读出的方式是 $o = Sq$。假设下一刻拿来查询的 q 恰好等于刚写进去的 k_t，你希望 $S_t k_t$ 等于什么？”

第 13 轮（围绕 q 的一段反复，多轮来回，压缩记录）

> **Bo**：q_t、o_t、k_t 这三个自然保留，我们要衰减的是 S_{t-1}，所以就是 $S_{t-1}q_t$ 这里要保持什么？
> **判**：不成立，问题在 $S_{t-1}q_t$ 这一处……写进 S 的东西里没有 q。
> **Bo**：$o_t = S_{t-1}q_t + (k_t^\top q_t)v_t$，第二项又不会被衰减，衰减的是第一项。
> **判**：成立。
> **Bo**：那“保留”没错呀。
> **判**：按“第二项不被衰减”的意思，成立；判卷方之前按“存进 S 的内容”去判了。剩下的问题在：要找的“核心信息”是 S 里该留住的东西。
> **Bo**：那就是 S_{t-1} 衰减时要保留什么，因为 S_t 的衰减也是作用在 S_{t-1} 上。
> **判**：成立。

第 14 轮

> **Bo**：越靠近 t 的位置保留的信息越多，比如 $t-1$ 衰减 α，$t-2$ 衰减再多一点，按某种比例。那就按 α^n 衰减就行了。
> **判**：（先判）不成立，问题在“α^n”和“就行了”。
> **Bo**：别逆向工程，这确实是衰减的常用办法（比如 RL 里的折扣期望）。
> **判**：（更正）作为一种衰减办法，成立。之前是拿 GDN 的最终形式对照着判的，不该那样判。

第 15 轮

> **Bo**：这里的问题是 α 不好调，可能衰减过快，导致信息流失太多。所以需要某种明确的信息表达：S_{t-1} 要衰减，但要和那个明确要保留的信息尽量靠近，类似 RL 和 SFT 尽量靠近、但又要有变化的思想。
>
> **判**：成立。

注：这一轮已经点出了最终结构的两个部件：衰减（α），以及“改动尽量小、但要对准某个目标”（近端修正）。

阶段四：核心信息是什么——排除法

第 16 轮

> **Bo**：这个明确的信息就是 S_t 是 $vk^\top$ 矩阵之和的那种感觉，q_t 不牵扯进来。所以可能类似某种 $Ax = \lambda x$ 那种信息量保留？
>
> **判**：前半句成立；后半句不成立，问题在“$Ax = \lambda x$”。
>
> **Bo**：但最后是 $S_t q_t$，那就是 S_t 做矩阵分解，保留最大特征值的方向。这个信息是 S 矩阵本身信息的保留……应该是吧，S 本身就是信息本身。
>
> **判**：不成立，问题在“保留最大特征值方向”和“S 本身就是信息本身”。
>
> **Bo**：所以 S 本身的那个信息表达并不是我们想要的，而是要尽可能和正常注意力分数中的某种信息近似。
>
> **判**：前半句成立；后半句不成立，问题在“注意力分数”。
>
> **Bo**：或者说正常注意力计算时，k 和 v 的交互方式那个。
>
> **判**：成立。

注：排除了“谱/特征方向”这条路：要保的不是 S 作为矩阵的能量，而是它作为“key→value 存储”的行为。

第 17 轮

> **Bo**：你列下对比，只列对比，我再对比下。感觉就在眼前，但就是缺个什么 trick。

判卷方列了表，但第三行直接把 $q = k_j$ 代入，写出了 $S_t k_j$ 的展开。这等于替 Bo 走了关键一步，是本次推导中第二次越界。Bo 指出后，表只保留前两行：

	softmax 注意力	线性注意力
存什么	所有 (k_i, v_i) 原样存着	$S_t = \sum_{i \le t} v_i k_i^\top$
用 q 读	$o = \sum_i \mathrm{softmax}(q^\top k_i)\, v_i$	$o = S_t q = \sum_i (k_i^\top q)\, v_i$

阶段五：去掉 q——用 k_j 代替 q

第 18 轮

> **Bo**：只看到 $q \approx k_j$，就是说 q 和 k_j 内积越大越相似，所以这里是在线性注意力里把 q 换成 k_j 的感觉。
>
> **判**：成立。
>
> **Bo**：但我们并不知道具体的 k_j，所以要提前先算一遍?
>
> **判**：No。
>
> **Bo**：那就是公式本身就能帮助找到最优 k_j，并在 S 的迭代中保持下来。
>
> **判**：不成立，问题在“找到最优 k_j”。

第 19 轮（又一段关于 q 的反复）

> **Bo**：我们实际上是用 $k_j \approx q_t$ 去做某种 S_t 的衰减，或者说保持 softmax 中 k 和 v 的关联。
>
> **判**：后半句成立；前半句不成立，问题在“$k_j \approx q_t$”。
>
> **Bo**：但前面说的就是 q_t 和 k_j 近似呀。
>
> **判**：“q 与 k_j 近似”本身成立；不成立的是把它接到“去做 S_t 的衰减”上，两件事不在同一个环节。
>
> **Bo**：那就是 q 和 k_j 最近似，原先注意力中 q 和 k_j 内积最大，这个信息要保留——在 S_{t-1} 衰减时保留这个最大信息。
>
> **判**：不成立，问题在保留的对象上。
>
> **Bo**：你按我的逻辑梳理，不要逆向。

判卷方按 Bo 自己的链条梳理：(1) 去掉 softmax 后 S 要衰减但留住核心信息——成立；(2) 要留的信息只跟 k, v 有关——成立；(3) softmax 里 q 与 k_j 最近似时读出 v_j——成立；(4) 所以 S_{t-1} 衰减时保留“q 与 k_j 内积最大”——判为不成立，理由是把 q 带了回来，与第 (2) 步矛盾。

> **Bo**：不是，是最后 o 的表达上呀，我没说错。
>
> **判**：（更正）按“最后 o 的表达”理解，第 (4) 步成立：读出的 o 应保持“q 跟哪个 k_j 最像就主要读出 v_j”的行为。之前当成“存进 S 的内容”判了，判错了。

第 20 轮

> **Bo**：那就是 $k_j^\top k_j$ 的内积最大? 这是 S 中可以去掉 q 的办法。
>
> **判**：成立。

注：这是整条推导的转折点。用“查询恰好等于某个已写入的 key”这个检验，把未知的 q 从问题里消掉了。

第 21 轮

> **Bo**：（看着 $S_t = \sum_i v_i k_i^\top$）感觉是 S_t 从左上到右下的对角线的值。
>
> **判**：不成立，问题在“对角线”。
>
> **Bo**：对，对角线不是 $k_j k_j^\top$，是 v。
>
> **判**：成立。
>
> **Bo**：假设我们知道某个 k_j，那 $S_t k_j$ 和 $k_j k_j$ 这个值应该近似。

> **判**：不成立，问题在“$k_j k_j$”（按内积 $k_j^\top k_j$ 理解：一边是向量，一边是标量）。
>
> **Bo**：S_t 中并没有直接的 k_i、k_i 内积，但还是要从 $S_t k_i$ 中出。$S_t \in \mathbb{R}^{d_v \times d_k}$，$k_i \in \mathbb{R}^{d_k}$，可以乘。你先乘一下，推一步。

$$S_t k_j = \sum_{i \le t} v_i \, (k_i^\top k_j)$$

> **Bo**：所以 $S_t k_j$ 是 v_i 从 1 到 t、以 k_i 和 k_j 的内积为权重的加权和。这里就是要保证：q_t 和 S_t 乘的时候，对应 $S_t k_j$ 中 $k_j^\top k_j$ 那一项最大。还没完全闭合。
>
> **判**：成立。

第 22 轮

> **Bo**：所以衰减 S_t 的同时，如果 $k_j^\top k_j$ 本身的值不够大，就要让它 scale 增大。我是按自己的逻辑体系推的。
>
> **判**：（先判不成立，后更正）按 Bo 自己的逻辑自洽，成立；但沿“放大 $k_j^\top k_j$”这条路推不到 GDN。

注：从这一轮起，约定判法分两层：“逻辑本身对不对”和“离 GDN 近还是远”。

阶段六：显式 vs 隐式

第 23 轮

> **Bo**：$S_t k_j$ 这个本身没问题，从这里到 GDN。
>
> **判**：逻辑成立；从 $S_t k_j$ 出发能推到 GDN。
>
> **Bo**：但关键是我们不知道这个 k_j，也不能提前知道 j 是哪个。
>
> **判**：逻辑成立；但把它当成卡住的地方，这条路推不到 GDN。
>
> **Bo**：但 q_t 来的时候，我们可以算一遍知道 j，这个不允许?
>
> **判**：能算，但那样必须把所有 k_i 都留着，状态不再是固定大小，等于退回普通注意力；推不到 GDN。
>
> **Bo**：所以我之前说嘛，不能显式算，某种隐式的感觉。
>
> **判**：逻辑成立；这个方向能推到 GDN。
>
> **Bo**：隐式的不就是类似某种“找到 j”嘛。
>
> **判**：逻辑上可以这么理解；但只要还是“找 j”的思路就推不到 GDN，问题在“找”字。
>
> **Bo**：这个和矩阵主对角线无关吧。总觉得对任意 i 都成立就可以了?
>
> **判**：两处都成立；这个方向能推到 GDN。

注：第二个转折点。不去“找” j，而是要求性质对**每一个**写入过的 key 都成立，这样无论将来 q 对上哪个 j 都没问题。

第 24 轮

> **Bo**：随着 S_t 的演化，无论哪个 k_j 的那一项都能最大程度保留，无论 q_t 是哪个 k_j 都可以。关键是假设 q_t 是这个 k_j 之后，形式化如何表达。
>
> **判**：逻辑成立；能推到 GDN。
>
> **Bo**：但每个都保留可能不容易解。随着 S_t 演化，距离 t 远的 j 那一项还是会衰减。也可能刚好巧合：S_t 必须衰减，因为不衰减会发散；但衰减的时候，距离 t 近的那一项最大程度保留。
>
> **判**：逻辑成立；能推到 GDN。

阶段七：写成优化问题并求解

第 25 轮：目标的形状

> **Bo**：所以就是衰减之后的 S_t 和 k_t 的乘积，与某个东西的差最小。这个东西能体现 k_tk_t；如果每一个 $k_t^\top k_t$ 都能保证最大，其实就是这个闭合的 S_t 衰减表达式。
>
> **判**：“衰减后的 S 乘 k_t 与某个东西差最小”逻辑成立，能推到 GDN；“这个东西能体现 k_tk_t”按 Bo 的逻辑说得通，但这一处推不到 GDN。
>
> **Bo**：现在有的只有 k_t, v_t, q_t?
>
> **判**：不成立，问题在“只有”。
>
> **Bo**：我知道还有 S_t、S_{t-1}，但能直接用在“被减的目标”上的，就只有 k_t, v_t, q_t。（笔误 S_tq_t 改为 S_tk_t。）
>
> **判**：逻辑成立；能推到 GDN。

第 26 轮：目标是什么

> **Bo**：你说“这个东西体现 k_tk_t”不对，但主思路就是尽可能保住每个 k_j 那一项的信息，这样无论 q_t 是哪个 k_j 都可以——很矛盾。
>
> **判**：不矛盾，主思路没问题；问题在“内积”两个字。
>
> **Bo**：那肯定 S_tk_t 和 $k_t^\top k_t$ 没法比，一个向量一个标量。要凑的东西是 $\mathbb{R}^{d_v}$ 里的向量，但又能表达 $k_t^\top k_t$ 这个信息量，是它的某种隐式表达。
>
> **判**：逻辑成立；能推到 GDN。
>
> **Bo**：要凑的东西和 q_t 无关吧，这里更多是数学优化的建模了。
>
> **判**：两处都成立。
>
> **Bo**：虽然有点扯，不会是某种 $v_tk_t^\top k_t$ 的同构吧?
>
> **判**：逻辑成立；能推到 GDN。
>
> **Bo**：所以是 $(v_tk_t^\top)k_t$ 的同构，但不是 $(v_tk_t^\top)k_t$?
>
> **判**：不成立，问题在“但不是”。
>
> **Bo**：对嘛，也就只能是 $(v_tk_t^\top)k_t$……被逼出来的感觉。
>
> **判**：成立。

注：回看 $S_tk_j = \sum_i v_i(k_i^\top k_j)$，$i=j$ 那一项正是 $(k_j^\top k_j)v_j = (v_jk_j^\top)k_j$：一个 $\mathbb{R}^{d_v}$ 向量，系数里带着 $k_j^\top k_j$。“要保的是那一整项，而不是它的系数”，这就是第 26 轮里“内积”两个字的问题所在。

第 27 轮：写出优化问题

> **Bo**：那就是 $\min \left\| S_t k_t - (v_t k_t^\top) k_t \right\|$ 这个优化目标?
>
> **判**：成立。
>
> **Bo**：然后 $S_t = \alpha S_{t-1} + A$，A 由这个优化问题给出?
>
> **判**：成立。
>
> **Bo**：把 S_t 代进去，求导等于 0，看 A 是啥?
>
> **判**：成立。
>
> **Bo**：你推一下，这里是纯数学计算。

记 $u = (v_t k_t^\top) k_t = (k_t^\top k_t)\, v_t$，

$$\mathcal{L}(A) = \tfrac{1}{2} \left\| (\alpha S_{t-1} + A) k_t - u \right\|^2, \qquad \frac{\partial \mathcal{L}}{\partial A} = \big((\alpha S_{t-1} + A) k_t - u \big) k_t^\top$$

令其为 0（$k_t \neq 0$）：

$$A\, k_t = (k_t^\top k_t)\, v_t - \alpha S_{t-1} k_t$$

A 有 $d_v \times d_k$ 个未知数，这里只有 d_v 个方程，解不唯一。

第 28 轮：补约束

> **Bo**：而且 A 是一个矩阵……
>
> **判**：成立。
>
> **Bo**：那就是还有别的约束条件?
>
> **判**：逻辑成立；能推到 GDN。
>
> **Bo**：A 要小于实际 S_t 的模? 类似矩阵谱半径那种度量的感觉。
>
> **判**：“A 要小”逻辑成立，能推到 GDN；“小于 S_t 的模”和“谱半径”按 Bo 的逻辑说得通，但这两处推不到 GDN。
>
> **Bo**：所以不能直接求解 A，应该是 A = 两个向量的乘积?
>
> **判**：成立。
>
> **Bo**：$A \in \mathbb{R}^{d_v \times d_k}$，$A$ = 向量 $\times k_t^\top$?
>
> **判**：成立。

第 29 轮：求解

令 $A = x\, k_t^\top$ 代入条件，左边 $= x\, (k_t^\top k_t)$，所以

$$x = v_t - \frac{\alpha S_{t-1} k_t}{k_t^\top k_t}, \qquad \boxed{S_t = \alpha S_{t-1} \left(I - \frac{k_t k_t^\top}{k_t^\top k_t} \right) + v_t k_t^\top}$$

验证：$S_t k_t = \alpha S_{t-1} k_t - \alpha S_{t-1} k_t + (k_t^\top k_t) v_t = (k_t^\top k_t)\, v_t = u$，恰好满足目标；对任意与 k_t 正交的方向 w，$S_t w = \alpha S_{t-1} w$，只衰减、不改写。

> **Bo**：这个不就出来了？
>
> **判**：逻辑成立。跟 GDN 的式子只差一处。

3. 收尾：从这个解到 GDN 原式

差的第一处：归一化。 GDN 在写入前先把 k_t 做 L2 归一化，$k_t^\top k_t = 1$，分母消掉：

$$S_t^* = \alpha_t S_{t-1}\big(I - k_t k_t^\top\big) + v_t k_t^\top, \qquad S_t^* k_t = v_t$$

Bo 的式子更一般：k 不归一化时同样成立，只是目标变成 $(k_t^\top k_t)v_t$。

差的第二处：写入强度 β_t。 每一步都精确改写太激进，key 带噪声时会把旧记忆冲掉。GDN 不直接跳到 S_t^*，而是在“衰减后的旧状态”与 S_t^* 之间插值：

$$S_t = (1-\beta_t)\,\alpha_t S_{t-1} + \beta_t\, S_t^* = \alpha_t S_{t-1}\big(I - \beta_t k_t k_t^\top\big) + \beta_t\, v_t k_t^\top$$

这正是 GDN 的更新式。它等价于：从 $\alpha_t S_{t-1}$ 出发，对 $\frac{1}{2}\|Sk_t - v_t\|^2$ 走一步步长为 β_t 的梯度下降：

$$S_t = \alpha_t S_{t-1} - \beta_t\big(\alpha_t S_{t-1} k_t - v_t\big)k_t^\top$$

$\beta_t = 1$ 时，就退回第 29 轮解出来的精确解。α_t、β_t 都不是常数，由当前 token 经一个小网络算出，每步不同。这一点也回应了第 15 轮“α 不好调”：干脆让模型按内容自己决定每一步衰减多少、写入多少。

和 GDN 原文思路的对比

	本文推导	GDN 原文
状态的角色	key→value 联想记忆	同
衰减	先衰减 αS_{t-1}，再修正	同（门控 α_t）
目标	$\min \|(\alpha S_{t-1} + A)k_t - (v_t k_t^\top)k_t\|$	$\frac{1}{2}\|Sk_t - v_t\|^2$（$k$ 已归一化时两者相同）
怎么解	解不唯一，取 $A = x\,k_t^\top$，精确求解	走一步梯度下降，步长 β_t
结果	$\alpha S_{t-1}\big(I - \frac{k_t k_t^\top}{k_t^\top k_t}\big) + v_t k_t^\top$	$\alpha_t S_{t-1}(I - \beta_t k_t k_t^\top) + \beta_t v_t k_t^\top$
关系	等于原文取 $\beta_t = 1$	本文精确解的“部分写入”版

4. 数值验证

用随机矩阵（$d_v = 5$, $d_k = 4$, $\alpha = 0.9$, $\beta = 0.3$）检验：

- 第 29 轮的解满足 $S_t k_t = \big(k_t^\top k_t\big)\, v_t$：通过（注意不是 v_t，除非 k 归一化）。
- 归一化后，插值形式 = 展开形式 = 一步梯度下降形式：三者数值完全一致。
- 与 k_t 正交的方向只被衰减、不被改写：通过。

5. 回到 ARC：为什么这件事影响前缀缓存

GDN 层的全部历史都被压进一个固定大小的 S_t，而且 S_t 只能从头按顺序一步步更新得到，没有“第 N 个 token 处的 S”可以随手截取。所以 vLLM 对这类层只能在少数位置存 S 的快照：对话前缀只要在快照之前被改过一个字，快照就作废，整段重算。这就是 agent 的对话组织改成“只追加、攒着一次性清理”的原因。

6. 协作复盘

这次推导里，判卷方出过几类错，记下来供以后避免：

1. **越界提示两次**：第 8 轮多写了“能递推的是 S_t”；第 17 轮表格多写了 $q = k_j$ 那一行，等于替推导者走了关键一步。
2. **按字面判、没按意思判**：第 10 轮“注意力分数”，Bo 明显指的是 S_t；第 25 轮把笔误 $S_t q_t$ 当成主要问题来判，Bo 指出“吹毛求疵”。
3. **拿终点公式倒推着判**：第 14 轮 α^n、第 22 轮“scale 增大”，按 Bo 自己的逻辑都自洽，却被判为不成立。
4. **判的对象没对齐**：第 13、19 轮关于 q 的反复，一方说“存进 S 的东西”，一方说“最后 o 的表达”，来回了好几轮。

由此约定的判法：**先判“按推导者自己的逻辑对不对”，再判“离目标近还是远”；只报位置，不给方向；推导者没点名要的东西一行都不写**。

附录 A：最早的线性注意力 = 核技巧

GDN 之前，线性注意力就是直接这么算的。最早的做法本质上就是 SVM 的核技巧，没有别的：把相似度 $\exp(q^\top k)$ 换成一个能拆开的核

$$\mathrm{sim}(q,k) = \phi(q)^\top \phi(k), \qquad \phi(x) = \mathrm{elu}(x) + 1 > 0$$

于是

$$o_t = \frac{\left(\sum_{i \le t} v_i\, \phi(k_i)^\top\right) \phi(q_t)}{\phi(q_t)^\top \sum_{i \le t} \phi(k_i)}, \qquad S_t = S_{t-1} + v_t\, \phi(k_t)^\top, \quad z_t = z_{t-1} + \phi(k_t)$$

- ϕ 是正的特征映射，所以权重 $\phi(q)^\top \phi(k_i)$ 全为正；
- 分母 $\phi(q_t)^\top z_t$ 让权重和为 1，模仿 softmax 的归一化。

状态 S_t、z_t 一路累加，不衰减、不覆盖。第 1 轮提出的两个问题（只增不减、无法覆盖旧记忆）在这里都还在，GDN 正是从这两点补上的。