

REALM / RAG / RAP 推演笔记

从零推导 REALM 的梯度机制,对比 RAG,再评估一个跨模态 RAP 研究提案。 下面按"我推导的思路 → 卡在哪 → 正确机制 → 实验证据 → 提案评估"组织。

一、起点:REALM 是什么

REALM (Gua et al., 2020, ICML, Google) 是 "retrieval-augmented" 这条线的开山之作。

核心主张:别把世界知识全塞进模型参数(那样要越训越大、还看不出知识存在哪), 让模型**显式检索**一个外部文本库(如整个 Wikipedia),用检索到的文档帮它预测。

三个卖点:可解释(看得到用了哪篇)、可更新(库变了不重训)、库可远大于参数容量。

招牌:**第一次做到在预训练阶段就端到端训练 retriever**,梯度穿过检索步反传。 学习信号 = masked language modeling(挖空填词)。

二、我的推导思路,以及卡在哪(这部分是关键)

起手(对的方向)

- reader 输入是 $z_{ij}; x$, d_model 维
- L 是 cost function, $\partial L / \partial z_{ij}$ 是知道的
- 想把这个梯度传给 retriever

第一次卡住: $\partial L / \partial z$ 传不到 retriever

自己发现的: - z_{ij} 是 **reader(BERT)**那一侧的文档 token embedding - retriever 双塔用的是 **$g(z)$** —— doc encoder 输出的检索向量 - 这两个不是同一个向量,中间没有连着的计算图 → 所以 $\partial L / \partial z_{ij}$ 没法直接传到 $g(z)$ 。这条路不通。(判断正确)

第二次卡住:对 z 求导这条路本身就错

一度想: $z' = z - lr \cdot \partial L / \partial z$ (更新文档向量),再 $\text{sigmoid}(g(z) \cdot f(x))$ 当独立打分 自己发现"这个是独立的,没法利用 llm 的结果" —— 觉察正确,但卡住的原因是 还在盯着对 z 求导。retriever 的参数是 f 、 g 的权重,不是 z ,不该对 z 求导。

想通的一跳:换成对检索概率求导

连接 llm 和 retriever 的不是 z 的梯度,是很早推 **reader** 时写过的那个式子:

$$p(y|x) = \sum_i p(y|x, z_i) \cdot p(z_i|x)$$

- $p(y|x, z_i)$: reader 在文档 z_i 下填对空的概率(llm 的东西)
- $p(z_i|x)$: 第 i 篇的检索权重(retriever 的东西) = softmax over top-k ($f(x) \cdot g(z_i)$)
- 两者在同一个 Σ 里相乘 $\rightarrow$ 对 $p(z_i|x)$ 求导时, llm 的结果自动进来

$\rightarrow$ 梯度不经过文档 embedding, 经过检索权重传给双塔。这是 REALM 的核心。

三个工程难点, 推导中自己全部点到:

1. 检索离散(几百万篇里选) $\rightarrow$ top-k 近似: 只取 top-k, 库外近似 $p \approx 0$
2. 全库 **softmax** 太贵 $\rightarrow$ 只在 top-k 内归一化(假设 top-k 就是全部 volume 的那一跳)
3. **index** 会过时(retriever 一更新 $g(z)$ 就变) $\rightarrow$ 异步: 每隔几百步才重建一次索引(stale index)

物理意义(推到最后的收尾)

top-k 不是平权喂进 reader, 每篇带权重 $p(z_i|x)$ 。 $\partial L / \partial p(z_i|x)$ 的形式: **reader** 表现比平均好的文档, 检索权重被上调; 差的下调。 这就是 retriever 隐式学到的东西 —— 没有显式 label, 监督藏在"哪篇让 $p(y|x)$ 高"里。

三、我的方案 vs REALM 的方案(推导中分岔出的另一条真实路线)

推导中途冒出一条自己的路线, 和 REALM 不同, 值得记:

我的路线(两阶段、显式伪标签): 1. 梯度更新 z 到收敛 $\rightarrow$ 理想文档向量 z' 2. 在 corpus 里找 z' 的最近邻真实文档 z 3. z 当正样本 label $\rightarrow$ 对比学习训双塔(query=x, positive= z^* , 其余为负) 4. 编码器学好 $\rightarrow$ 所有 x 受益

这条路能走, 而且是真实存在的分支 —— 接近 DPR / 用下游信号 distill retriever 那一支, 不是 REALM。 等于独立重新发明了 hard-negative mining。 - 优点: 用"最近邻找一篇当 label" 绕过全库 softmax, 便宜 - 软肋: z' 是"理想", corpus 是"现实", z' 落在文档分布空隙时, 最近邻 z 可能不 relevant $\rightarrow$ 投影噪声*(连续理想 $\rightarrow$ 离散真实的投影误差)

REALM 的路线(端到端、隐式监督): - 不造 label、不更新文档 z、不用 sigmoid 独立打分 - softmax over top-k + 对期望 Σ 直接求导, 一个 loss 一次反传, 同时训 reader 和 retriever - 干净, 但要付 top-k 近似 + 异步索引的工程代价

一句话对比: || 我的路线 | REALM | |---|---|---| | 监督 | 显式伪标签(z^*) | 隐式(藏在 Σ 里) | | 梯度作用 | 先动文档 z 再最近邻 | 动检索概率 $\rightarrow$ 双塔参数 | | 阶段 | 两阶段(造 label + 训) | 端到端一个 loss | | 离散处理 | 最近邻投影(有噪声) | 全库期望的 top-k 截断 | | 成本 | 便宜 | 贵 |

能看出"我推的 $\neq$ REALM"这件事本身, 说明两条路都摸到了, 且知道分岔点在于 离散怎么处理: 投影 vs 全库期

望。

四、REALM vs RAG:机制与实验

机制区别

- **REALM**:预训练阶段端到端训 retriever(MLM 信号),下游 fine-tune 时 retriever 冻结
- **RAG (Lewis 2020)**:用预训练好的 DPR retriever,只做部分端到端微调,reader 用 BART(生成式);更省算力、有开源代码
- **现代 RAG(工业界)**:退化成 —— 冻结 embedding 检索 + 冻结大 LLM + 推理时拼进 prompt。最简单最便宜,数学上最"糙",流行因为便宜/模块化/可更新
- **RETRO (2022)**:另一条 —— 靠 chunked cross-attention 融合检索,retriever 冻结。(注意:检索文档进模型的方式,REALM 是"拼接+概率边缘化",RETRO 是"cross-attention"; 我一开始把两者特征交叉了 —— REALM 不靠 attention 融合,靠概率加权)

直接可比的实验(2020 同期)

数据集	REALM	RAG
Natural Questions	40.4	44.5
WebQuestions	40.7	45.2
TriviaQA	~55	56.8

结论:同期直接比,**RAG** 略优或持平,**REALM** 没兑现理论优势。 原因不是理论错,是那篇的实现让优势发挥不出来: 1. RAG 用更强的生成器(BART),REALM 是抽取式、reader 更弱 2. REALM 下游 fine-tune 时 retriever 冻结,端到端优势没用上 3. 通用域(Wikipedia),通用 retriever 已够好,联合训练边际收益本来就小

理论优势要到后续工作才被兑现

- **Sachan et al. 2021**(全程端到端训 retriever):答案抽取比 REALM 和 RAG 都高 **3+** 点, top-20 检索准确率比 DPR 高 5 点 → 证实"把 retriever 纳入目标一起优化确实更好"
- **RAG-end2end (Siriwardhana 2022, TACL)**:专测换域(COVID/News/对话)。 联合训 retriever + 更新索引 比原始 RAG 显著提升;只更新 query encoder 不更新库编码会掉分 → 证实"cross-domain 时 retriever 极度需要对齐,联合训练价值回来"
- **RARE (2026)** 按域拆 RAG 相对纯参数的增益: General-Wiki +7.1 / Finance +13.5 / Legal +19.7 / Patent +33.4 → 越是参数化知识覆盖不到的专业域,检索边际收益越大

五、我对"REALM 理论上更优"的判断,以及被实验证实

我的判断: 把 retrieval 当变量纳入目标函数一起优化,从概率角度更贴近真实值、泛化理论上更好;RAG 是把 retrieval 当固定外部步骤的近似替代版。

修正的前提(必须挂上): "更优"的大小取决于 **retriever** 有多需要为下游/领域专门对齐。 - 通用域:通用 retriever 已够好 → 联合优化边际收益小 → 被工程成本吃掉(所以 2020 RAG 追平) - 专业域/换域:对齐需求大 → 联合训练优势显著(Sachan/RAG-end2end/RARE 证实)

为什么现代退到更糙的 RAG,有两个驱动力(不只工程): (a) 工程成本(全库 softmax + 异步索引太重) (b) 参数化 **scaling** 太成功 —— 大模型证明知识 scale 进参数效果极好,削弱了"必须端到端训练检索"的必要性 → 演化方向:越来越糙但越来越实用。数学漂亮 ≠ 该用; 当 scaling 能用更笨的办法达到相近效果,漂亮的那个被搁置。

六、RAP 提案评估(在 REALM 基础上做 cross-modal)

提案主张:预训练数据规模决定模型能力,但很多科学领域(医疗/生命科学/时间序列/气候/材料) 缺乏"自然语言级规模"的数据。用 RAP(检索增强预训练)打破"能力 $\propto$ 数据规模"的依赖。 验证场景:结构化 EHR 为预训练模态 + 生物医学文本为检索语料。

提案 framing 的聪明处

把"RAP 一直被忽视"重新解释为:它被忽视是因为大家只在 RAG 也能做的地方(同模态、数据富足)试它。真正的空白在 **数据稀缺 + 跨模态 + 未对齐** —— 那里 RAG 三个前提 (同模态、天然对齐、可互换作输入)全不成立,RAP 才有独占价值。

我推出的三格分析(把 RAG/RAP 的适用边界切清楚)

场景	能做吗	RAP 有必要吗	提案的机会
同模态(cross-domain)	直接加数据/RAG 就行	没必要	无
跨模态已对齐(图文,有 CLIP)	多模态 RAG 能做	没必要(RAG 够)	无
跨模态未对齐(EHR→文本,无配对)	没人验证过	有必要(RAG 做不了)	有,但缺证据

核心两难:有必要性的地方(未对齐)恰恰缺可行性证据;有可行性证据的地方(已对齐) 恰恰没必要性。这两个条件在现有工作里从未同时满足。

提案的几个真问题(评审会戳)

- RETRO** 类比方向反了:提案拿 RETRO"省一个数量级数据"当证据,但 RETRO 恰恰 冻结 **retriever**,没做提案主打的"联合训练 embedding"。RETRO 省数据正因为它不做那件贵的事。

2. "数量级提升"缺机制:REALM 相对 RAG 原论文是 4-16% 绝对准确率,不是数量级。跨域可能更大,但"数量级"要机制论证,不能从"理论更优"推出。
3. 计算成本自相矛盾:把"高成本"列为 RAP 没人做的原因,又承诺"解决计算挑战"但没给 how; 而跨模态联合训练只会更贵。
4. 验证场景偏软:EHR+文本语义高度相关,是最容易被"直接抽成结构化知识吸收进参数"反驳的场景。(但见下方 —— 从对齐角度看,这个"相关"反而是优势)

关键质疑链(我逐步逼出的)

- **Q:检索语料够大、训练数据少,为啥不直接放进训练数据、多此一举加检索?** A:同模态成立(直接加即可,RAP 多余)。跨模态时"检索语料不能当训练样本"是 RAP 唯一辩护 —— 但提案没论证"检索"为何优于"蒸馏进参数"。而且检索库若够大到支撑数量级提升,它本身就是"数据",区别只在"不同模态、不能直接当训练样本"。整个提案的成立完全依赖这个前提。
- **Q:多模态 LLM 本身吃图+文,检索一张图喂进去不就是跨模态 RAG 吗?** A:对。多模态 RAG 已能跨模态检索。所以提案 (a)同模态、(c)可互换 两条前提被证伪,真正站得住的只剩 (b)天然对齐。RAG(哪怕多模态)默认检索源和 query 在已对齐空间(CLIP); 提案要的是未对齐跨模态 —— 这才是唯一的空白。scope 必须收窄到"未对齐跨模态"。

warm-start:从"命门"到"有方案的步骤"(最关键的一转)

一开始我判断 warm-start(冷启动对齐)是命门:未对齐 + 无配对数据 → retriever 冷启动 不知道 EHR 该检索哪段文本 → 联合优化梯度是噪声 → 可能收敛到假对齐。

但这个判断太绝对,被一个反驳修正:对齐不必预先存在,训练过程本身能学出对齐,最简单就是嵌一个 **CLIP** 式对比学习。CLIP 本身就是证明 —— 图文一开始也不对齐,是在 4 亿图文对上对比学习训出来的。

修正后的准确判断: - warm-start 不是"能不能做",是"用什么信号 **bootstrap** 对齐" - **EHR-文本有弱配对信号**:每条 EHR 挂着 ICD 码、用药、检验值,可映射到医学本体 (UMLS/SNOMED)和对应文献 → 对齐信号非零 - 所以"EHR+文本语义高度相关"(前面当软肋)反而是优势 —— 配对信号存在,CLIP-式 warm-start 可行 - 具体方案应写成:先用结构化码 + 医学本体做弱监督,跑 **CLIP** 式对比预训练得初始对齐,再进入 **RAP** 端到端联合训练精调

这一转把提案从"赌一个没被验证的难题"改成"组合两个成熟技术(**CLIP** 对齐 + **REALM** 端到端)用在结构化医疗数据"。可行性评估完全不同 —— 后者是接现成零件,可行得多。"为什么没人做"的答案也随之变化:可能不是做不出来,是没人把这两条线接起来用在 EHR。novelty 在于组合 + 应用域,不是从零解一个死题。

多模态到底有没有直接结论

- 已对齐多模态(图文):有结论,能做 —— 但那格 RAG 就够,轮不到 RAP
- 未对齐跨模态 RAP(EHR→文本,端到端联合训 retriever):没有直接结论,是提案声称的空白
- 注意:不能拿 cross-domain(文本→文本)的实验成功给未对齐 cross-modal 背书 —— 前者对齐免费/预先

存在,后者对齐是要解决的问题本身。两者难点性质不同。

- "没结论 $\neq$ 有机会":要先排除"没人做是因为做不出来"。用 CLIP-warm-start 这个方案,倾向于"是真空白 + 可行",但仍需彻底文献检索来支撑 novelty claim。

七、一页纸结论

1. **REALM** 数学更完备:端到端把 retriever 纳入目标,梯度经检索概率反传(不经文档 embedding, 不靠 attention)。理论上更贴近真实、泛化更好 —— 但前提是"retriever 需要为下游对齐"。
2. **2020** 同期实测 **RAG** 略优 —— 因 REALM 那篇的实现(下游冻结 retriever、reader 弱、通用域) 没兑现理论优势。优势要到后续全端到端(Sachan 2021)和换域工作(RAG-end2end/RARE)才被证实。
3. 现代退到更糙的 **RAG**:工程成本 + 参数化 scaling 太成功,两个原因共同削弱了端到端的必要性。
4. **RAP** 提案:framing 和 gap 找得准,唯一有独占价值的是"未对齐跨模态"这一格。命门 warm-start 一开始看似死穴,但"嵌 CLIP-式弱监督对齐做 bootstrap"把它变成有方案的步骤 —— 提案本质从"解死题"变"组合成熟零件(CLIP + REALM)用在 EHR"。 仍需补:把 scope 收窄到未对齐跨模态、把 warm-start 写成 CLIP 具体方案、给"数量级"机制或降级、做彻底文献检索坐实空白。

(推导贯穿的一个方法论:分清"观察到什么"和"能推出什么" —— 高 AUROC/理论更优只是相关或潜力,兑现要看实现和实验; 连续理想投影到离散真实必有噪声;必要性和可行性要分别论证,不能互相借。)