

RL Learning · 强化学习

Part 2 — RL 诊断案例集 / RL Diagnosis Casebook

五道诊断题的完整 back-and-forth · 含走过的弯路、被纠正的误诊、追到根的过程

怎么读这份案例集。 每道题不只给「标准答案」,而是还原真实的诊断过程:初诊(常常是错的或不完整的)→ 被 challenge → 纠错 → 追到根。诊断能力不是背结论,是能在自己答错时看见哪里错了。所以那些「一开始答歪、后来扶正」的地方,恰恰是最该看的。每道题的结构:场景 → 症状 → 初诊与弯路 → 纠错过程 → 定位判据 → 修法 → 回旋镖(修法可能引入的新问题)。

目录

0 诊断总纲:四层轴 + 现场话术

Q1 数据中心冷却 — 目标错(reward misspecification)

Q2 机械臂插孔 — 稀疏 reward(探索够不到信号)

Q3 迷宫导航 — 表征过拟合(局部视觉死记)

Q4 自动驾驶 BC — 闭环错配(开环训、闭环用)

Q5 长局游戏 — credit assignment(delayed reward)

附 δ 与 A 的完整数学(tower rule / Bellman 展开)

0 诊断总纲

一个 learning 系统 = 目标 (reward/loss) $\times$ 容量 (model class) $\times$ 数据/环境 $\times$ 优化。跑歪了,就是这四层之一(或耦合)。诊断的核心技能是快速定位在哪一层——四层的修法完全不同,而且极易误诊。

现场话术(遇到「模型行为很奇怪」,别跳修法,按顺序问出声):

1. 它是学歪了还是没学到?(歪 vs 空)
2. 如果学歪,它是不是完美优化了我写的目标?($\rightarrow$ reward 错,不是模型错)
3. 训练误差降了吗?(没降 $\rightarrow$ 容量/优化;降了但行为怪 $\rightarrow$ 目标/数据)
4. 这个 hack 在训练分布里 reward 真的更高吗?(是 $\rightarrow$ spec gaming,改 spec)
5. 它利用的是真实信号还是环境/评测的 bug?

核心洞察:优化器永远是对的,精确给你要的东西。模型「学歪」几乎从不是模型的错,是目标/环境/数据留了缝。第一反应审计 spec,不是加容量。

Q1 数据中心冷却 — 目标错

场景

RL agent 控制数据中心冷却。action = 调各机组制冷功率, reward = -(总能耗), 目标省电。硬约束: 任何机柜温度超过 $T_{\max}$ 给大负 reward - M。

症状

训练曲线漂亮, 比人工基线省 18% 电。压力测试发现: agent 大部分时段把制冷压到近零, 只在温度即将触顶前一刻猛开、贴着 $T_{\max}$ 反复横跳。能耗低, 但机组频繁急启急停, 缩短硬件寿命。

初诊与弯路

第一反应容易说成「模型学歪了, 要加个惩罚项」。这里有两处会被 challenge:

- 「模型学歪」这个定性错了轴。agent 精确、诚实地最大化了 - 能耗, 贴顶横跳真的能耗最低——它优化对了, 没歪。说「学歪」会让你去修模型; 真相是目标漏了(没写硬件寿命/安全裕度), 该去修 reward。这个区分是方向性的, 搞反了修法全错。(顺带: 贴顶横跳不是「鞍点」——它是 reward 认可的近最优策略, 叫 reward 与 intent 的 gap, 不是鞍点。)
- 「加温度变化率平缓项」罚错了对象。工程师担心的是压缩机急启急停, 那是 action(功率指令)在抖, 不是温度在抖。该罚 action smoothness $\|a_t - a_{t-1}\|$ 。(在功率-温度强耦合的健康设备上, 罚温度也能间接传导——但罚 action 更直接、更少依赖「耦合健康」这个前提。这是 robustness 取舍, 不是对错。)

纠错过程: 表象 vs 病根

就算把 smoothness 加对了(罚 action), 也不够——这是最容易漏的一层:

「横跳」只是表象, 病根是「贴着 $T_{\max}$ 运行」。加了 action-smoothness 后, agent 的新策略几乎必然是平滑地、稳稳地常年贴着 $T_{\max}$ 跑: 不横跳了(躲过 smoothness 罚), 能耗还是最低(还在贴顶省电), 但机组常年顶格、零安全裕度, 任何扰动一冲就超温。你治了横跳, 没治贴顶, 还治出个更隐蔽的版本。

定位与判据

层: 目标错(reward misspecification)。判据: agent 没有「学不到」(它训练表现很好), 也不是容量/优化问题(误差降得很好); 它学到了一个高 reward 但坏的策略, 而这个策略真的最大化了写下的 reward——这是「目标漏了」的指纹。

修法(分三层, 缺一不可)

1. action smoothness - $\lambda_1 \|a_t - a_{t-1}\|$: 治急启急停(表象)。
2. soft barrier / 带 buffer 的软上界: 治「贴顶」(病根)。核心是把悬崖换成斜坡——别用「超 $T_{\max}$ 才罚」的悬崖式 reward, 改成温度越接近 $T_{\max}$ 越早、越平滑地递增惩罚, 从结构上消除「贴临界最优」这个激励。

3. 对每个新项再问一遍新缝: λ 太大 $\rightarrow$ agent 过度保守、制冷常开、省电目标废掉(从一个极端滑到另一个)。 λ 的平衡本身是新的攻击面。

回旋镖 / 收口

悬崖式 reward(-M 硬阈值)是万恶之源——它制造「只要不超线,越贴越赚」的激励,agent 必然贴线。真正的治本不是往上打补丁,是改 reward 的形状(悬崖 $\rightarrow$ 斜坡)。smoothness 是治标,soft barrier 是治本。诊断的分水岭:能不能在纸面上预判「加一个项会催生什么新 hack」——「贴顶」这个新缝是纯逻辑推得出的,不用上线看数据。

Q2 机械臂插孔 — 稀疏 reward

场景

机械臂多阶段任务:(a) 走到零件前 $\rightarrow$ (b) 抓起 $\rightarrow$ (c) 插进插槽。reward 只在**成功插入**时给 +1,其余全程 0。用标准 PPO 训。

症状

训了很久,agent 稳定走到零件前就**停住不动**,反复微调姿态,从不尝试抓取。reward 曲线一直是 0,没有任何上升。

初诊与关键澄清

直觉:「每个阶段都需要反馈,只有最后有 reward,搜索空间过大」——方向对。但归类时有个**致命误判**要避免:

不是「训练数据不全」。这是 RL 和监督学习的根本区别:

- 监督学习:数据外部给定、静态,「数据不全」 $\rightarrow$ 去**收集更多数据**。
- RL:agent **自己生成数据**,它不缺交互机会——它每天跑无数条轨迹。它缺的是**有信号的数据**:所有轨迹 reward 都是 0,跑再多还是全零。

所以准确性是:agent 能生成海量数据,但数据里不含有效学习信号(reward 恒零,探索碰不到那**唯一的 +1**)。诊断成「数据不全」会引向「搞更多数据」(错路,RL 不缺数据);诊断成「有数据但无信号」才引向「帮探索够到稀疏信号」(对路)。

还有一处措辞要拧:说「数据不存在」也不对——**数据海量存在,不存在的是有效信号**。「数据不存在」引向搞数据(错),「有数据无信号」引向帮探索(对)。

定位与判据

层:探索-信号层。判据:**reward 曲线恒零 + agent 卡死不动 = 「没起步」的指纹**,不是「学歪」的指纹。目标没错(成功插入给 +1 是对的),reward 结构没歪,是信号太稀、太远,探索碰不到第一个正反馈,梯度长期为零。不是容量问题(不是模型装不下解,是没拿到能学的信号)。

Q1 vs Q2:歪 vs 空(这个区别帮你定位)

- Q1:数据有意义但意义是错的(agent 学到歪策略,reward 非零且被坏行为拿到)→ 目标层,改 reward。
- Q2:数据没意义(全零,因为稀疏),agent 啥都没学到 → 探索层,帮探索/加信号。

区别 = 「有信号但错」vs 「根本没信号」= 歪 vs 空。看到学歪往 reward 编码查,看到恒零卡死往稀疏/探索查。注意:Q2 里「没意义」的具体原因就是稀疏(症状恒零锁死了它);别用「RL 数据多但可能没用」这种一般原理去冲淡这道题的具体诊断。

修法(一类,不止一种)

把稀疏变稠密 / 助力探索:reward shaping(加中间信号)、intrinsic / curiosity(给探索到新状态发奖)、demonstration / imitation warm-start(示范暖启动)、curriculum(先训简单版)。别只说「每阶段加反馈」——那只是 shaping 一种,收窄早了。

回旋镖

reward shaping 一加,各阶段 reward 权重怎么配就成了新的攻击面:配不好,agent 可能只刷好拿分的中间阶段(反复走到零件前拿「接近奖励」却永不抓取),把 shaping 信号本身变成新 hack。解决稀疏(Q2)引入的 shaping,可能制造新的 misspec(Q1)。正规解法:potential-based shaping(可证不改变最优策略)。

Q3 迷宫导航 — 表征过拟合

场景

agent 玩迷宫导航。状态 = agent 当前位置的第一人称视觉图像(像素),动作 = 上下左右。reward = 到达终点 +1、每步 -0.01(鼓励快)。PPO + 一个 CNN 编码图像。

症状

agent 在训练迷宫上表现很好,稳定找到终点。换一个新迷宫(布局不同,视觉风格一样)就完全迷路,performance 掉到接近随机。训练 reward 一路涨得好,无异常。

先厘清 setup(诊断前必须钉清的几个概念)

诊断前把 reward / transition / value 分清,否则诊断会歪:

- reward 是环境写死的规则(终点+1、每步-0.01),不是学出来的、不是现算的。这跟 RLHF 不同(那里要训 reward model,因为「人类偏好」没现成公式);这里环境直接给,无需 reward model。
- 「撞墙不能走」是 transition $P(s' | s, a)$ (环境不让穿墙,状态不变),不是 reward。可以额外给撞墙一个负 reward,但那是设计选择;「撞墙原地不动」本身是 transition 规则。
- $V(s)$ 是多步 value(这题要走很多步才到终点),用 critic 网络 $V_{\phi}(s)$ 估,回归实际累积回报。但 V 怎么估和这题诊断无关——症状是「训练好新迷宫崩」,不是 value 估不准。别被 V 带偏。

关键 setup 澄清:第一人称局部,不是全局(这里反复踩坑)

状态是 agent 眼前看到的局部图像,agent 看不到全局迷宫。这一点极易记反成「全局俯视图+坐标」。记反了因果链就全错:

- **✗** 错版本:「有全局信息 → 记住全局迷宫特点 → 换迷宫作废」(没有全局信息,不成立)。
- **✓** 对版本:「只有局部第一人称视觉 → agent 没学会导航,而是把「视觉线索→动作」死记硬背(看到这面红墙就右转、这个纹理就直走)→ 换迷宫,视觉线索变了、背的映射失效 → 迷路」。

过拟合的是训练迷宫的视觉表面,不是全局结构。

CNN 的位置:policy 和 value 共享(另一处易错)

不是「全局 CNN」,也不是「CNN 只在 value 用」。标准做法(状态是图像时):

局部图像 → [CNN backbone] → 特征向量 h

└→ [policy head] → 动作概率 $\pi(a|s)$

└→ [value head] → $V(s)$

CNN backbone 被 **policy** 和 **value** 共享,上面分两个头。这个共享结构正是病灶所在:如果共享 CNN 学到的表征只记住了训练迷宫的表面视觉特征,policy head 和 value head 会一起废——两个头都建立在那个不泛化的特征 h 上。病根在共享 CNN 表征,不在某一个头。

不是 feature engineering,是 representation learning 失败

一个自然的追问:「正常不该这么脆吧?是不是 feature engineering 没做好?」——方向(想追更细机制)对,但用词错:

- 深度 RL 不做手工 feature engineering——CNN 的卖点就是自动从像素学特征。所以问题不是「特征工程没做好」,是 **CNN 自动学到的表征(representation)不可迁移**。
- 不是「某个权重过大」,是整个表征学歪了方向:它学的是「记住这个迷宫长什么样」,而非「理解空间结构怎么导航」。

定位、判据、根因

层:表征/泛化层。判据:训练好 + 新迷宫崩 = 学到的东西不泛化 = 表征过拟合。不是目标层(reward 没错)、不是探索层(它明明学到了东西、训练迷宫表现好)。

根因:训练分布太窄(只有训练迷宫)+ 没有泛化压力。死记训练迷宫的视觉就能刷满 reward,CNN 没有动力学可迁移表征——死记是最省力的解。不是特征工程、不是权重大小,是训练分布单一让表征过拟合成了最省力解。

RL 里「训练好测试崩」的两个根因

同一症状在 RL 里可能是两个不同的病(容易一口咬定「过拟合」而漏掉第二个):

1. 表征过拟合(本题主因):CNN 记住训练迷宫视觉特征,感知不泛化(看到新图认不出该干嘛)。这是监督学习也有的经典过拟合。

2. **policy 背动作序列**(RL 特有的次要变体):agent 可能学成一串对训练迷宫特定布局的**固定动作序列**(「先左三步再右两步」),**策略不泛化**(压根没学「根据看到什么决定动作」,学的是盲背套路)。

修法不同:第一个修表征(数据增强、domain randomization、更强 encoder);第二个修策略学习(程序化生成大量迷宫,防背套路)。

修法

给它泛化压力。 核心:**domain randomization**——程序化生成大量不同迷宫训练。见的迷宫多了,死记不再是最省力解,CNN 被逼着学「通用导航」而非「记住某个迷宫」。外加数据增强(随机化视觉风格、光照)让表征对表面变化鲁棒。

与 Q4 的分界(先埋一句)

Q3 是**静态泛化**:换环境(真的换了地图)就崩,分布差是**外生**的。下一题 Q4 是**动态复合**:同一环境、沿时间自我放大。别把两者都笼统叫「泛化」。

Q4 自动驾驶 BC — 闭环错配

场景

简化版自动驾驶。状态 = 前方摄像头图像,动作 = 方向盘转角。用**模仿学习 warm-start**:先收集大量人类司机数据 $(s, a_{\text{人类}})$,监督学习让 policy 模仿人类动作(behavior cloning),再上 RL 微调。

症状

BC 阶段验证集上**动作预测准得很**(预测转角和人类几乎一致,loss 很低)。但一让 policy **真的去开**(闭环),车开着开着慢慢偏离车道中心,越偏越远,最后冲出路面——哪怕道路笔直、训练见过无数次。

初诊:类比 A/B test 上线崩(对了一半)

直觉:「和选模型 A/B、上线效果差一样,验证集和实际情况有差别」——大框对(离线好、在线崩 = 分布错配),但漏了 RL 那层「自己制造差别」的要害:

两种分布错配,机制不同:

- **普通漂移 / A/B(被动)**:分布变了是**外部世界变了**(用户变、季节变),模型是受害者,没参与制造漂移。
- **Q4 闭环错配(主动,RL 特有)**:BC 的验证集里状态全是人类开出来的(人类始终在车道中心,所以训练状态都是「车在中心」)。但 policy 自己开时,动作有微小误差 → 车略微偏离 → 面对一个训练集里从没出现的状态 → 预测更差 → 偏更多 → 状态更陌生 → 误差滚雪球 → 冲出路面。

这个分布错配不是外部世界变了,是 policy 自己的动作把自己带进了训练集没覆盖的状态。 是 agent 主动制造的分佈漂移(covariate shift / compounding error),不是被动遇到的。监督学习没有这个——样本 iid,单个预测错了不影响下一个输入;闭环里这一步的错**改变了**下一步的输入。

纠错一：「验证集不好」吗？——不，是原理性盲区

一个利落的反驳：「连车开偏这种状态都没验证，是验证集没做好」——结论下反了：

那些偏离状态，在收集数据时根本不存在，不是「没放进验证集」，是「造不出来」。BC 数据来自人类司机，人类始终把车保持在中心，不会故意开偏再纠回来给你采样。所以人类数据里天然没有「车已经偏了」这种状态；从同一批人类数据切出的验证集，也全是「车在中心」→ 和训练集同分布 → 验证集预测准是「真的准」，它没骗你。

不是验证集偷懒，是任何离线验证在闭环任务里都有原理性盲区——policy 自造的状态，数据收集阶段造不出来。这不是工程没做好，是闭环 vs 开环的本质鸿沟。要覆盖那些状态，不是改验证集，是改数据收集方式(DAgger: 让 policy 自己开产生偏离状态，再问人类「这里怎么救」)。

纠错二：「这么敏感？不是全部吧」——对，是三因叠加

怀疑「车偏一点属于泛化问题，真这么敏感？」——直觉对，单一「没覆盖」解释不了雪崩。真实的崩是三个叠加：

1. (a) 分布外 + 泛化有限: 偏一点，网络还能勉强外推，预测略差。单独不致命。
2. (b) 闭环复合 —— 雪崩的引擎: 关键不是「偏一点预测差一点」，是这个差一点的动作让车偏得更多 → 下一步状态更陌生 → 预测更差 → 偏更多。误差每步喂给下一步、正反馈放大，小误差被闭环递归成指数发散。这是监督学习没有的。
3. (c) 无纠偏样本: 人类数据里没有「我开偏了、打方向盘救回来」的纠正动作(人类不偏，所以没纠偏样本)。policy 偏了不知道怎么救，只能继续偏。

三个叠加才雪崩: (b) 是引擎, (a)(c) 供燃料。单独任何一个都不至于冲出路面。

纠错三：「这训练/验证都是监督学习，不算 RL」——对，而这正是重点

behavior cloning 段就是纯监督学习(输入状态、拟合人类动作，没 reward、没环境交互、没 policy gradient)。「policy 怎么部署」的解: 监督学出来的网络本身就是 policy，放上车闭环跑就是部署。同一个网络，两种运行模式：

- 训练(开环): s 来自人类数据集(固定)，每个预测独立，iid，验证集准。
- 部署(闭环): s 来自车的实际状态，而状态被上一步的动作决定， π 的输出变成下一步的输入，误差累积。

病根就是「开环训、闭环用」的模式错配——比「分布不一致」更底层: 分布不一致是结果，运行模式不一致(开环 vs 闭环)是原因。

定位与最终收口:这不是 RL 的失败,是没用 RL 导致的失败

层:分布漂移 / 闭环错配(方法与问题的性质错配)。判据:离线指标好、在线崩,而且在训练见过无数次的直路上、沿时间累积才崩(不是换环境就崩,那是 Q3)。

最终结论(面试可直接说):这不是 RL 的失败,恰恰是没用 RL 导致的失败。BC 是开环监督学习,而驾驶是闭环序列决策任务(policy 的动作改变它未来遇到的状态)。方法的假设(iid、开环)和任务的性质(非iid、闭环)错配,才有 covariate shift 和复合误差。这题反证了 RL 在序列决策上不可被监督学习替代的价值:RL 天生闭环,训练过程本身就经历「我的动作改变我的下一个状态」。

修法:让训练也变闭环

- DAgger:让 policy 自己开(产生偏离状态)→ 问人类「这个偏离状态该怎么救」→ 把「policy 自造状态 + 人类纠正动作」加进训练。不用 RL,但把数据收集从开环变闭环。
- RL 微调:policy 自己开、从环境 reward 学,天然经历闭环,学会纠偏。

Q3 vs Q4 分界(钉死)

Q3(静态泛化):换了世界(真的换地图),分布差外生 → 修表征泛化(domain randomization)。

Q4(动态复合):同一条直路,policy 自己把自己带偏,分布差内生、沿时间复合 → 修「让训练闭环」(DAgger / RL)。

Q3 是「换了世界」(外生),Q4 是「自己把自己带偏」(内生、闭环复合)。

Q5 长局游戏 — credit assignment(delayed reward)

场景

一局很长的策略游戏(200 步)。reward 只在游戏结束时给:赢 +1、输 -1,中间 199 步全是 0。PPO + GAE 训。

症状

agent 能慢慢学(胜率 50%→60%),但极慢、极不稳定,胜率曲线剧烈震荡。诊断发现 agent 经常把功劳/责任归错步:某局赢了,+1 的信用被平摊或错配给一些无关的中间动作(甚至开局随机走子),而真正的关键决策(第 150 步妙手)反而没被强化。

Q2 vs Q5:两个不同的「稀疏」病

Q2 和 Q5 都是「稀疏 reward」,但病不一样:

- Q2:稀疏到探索碰不到那个 +1,信号根本拿不到 → 学不出来(reward 恒零)。
- Q5:信号拿得到(能到结尾,胜率在涨),但 delay 太久 + horizon 太长,没法准确归因到该负责的一步 → 学得出来但慢且错配。

一个是「够不到信号」,一个是「够到了但分不清谁的功劳」。

初诊:病在 value 网络(方向对,机制要补)

直觉:「能收敛说明 value 有用,不然学不动;问题应该是 value 让某些状态分数变奇怪、没学对」——**方向对**(病灶在 V 估不准),但要说清机制。

信用怎么从第 200 步的 +1 传回第 150 步的妙手?全靠 value 网络当中继。中间步 $r_t = 0$, 所以

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t) = \gamma V(s_{t+1}) - V(s_t)$$

信用完全由**相邻状态的 value 差**决定。要让妙手拿到信用,必须 $V(\text{妙手后}) > V(\text{妙手前})$, 即 value 网络得看得出「这步让局面变好了」。

纠错:不是「本步动作信号没了」,是信号全靠 V 传、而 V 估不准

一个易犯的说法:「 δ_t 把 action 和未来 state 平均了,本步动作的强化/减弱信号没了」——反了。

- $\gamma V(s_{t+1})$ 里, s_{t+1} 是这一步动作 a_t 实际导致的下一状态,所以**本步动作的信号没丢,它藏在「你到了哪个 s_{t+1} 」里**:好动作 $\rightarrow$ 好 s_{t+1} (高 V) $\rightarrow \delta_t > 0 \rightarrow$ 被强化;坏动作 $\rightarrow$ 差 $s_{t+1} \rightarrow \delta_t < 0 \rightarrow$ 被减弱。

真正的病:中间步无真实 reward 锚定,信号全托给 V_ϕ ;长 horizon 下 V_ϕ 估不准, δ_t 失真 $\rightarrow$ 错配。

那个 +1 要穿 200 步、经 $(\gamma\lambda)^{50}$ 衰减才传到第 150 步,衰减+噪声让信号到中间步时已很弱很糊; V_ϕ 于是把「赢」这个结果**统计性地平摊**给沿途所有状态(相关性误当因果),关键步反而没被识别。

为什么「平摊」+ 为什么震荡:GAE 的 bias-variance 两难

梯度是 $\sum_t \delta_t \nabla \log \pi(a_t|s_t)$ (小 λ 时)。 δ_t 是每个动作的权重。 V_ϕ 估歪 $\rightarrow$ 权重歪 $\rightarrow$ 无关动作被赋正权重(强化)、妙手被赋近零权重(没强化)= 归因错配。而中间步 $\delta_t = \gamma V(s_{t+1}) - V(s_t)$ 都是小量噪声差(真实 reward 是 0,全靠 V 估计抖动),**信噪比极低** $\rightarrow$ 梯度方向被噪声主导 $\rightarrow$ 震荡。

GAE 的 λ 陷入两难:

- λ 小(偏 TD,靠 V_ϕ): V_ϕ 估不准 $\rightarrow \delta_t$ 偏 $\rightarrow$ 信用错配。
- λ 大(偏 MC,靠实际回报):不碰 V_ϕ 但 200 步回报**方差爆炸** $\rightarrow$ 训练震荡。

长 horizon + 稀疏 reward 把 GAE 逼到两难:要么 bias(错配),要么 variance(震荡)。症状里「慢+震荡+错配」正是这个两难的表现。

定位与判据

层:credit assignment / delayed reward。判据:**reward 不是稀疏得学不出来(Q2 那种恒零),而是学得出来、只是慢且错配**——胜率在缓慢爬升(信用多少传对了一点),但曲线剧烈震荡、信用平摊到无关步。这指向「信号能拿到,但传信号的中继(V_ϕ) 在长 horizon 下估不准,把信用配错步」。

修法(两个思路,a 治根)

a(reward shaping / 加密中间 reward)—— **更治根**: 病根是中间步 $r_t = 0$, 导致 δ_t 纯靠 V 估计的差、无真实信号锚定。a 直接往中间步注入真实 reward(如「吃子+小分、占要地+小分」), 让 $r_t \neq 0, \delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ 有真实锚 $\rightarrow$ 归因不再纯靠估不准的 V 。「**reward=0 是根, 那就让 reward $\neq 0$** 」——直接命中。

b(改进传播 / 缩短 horizon)—— **不治根**: 无论怎么改进传播(大 λ 、更好的 V_ϕ 、hierarchical), 中间步 reward 还是 0, 信号本质上还是稀疏、还要跨长距离传。大 λ 绕过 V_ϕ 又带来方差爆炸(还是震荡)。b 在和病根搏斗, a 直接消除病根。

(注: 否定 b 的正确理由是「不治根」, 不是「不知道 horizon」——「改进传播」是纯算法层, 不需要知道 horizon; 「缩短 horizon」才需要领域知识切任务。这两个别混着否定。)

回旋镖: a 会引入 Q1 式 misspec

reward shaping 一加, 权重怎么配就成了新的攻击面(接回 Q1): 中间 reward 配不好, agent 可能只刷好拿的中间分(反复吃子拿小分)却不追求最终胜利, 把 shaping 信号本身变成新 hack。a 治了 Q5(credit assignment), 但可能引入 Q1(reward misspec)。

正解: **potential-based reward shaping**——用 $F(s, s') = \gamma \Phi(s') - \Phi(s)$ 形式的 shaping, 可证明不改变最优策略, 只加速学习。这是唯一能「加密 reward 又不引入新 hack」的方式。面试答 a 时加这一句, 滴水不漏。

附 δ 与 A 的完整数学(back-and-forth 追到底)

Q5 的核心是搞清 TD 残差 δ_t 和 advantage A_t 到底差在哪。这一节把「都是期望啊、差别在哪」追到代数底。

先分清三个量: reward / Q / V

- r_t (reward): 即时、单步的分, 环境当场给。中间步 $r_t = 0$ 、结尾 ± 1 。
- $Q(s, a)$: 从 s 出发、这一步强制选动作 a 、之后按 policy 走, 一路到底的期望总回报。Q 不是 reward——reward 只是 Q 的第一项: $Q = r_t + \gamma(\text{之后})$ 。
- $V(s)$: 从 s 出发、对动作按 policy 平均、一路到底的期望总回报。

Q 和 V 唯一的区别: 第一步定不定动作。关系: $V(s) = \sum_a \pi(a|s) Q(s, a) = E_{a \sim \pi}[Q(s, a)]$ 。

为什么 Q 必须「到底」不能是单步 reward: 妙手的 reward 也是 0, 但它的价值在于「导向了结尾的 +1」——这个「导向未来的价值」只有到底的 Q 抓得住。若 Q 只是 reward, 中间步 advantage 全是 0, agent 永远学不到中间决策。

advantage 与 δ 的定义

$$A_t = O(s_t, a_t) - V(s_t)$$

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

展开 $Q:A_t = E[r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots | s_t, a_t] - V(s_t)$ 。

差别的精确位置(从第 $t + 1$ 步往后):

- A_t 用真实的 $r_{t+1} + \gamma r_{t+2} + \dots$ 走到底(不碰 $V_\phi \rightarrow$ 无偏,但要整条轨迹 $\rightarrow$ 方差大)。
- δ_t 用 $V(s_{t+1})$ 一个数把「从 $t + 1$ 到底」全部概括掉(只走一步真实 r_t ,后面托给 $V \rightarrow$ 有偏,但不用走到底 $\rightarrow$ 方差小)。

δ_t 是 A_t 的单步 bootstrap 估计($\lambda = 0$ 的 GAE),不是 A_t 本身。

「都是期望啊,差别到底在哪」—— 展开 V ,发现期望相等

把 δ_t 里的 $V(s_{t+1})$ 也按定义展开(它本身是期望): $V(s_{t+1}) = E[r_{t+1} + \gamma r_{t+2} + \dots | s_{t+1}]$ 。用 tower rule(全期望公式) $E[E[X | Y]] = E[X]$ 对 s_{t+1} 再取期望:

$$E[V(s_{t+1}) | s_t] = E[r_{t+1} + \gamma r_{t+2} + \dots | s_t]$$

tower rule 直觉(分组平均再平均 = 总平均):按性别分组算身高——男生均值 175(占60%)、女生均值 165(占40%), $E[E[\text{身高} | \text{性别}]] = 0.6 \times 175 + 0.4 \times 165 = 171 =$ 全班均值。内层是「随分组变的量」,外层按分组概率再平均一次,等于总平均。这里「性别」= s_{t+1} 、「身高」=从 $t + 1$ 起的总回报、内层条件平均 = $V(s_{t+1})$ 、外层按转移概率平均。

纯数学证明: $E[\delta_t] = 0$ (真实 V 下)

先证 Bellman 方程(从定义 + tower rule):

$$V(s_t) = E[\sum_{k \geq 0} \gamma^k r_{t+k} | s_t] = E[r_t + \sum_{k \geq 0} \gamma^k r_{t+1+k} | s_t] = E[r_t + \gamma V(s_{t+1}) | s_t]$$

对 s_{t+1} 用 tower rule

主证明(对 δ_t 取条件期望,线性拆开):

$$E[\delta_t | s_t] = E[r_t + \gamma V(s_{t+1}) | s_t] - E[V(s_t) | s_t] = V(s_t) - V(s_t) = 0$$

由 Bellman = $V(s_t)$ = $V(s_t)$ (给定 s_t 是常数)

同理 $E[A_t] = 0$: $E_{a_t \sim \pi}[A_t | s_t] = E_{a_t}[Q(s_t, a_t) | s_t] - V(s_t) = V(s_t) - V(s_t) = 0$ (用 $V = E_{a \sim \pi}[Q]$)。

结论:真实 V 下 $E[\delta_t] = E[A_t] = 0$,期望层面无差别(都为零)。 直觉:advantage 是「比平均好多少」,对动作平均后当然是零;残差是「比预期好多少」,预期准时平均也是零。

差别全在:真实世界用的是估计 V_ϕ ,不是真实 V 。

- A_t (实际回报, $\lambda = 1$):未来用真实采样,不碰 $V_\phi \rightarrow$ 无偏,方差大。
- $\delta_t(V_\phi, \lambda = 0)$:未来用 $V_\phi(s_{t+1})$ 替代 $\rightarrow$ 被 V_ϕ 误差带偏,方差小。

V_ϕ 完美时两者无差; V_ϕ 不完美才分野。GAE 的 λ 调的就是「多信实际回报还是多信 V_ϕ 」——这就是 bias-variance 权衡,不在期望本身,在「用哪种方式估同一个期望、 V_ϕ 准不准」。

GAE 的望远镜求和(为什么 $\lambda = 1$ 回到真实回报)

$$A_t^{\text{GAE}(\lambda)} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}$$

$\lambda = 1$ 时, $\sum_l \gamma^l \delta_{t+l} = \sum_l \gamma^l (r_{t+l} + \gamma V(s_{t+l+1}) - V(s_{t+l}))$, 相邻的 $\gamma^{l+1} V(s_{t+l+1})$ 与 $-\gamma^{l+1} V(s_{t+l+1})$ 两两抵消(望远镜), 只剩 $\sum_l \gamma^l r_{t+l} - V(s_t) = \text{真实回报} - V(s_t)$ 。 $\lambda = 0$ 时就是 δ_t 。
GAE 在两端之间插值。

*Part 2 完 —— 五道诊断题的完整 back-and-forth。诊断能力的核心不是背结论，
是在自己初诊答歪时能看见哪里错了：歪 vs 空、外生 vs 内生、治标 vs 治根、每个修法的回旋镖。*